中图分类号: 学校代码: 10055
UDC: 密级: 公开

南開大學

博 士 学 位 论 文

基于深度学习的跨外观行人重识别关键技术研究

Research on Key Technologies of Cross-appearance Re-ID Based on Deep Learning

论文作者 刘蒙蒙 指导教师 李涛 教授
申请学位 工学博士 培养单位 计算机学院
学科专业 工科 研究方向 计算机科学与技术
答辩委员会主席 评 阅 人

南开大学研究生院

二〇二六年四月

南开大学学位论文使用授权书

本人完全了解《南开大学关于研究生学位论文收藏和利用管理办法》关于南开大学 (简称“学校”) 研究生学位论文收藏和利用的管理规定，同意向南开大学提交本人的学位论文电子版及相应的纸质本。

本人了解南开大学拥有在《中华人民共和国著作权法》规定范围内的学位论文使用权，同意在以下几方面向学校授权。即：

1. 学校将学位论文编入《南开大学博硕士学位论文全文数据库》，并作为资料在学校图书馆等场所提供阅览，在校园网上提供论文目录检索、文摘及前 16 页的浏览等信息服务；

2. 学校可以采用影印、缩印或其他复制手段保存学位论文；学校根据规定向教育部指定的收藏和存档单位提交学位论文；

3. 非公开学位论文在解密后的使用权同公开论文。

本人承诺：本人的学位论文是在南开大学学习期间创作完成的作品，并已通过论文答辩；提交的学位论文电子版与纸质本论文的内容一致，如因不同造成不良后果由本人自负。

本人签署本授权书一份（此授权书为论文中一页），交图书馆留存。

学位论文作者暨授权人 (亲笔) 签字：_____

20　　年　　月　　日

南开大学研究生学位论文作者信息

论 文 题 目	基于深度学习的跨外观行人重识别关键技术研究				
姓　　名	刘蒙蒙	学号	1120190176	答辩日期	
论 文 类 别	博士 ☑　学历硕士 ☐　专业学位硕士 ☐　同等学力硕士 ☐　划☑选择				
学院（单位）	计算机学院		学科/专业 (专业学位) 名称	工科	
联 系 电 话	18222408590		电子邮箱	1120190176@nankai.edu.cn	
通讯地址 (邮编)：300350					
非公开论文编号			备注		

注：本授权书适用我校授予的所有博士、硕士的学位论文。如已批准为非公开学位论文，须向图书馆提供批准通过的《南开大学研究生申请非公开学位论文审批表》复印件和“非公开学位论文标注说明”页原件。

南开大学学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下进行研究工作所取得的研究成果。除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人创作的、已公开发表或者没有公开发表的作品的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名：_____ 年 月 日

非公开学位论文标注说明

(本页表中填写内容须打印)

根据南开大学有关规定，非公开学位论文须经指导教师同意、作者本人申请和相关部门批准方能标注。未经批准的均为公开学位论文，公开学位论文本说明为空白。

论文题目			
申请密级	☐ 限制 (⩽2 年) ☐ 秘密 (⩽10 年) ☐ 机密 (⩽20 年)		
保密期限	20 年 月 日至 20 年 月 日		
审批表编号		**批准日期**	20 年 月 日

南开大学学位评定委员会办公室盖章 (有效)

注：限制 ★2 年 (可少于 2 年); 秘密 ★10 年 (可少于 10 年); 机密 ★20 年 (可少于 20 年)

摘要

目前，计算机视觉技术已在诸多实际场景中得到广泛应用。其中，人脸识别技术在工业、医疗、教育等领域已展现出超越人类水平的性能，推动学术界与工业界的关注焦点逐步转向更具科研价值与应用前景的行人重识别任务。在交通运输、工业制造等现实场景中，监控图像往往存在人脸模糊甚至缺失人脸的情况，导致人脸识别技术的效能受到显著制约。行人重识别（Person Re-identification, Re-ID）旨在给定一个监控行人图像后，检索该行人在其他摄像头下出现的图像，从而弥补人脸识别失效及固定摄像头的视觉盲区，在视频监控、智能安防、智慧城市等领域具有重要的应用价值。由于行人需在跨设备的图像或视频中被识别，各设备间分辨率与安装位置不一致、监控范围缺乏重叠而导致的时空信息断裂，光照条件、背景环境、遮挡情况变化多端，以及行人姿态与外观的动态变化等因素，均为行人重识别技术的实际部署构成了严峻的技术挑战。

本文在系统梳理国内外行人重识别研究现状的基础上，凝练出现有方法在跨外观应用场景中存在的主要问题与难点，围绕跨外观场景建模与行人特征表达两个关键维度展开研究，设计并构建了新的数据集以引导模型训练，显著优化了行人检索性能。本文的主要研究进展如下：

1. 针对现实场景中行人外观随时间变化普遍存在，而传统方法多假设外观不变导致失效的问题，本文聚焦于长时间跨度下的跨外观行人重识别任务。为弥补现有跨外观数据集规模较小、外观变化程度有限的不足，构建了一个高质量、大规模的跨外观行人数据集。通过采集多个室内外摄像头跨季节监控视频，充分考虑行人图像的姿态、背景、时间分布及视角多样性，系统验证了所构建数据集在多种基准模型上的有效性与挑战性，为后续研究提供了有力的数据支撑。

2. 在经典行人重识别框架中，模型高度依赖行人的外观特征进行检索，但在跨外观场景下，外观特征反而成为干扰因素，显著增加了识别难度。为此，本文提出在传统的 RGB 图像基础上引入多模态图像信息，通过提取行人的轮廓、体型及语义分割等深层特征，增强行人特征的多样性与鲁棒性。在此基础上，融合多模态信息，提取关键特征引导模型检索，并通过增加训练批次内行人的外

观多样性，设计多外观损失辅助传统外观损失，削弱外观相关特征对决策的影响，从而提升模型在长时间跨度下的行人重识别能力。

3. 基于在跨外观数据集上的实验分析，发现数据集规模是影响模型性能的关键因素之一。然而，由于隐私保护及人工标注成本较高，尤其是在长时间跨外观场景下，数据集的构建极为困难。本文在分析现有行人数据集属性的基础上，发现当前外观数量无法有效支撑模型优化。为此，提出一种生成框架，分别提取不同行人的外观特征与体型特征，通过特征解耦与重组生成行人的跨外观图像，构建包含丰富外观变化的增强数据集。实验结果表明，扩充后的数据集能有效引导模型学习更具鲁棒性的行人特征，显著提升跨外观行人重识别性能。

4. 视角变化同样是影响跨外观行人重识别性能的重要因素。通过对比实验发现，同一视角下的检索精度显著优于跨视角场景。为此，本文聚焦于行人图像的多视角差异，通过行人的视角信息，以相近视角中的行人图像为线索，提升模型在跨视角条件下的泛化能力，更进一步提升相近视角下检索跨外观行人图像的能力。具体而言，通过相近视角的特征信息，提升行人体型或步态特征的权重。实验证明，通过相近视角下的跨外观图像检索，跨视角损失有效降低了模型对外观的依赖，提升了模型的整体识别精度。

关键词： 行人重识别；跨外观；生成模型；数据增强；度量学习

Abstract

Currently, computer vision technology has been widely applied in numerous practical scenarios. Among these, face recognition technology has demonstrated performance surpassing human levels in fields such as industry, healthcare, and education, prompting academia and industry to gradually shift their focus towards person re-identification tasks, which hold greater research value and application prospects. In real-world scenarios like transportation and industrial manufacturing, monitored images often suffer from blurred faces or even occluded faces, significantly limiting the effectiveness of face recognition technology. Person Re-identification (Re-ID) aims to retrieve images of a specific pedestrian captured by other cameras, given a query image of that pedestrian. This technology compensates for the failure of face recognition and the visual blind spots of fixed cameras, holding significant application value in areas such as video surveillance, intelligent security, and smart cities. However, practical deployment faces severe challenges due to variations in camera resolution and installation positions across different devices, lack of temporal-spatial continuity from non-overlapping fields of view, diverse changes in illumination, background, and occlusion, as well as dynamic changes in pedestrian posture and appearance.

Based on a systematic review of existing research on person re-identification, this thesis identifies the core problems and difficulties in cross-appearance scenarios. Addressing these challenges from the perspectives of cross-appearance scene modeling and pedestrian feature representation, this research designs and constructs novel datasets to guide model training, significantly optimizing retrieval performance. The main research contributions are summarized as follows:

1.Addressing the prevalent issue of pedestrian appearance changes over time in real-world scenarios, where traditional methods often fail due to the assumption of constant appearance, this thesis focuses on long-term cross-appearance person re-identification. To overcome the limitations of existing cross-appearance datasets, such as small scale and insufficient appearance variations, a high-quality, large-scale cross-appearance per-

son dataset is constructed. By collecting surveillance videos spanning multiple seasons from several indoor and outdoor cameras, and carefully considering the diversity of pedestrian poses, backgrounds, time points, and viewpoints, the dataset's validity and challenging nature are systematically verified using various baseline models, providing robust data support for subsequent research.

2.In classic person re-identification frameworks, models heavily rely on pedestrian appearance features for retrieval. However, in cross-appearance scenarios, appearance features become interfering factors, significantly increasing the difficulty of identification. To mitigate this, this thesis proposes incorporating multi-modal image information alongside traditional RGB images. By extracting deep features such as pedestrian silhouettes, body shapes, and semantic segmentation maps, the diversity and robustness of pedestrian representations are enhanced. Subsequently, by fusing multi-modal information to guide retrieval with key features, and by increasing appearance diversity within training batches, a multi-appearance loss is designed to complement the traditional appearance loss. This approach reduces the influence of appearance-related features on decision-making, thereby improving the model's capability for long-term person re-identification.

3.Experimental analysis on cross-appearance datasets reveals that dataset scale is a critical factor affecting model performance. However, constructing such datasets is extremely costly due to privacy concerns and high annotation expenses, especially for long-term cross-appearance scenarios. After analyzing the attributes of existing pedestrian datasets, it was found that the limited number of appearances per identity is insufficient for effective model optimization. Therefore, a generative framework is proposed to disentangle and recombine appearance features and body shape features from different pedestrians, generating cross-appearance images for each identity. This process creates an augmented dataset rich in appearance variations. Experimental results demonstrate that the augmented dataset effectively guides the model to learn more robust pedestrian features, significantly boosting cross-appearance person re-identification performance

4.Viewpoint variation is also a critical factor affecting the performance of cross-appearance person re-identification. Through comparative experiments, it is found that

retrieval accuracy under the same viewpoint is significantly superior to that in cross-viewpoint scenarios. To address this issue, this paper focuses on the multi-view discrepancies in pedestrian images. By leveraging the viewpoint information of pedestrians and using pedestrian images from similar viewpoints as cues, the proposed method enhances the model's generalization capability under cross-viewpoint conditions and further improves its ability to retrieve cross-appearance pedestrian images from similar viewpoints. Specifically, by utilizing feature information from similar viewpoints, the weights of pedestrian body shape or gait features are increased. Experimental results demonstrate that cross-appearance image retrieval from similar viewpoints, combined with a cross-view loss, effectively reduces the model's reliance on appearance and improves overall recognition accuracy.

Key Words: person re-identification; cross-appearance; generative model; data augmentation; metric learning

目录

摘要 …… I
Abstract …… III
第一章 绪论 …… 1
第一节 研究背景及意义 …… 1
第二节 国内外研究现状 …… 2
1.2.1 早期的行人重识别的研究 …… 2
1.2.2 基于深度学习的行人重识别研究与进展 …… 5
1.2.3 行人重识别的实用性研究 …… 7
第三节 论文结构 …… 13
第二章 面向跨外观行人重识别的大规模数据集构建与基准实验 …… 17
第一节 常用的行人重识别数据集 …… 17
2.1.1 同外观行人重识别数据集 …… 18
2.1.2 跨外观行人重识别数据集 …… 20
第二节 长期的跨外观行人重识别数据集 …… 22
2.2.1 数据集概述 …… 22
2.2.2 数据集的建立流程 …… 23
2.2.3 NKUP+ 数据集特性分析 …… 25
第三节 行人重识别算法流程 …… 27
2.3.1 特征提取 …… 28
2.3.2 度量学习 …… 31
2.3.3 重排序 …… 33
第四节 实验评估及分析 …… 34
2.4.1 评估指标 …… 34
2.4.2 传统行人重识别方法的实验结果及分析 …… 35
2.4.3 基于 NKUP+ 数据集的基准网络和骨干网选择 …… 36
第五节 本章小结 …… 38
第三章 基于多模态行人图像的跨外观行人重识别算法 …… 39

第一节 引言 …… 39
第二节 预备知识 …… 41
3.2.1 行人轮廓草图 …… 41
3.2.2 人体语义分割 …… 42
第三节 算法设计与实现 …… 43
第四节 M2Net 网络的损失函数设计 …… 45
3.4.1 行人重识别的常用损失函数 …… 45
3.4.2 基于外观标签的损失函数 …… 47
第五节 实验评估及分析 …… 49
3.5.1 实验设置和训练细节 …… 49
3.5.2 超参数预实验 …… 50
3.5.3 消融实验 …… 50
3.5.4 SOTA 模型的对比实验 …… 54
3.5.5 SOTA 模型的参数对比 …… 55
3.5.6 可视化结果及分析 …… 56
第六节 本章小结 …… 59
第四章 基于生成模型的跨外观行人数据集的外观增强 …… 61
第一节 引言 …… 61
第二节 算法设计与实现 …… 63
4.2.1 CAG 模型概述 …… 63
4.2.2 CAG 框架的设计 …… 63
4.2.3 CAG 生成框架的损失函数设计 …… 64
4.2.4 生成框架的优化 …… 67
4.2.5 行人重识别算法的设计 …… 68
4.2.6 行人重识别算法与生成图像的融合训练 …… 74
第三节 生成网络解耦外观特征和行人特征的理论分析 …… 75
第四节 实验评估及分析 …… 77
4.4.1 实验设置和训练细节 …… 77
4.4.2 消融实验 …… 78
4.4.3 SOTA 模型的对比实验 …… 79
4.4.4 可视化结果及分析 …… 81
第五节 本章小结 …… 82
第五章 基于多视角的跨外观行人重识别 …… 83

第一节 引言 …… 83
第二节 算法设计与实现 …… 85
第三节 MVMA 网络的损失函数设计 …… 86
第四节 实验评估及分析 …… 89
5.4.1 实验设置和训练细节 …… 89
5.4.2 超参数预实验 …… 90
5.4.3 消融实验 …… 91
5.4.4 SOTA 模型的对比实验 …… 92
5.4.5 引入 CAG 框架生成的行人图像 …… 94
5.4.6 可视化结果及分析 …… 95
第五节 本章小结 …… 95
第六章 总结与展望 …… 99
第一节 工作总结 …… 99
第二节 未来展望 …… 100
6.2.1 开放场景下的行人重识别（Open-world Re-ID）问题 …… 100
6.2.2 其他类型的行人重识别研究挑战 …… 102
参考文献 …… 105
致谢 …… 115
个人简历、在学期间发表的学术论文与研究成果 …… 117

第一章 绪论

本章对行人重识别及跨外观行人重识别的概念及应用前景进行简单的介绍，论述相关数据集和方法的研究的发展及瓶颈。然后，对目前行人重识别的亟待解决的问题进行进一步地分析，尤其是模型在现实世界的应用过程中存在的问题，列举行人重识别的提出及发展过程，总结模型针对行人图像中的遮挡、域适应、无标签、跨外观等重点研究方向的模型进展。最后，将本文的主要研究内容和论文组织结构进行简单的论述。

第一节 研究背景及意义

21 世纪初，中国公安部提出了覆盖全国范围的公共安防体系并开始进行试点建设。随着国家对“平安城市建设”的推进，越来越多的高清摄像头部署在各种公共场所，如机场、地铁、火车站等，伴随着计算机技术的发展，许多城市建立了“天网”的监控系统。这些系统包括大量的摄像头和数据分析中心，能够实时监控城市的交通、治安等情况。天眼系统不仅在城市中广泛应用，也逐渐扩展到乡镇、农村等地区，形成了一个覆盖范围广泛的监控网络。因此研究者将目光转向了行人重识别（Person Re-identification），行人重识别是用于跨摄像头跨场景下的对特定行人的识别和检索的主要技术。早期行人重识别提出的原因与监控画面的质量有关。监控视频由于相机分辨率和拍摄角度等原因，通常无法得到质量非常高的人脸图片，尤其是目标被口罩这样的面部遮挡的问题十分常见，因此行人重识别技术可以成为人脸识别的重要补充，相关研究受到了很大的关注。行人重识别的任务流程和应用场景如图1.1所示：

对于行人重识别的研究工作，以前的大多数数据集和模型都基于短期的行人图像，研究假定行人不会改变他们的外观，因此模型主要依靠衣着的颜色和纹理进行判断。然而，在现实世界中，跨外观的场景也很常见，如工厂、写字楼等封闭场景中，人员固定但需要长期进行身份识别，跨外观的行人重识别更具有自己的优势。尤其是智能安防场景中，坏人为了逃避监控的追踪，可以进行伪装。在这种情况下，仅通过外观进行 Re-ID 是不可靠的，需要新的方法适应这种场景，跨外观的行人重识别问题应运而生。因此，跨外观行人重识别的研



图 1.1　行人重识别应用的任务流程示意图

究具有重大的意义。然而，由于行人数据集采集的成本限制，当前跨外观行人重识别的数据集和现实场景之间存在着难以弥合的问题，同样的，基于不同数据集的行人重识别模型也难以通用。因此，研究者们需要统一多标签的跨外观行人数据集，以支持通用的识别模型。

通过调研行人重识别的研究成果与进展，本文发现行人重识别在落地应用的过程中仍存在巨大的挑战，针对行人重识别实用性包括行人图像的跨域识别，行人图像无标签或部分无标签相关的无监督或半监督问题，行人的开放场景遮挡问题、多模态行人数据等相关的行人重识别等多个问题中，本文发现跨外观行人重识别是一个亟待解决的问题，尤其对于安防应用意义重大。因此，本文聚焦于跨外观的行人重识别问题，从数据集的采集及评估入手，利用数据集提供的线索引导模型在跨外观的识别过程中获取行人的鲁棒特征，通过外观多样性和视角多样性的优势提升跨外观行人重识别模型的性能。

第二节　国内外研究现状

1.2.1　早期的行人重识别的研究

2006 年，Gheissari 等人[1]第一次系统提出了一个新的任务，即在监控网络中定位目标行人，这是图像检索的一个子问题。随后，Gary 等人[2]提出了 VIPeR 数据集，成为了早期行人重识别算法的基准数据集。早期的行人重识别的行人图像较少，但视角差异较大，因此跨视角的行人匹配是研究的难点。Wang 等

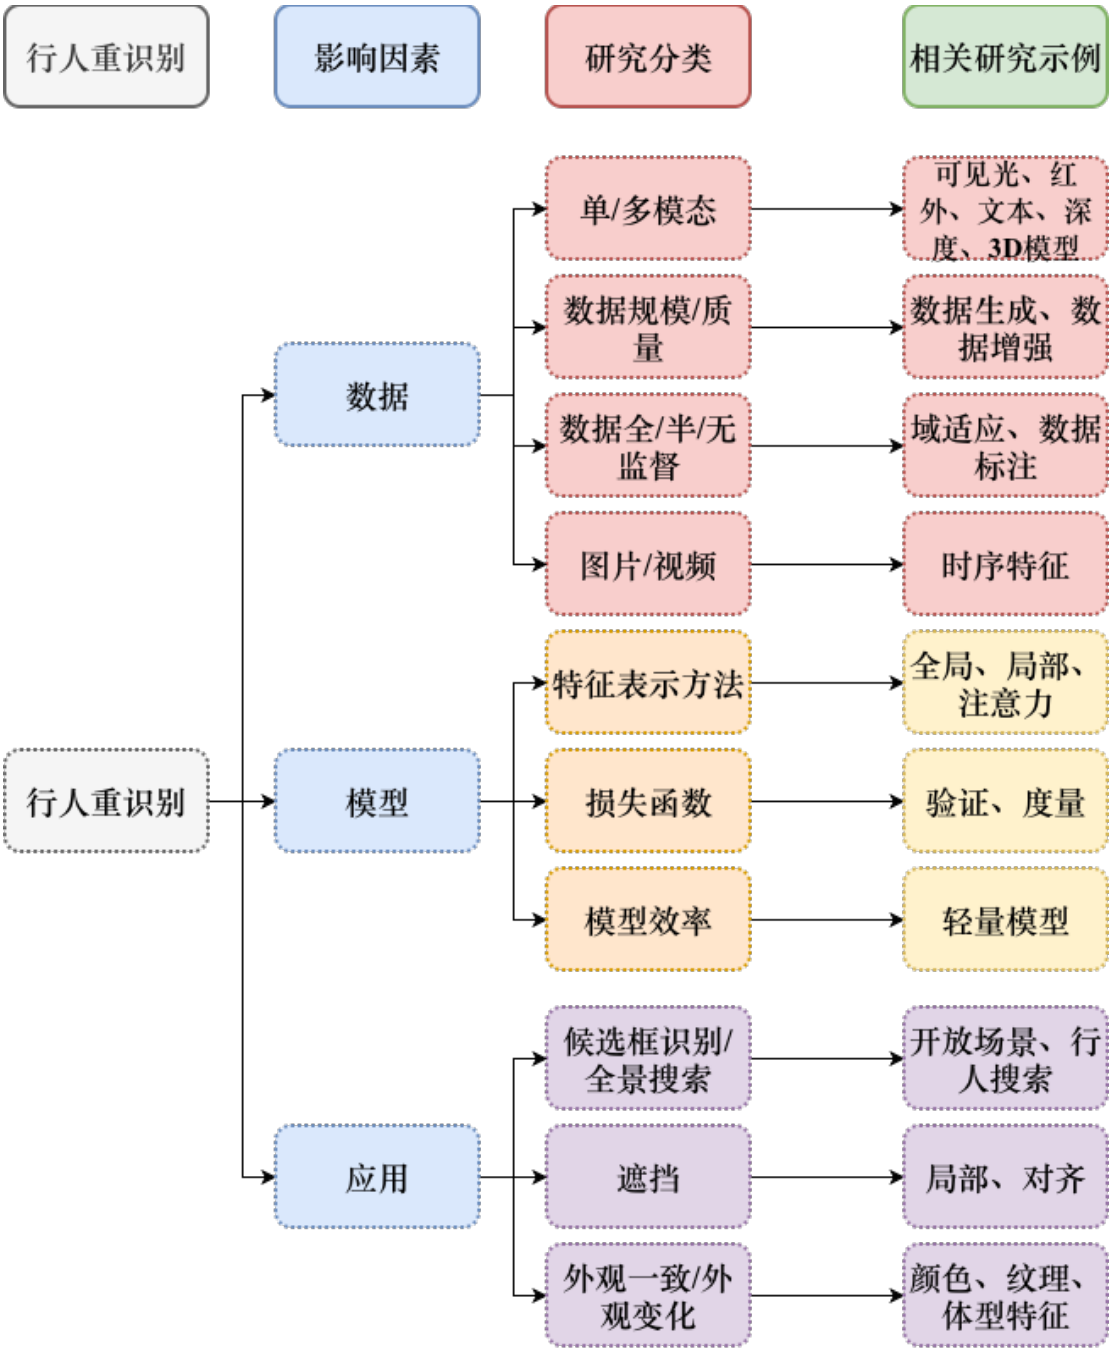


图 1.2 行人重识别研究领域总结

人[3]提出了结合行人的形状和外观进行上下文建模的方法，提升了行人跨视角下特特征匹配的鲁棒性。Gary 等人[4]使用机器学习算法根据人的直觉定义的特征空间提取行人最佳的局部特征，优化算法挖掘在跨视角下保持视角一致性的特征表示。Bazzani 等人[5]连续提取行人的关键帧，使用多帧图像的累积 HSV 颜色直方图的全局特征结合上、下半身在多帧图像中频繁出现的局部特征相结合进行行人的匹配识别。在这个阶段中，应用度量学习的概念结合更具有判别性的行人特征进一步优化了行人检索的匹配机制。

2010 年，研究者们不断尝试在特征提取的方向上进行探索。Farenzena 等人[6]提出了一种基于行人外观的算法，主要是提取与行人外观相关的三个互补的特征：整体色彩含量、颜色分布以及特殊的局部细节，从而实现了对极低分辨率、遮挡和姿势、视角和照明变化的鲁棒性。Bak 等人[7]提出了一种基于人体局部提取空间协方差区域的新算法，使用新的空间金字塔来获得人体局部间的相关性信息，使模型具有稳定的分辨能力。Prosser 等人[8]另辟蹊径，从排序问题着手，通过学习一个子空间直接对真实匹配被赋予高排名，而放弃距离度量，通过一种新的 Ensemble RankSVM，克服了之前排名方法的可扩展性限制问题，在性能和资源使用上都保持了显著的优势。Cheng 等人[9]提出了一种基于人体结构来划分行人各个局部从而提取对应局部的特征以达成精准匹配的算法。Ma 等人[10]为行人图像的每个像素计算一个由像素坐标、其强度以及一阶和二阶导数组成的简单属性向量，使用了改进 Fisher Vector（LDFV）编码融合多尺度的行人特征来增强特征的稳定性。2010 年前后，行人重识别算法开始了迅猛的发展。早期的行人重识别模型的发展从小规模数据集和人工设计特征开始，通过人的直觉为指导，逐渐发展为引导机器学习算法来获取更具有判别性的特征，以识别目标行人。

Zheng 等人[11]引入了一种新的概率相对距离比较（PRDC）模型，该模型旨在最大限度地提高一对正样本的行人图像比负样本的行人图像的特征距离更小的概率，而不是最小化类内差异，这个模型忽略光照等造成的轻微的外表变化，不容易过度拟合。Kostinger 等人[12]探索了一种简单高效的度量学习算法，即从等价约束中学习距离度量，避免了复杂的优化问题和计算上昂贵的迭代，成为了度量学习的算法的经典基准网络。Hirzer 等人[13]提出了一种松弛成对的度量学习（RPML）方法, 优化跨摄像头下的行人的相似性计算问题。2010 年后的一两年中，基于度量学习的方法逐渐兴起，研究者们发现基于相似度的匹配具有

更强的鲁棒性。

1.2.2 基于深度学习的行人重识别研究与进展

从 2014 年开始，深度学习开始逐步应用在行人重识别算法中。研究者们将行人重识别任务解决为分类问题、验证问题等，并尝试不同的思路进行尝试。如图1.2所示，总结了目前行人重识别领域的相关研究。

研究者们充分利用了深度学习模型的优势，利用卷积神经网络（Convolutional Neural Network，CNN）提取全局行人特征，通过分类函数或度量学习提升行人特征的判别性。Li 等人[14]提出了可以支持深度模型训练的行人数据集 CUHK03 数据集，并首次将深度学习应用在行人重识别任务中，模型利用卷积网络匹配行人的跨视角的特征。Ejaz 等人在[15]中提出了一种成对输入并同时学习特征的方法，网络通过跨输入差异比较结构计算两个输入图像之间的局部相似度并集成而输出一个最终的相似值，表示两个输入图像是否属于同一身份。Zheng 等人在[16]提出了一个同时计算识别损失和验证损失的孪生网络，对于成对的训练图像，网络会同时预测两个输入图像的身份，以及是否属于同一身份，网络同时学习具有判别性的特征和相似性度量，从而充分利用行人标签。这个模型影响了大量模型的损失函数设计，成为了后续研究的基准模型。Alexander 等人[17]提出了基于困难样本挖掘的最难三元组损失，这也是行人重识别算法中广泛应用的损失函数。Sun 等人在[18]中提出了一种新的度量损失函数 Circle 损失，通过重新加权每个相似度来突出未优化的相似度，从而使得模型的优化更加灵活，收敛的效果显著提升。

随着度量学习和深度学习模型更进一步的融合，对深度学习模型的梯度更新逐渐优化。行人重识别面临的难点是行人的姿态具有特异性，解决跨视角下的行人检索是提升模型性能的关键。研究者们开始探索更具有鲁棒性的行人特征，因此融合行人的全局特征和局部特征的方法不断涌现。Sun 等人在[19]中通过硬划分和软分割的方式分别分割行人图像和特征向量，对各个局部特征分别分类，使得模型增加对局部特征的关注，进而提高了模型的检索能力。Wang 等人在[20]中提出了同时学习多粒度行人特征的网络，利用灵活融合多粒度的特征而充分发挥各个粒度特征的优势，从而提升模型应对多种挑战如姿态变化、光照变化、视角变化等难题的能力。Zhang 等人[21]等人应对检测框不稳定而造成的行人局部错位的问题，使用动态对齐的方法解决错位，同时利用协同学习的方法进一步提高模型的识别精度。

行人图像的特征分为主体特征、背景特征及其他无关特征。在行人重识别的相关研究中，强调与行人有关的主体特征和更具有判别里的细粒度特征，同时抑制无关特征尤其是干扰特征如天气、光照、分辨率等对模型检索识别的影响，可以有效地提升深度学习模型对行人图像的分类和匹配能力。因此，基于注意力机制和后续基于 Transformer 的自注意力机制的研究取得了优异的结果。注意力机制主要是自适应地学习不同场景下识别任务的关注重点[22-23]，驱动模型在不同场景下关注关键特征等，使得模型在多个数据集和场景下具有更强大的泛化能力。Li 等人在[24]中提出了使用多粒度的注意力机制优化深度学习提取的行人特征的思想，使用和谐注意力机制网络（Harmonious Attention Convolution Neural Network，HA-CNN）结合跨注意力交互的学习方案，在行人重识别任务中取得了不错的效果。Chen 等人[25]提出了融合注意力机制和多样性约束的模型框架 ABD-Net，模型可以捕捉看空间和通道维度中的重要特征的所在区域，同时防止注意力过度集中于局部特征，在复杂背景和遮挡场景下的行人重识别研究中表现突出。Dai 等人[26]提出了一种 Batch DropBlock 的方法，即对模型提取的行人特征图进行随机遮挡的方法，迫使模型关注行人鲁棒的局部区域，并通过注意力机制提升对应的权重，在遮挡场景下的行人重识别任务中取得了显著的优势。Fan 等人在[27]中设计了多分支网络架构，通过内注意力网络独立学习全局特征和局部特征并通过跨注意力模块自适应融合两部分特征，最终在多个数据集上实现了优异的识别效果。Zhang 等人在[28]中提出了关系感知的全局注意力机制 (Relation-Aware Global Attention，RGA)，通过建模不同粒度的特征间的关系而动态调整不同特征的注意力权重，这种将全局上下文信息与局部特征关联的做法，大大增强了特征的判别性。Yang 等人在[29]中提出了时空图卷积网络（Spatial-Temporal Graph Convolutional Network，STGCN），结合了注意力机制建模行人动作的时空关联，通过人体的关键关节和时空序列的动态更新，显著提升了基于视频序列的行人重识别任务的精度。2017 年，Transformer 结构[30]的提出，成为了人工智能领域的分水岭，并逐渐从自然语言处理领域延伸到计算机视觉视觉等方向。He 等人在[31]中首次将 Transformer 应用到行人重识别领域，通过自注意力机制建模全局特征的依赖关系，融合了视角等辅助信息，提取鲁棒的局部特征并提高了模型检索行人的性能。Hu 等人[32]针对传统 Transformer 结构难以关注人体局部的细粒度特征的劣势，利用遮挡图像建模加强对细粒度特征的学习，结合自监督学习环节标签不足的问题，是模型更好地应对行人图

像的遮挡、错位等复杂情况，更具有泛化性和鲁棒性。

通过对行人重识别发展过程的梳理，本文在图中列出来行人重识别发展过程中的重大里程碑。目前从行人重识别相关研究的时间线来看，行人重识别模型的发展主要经历了手工设计特征和深度学习提取特征的两大阶段，结合度量学习的发展，研究者们从特征提取，特征处理，度量标准等方面挖掘了深度学习模型的潜力，使得深度学习模型对行人重识别数据集的精度一步步提升，在一些数据集上甚至超过了人的识别能力。然而，研究者们对行人重识别任务的简化建模，同样导致了行人重识别模型在复杂的真实场景中的识别精度大幅度下降的问题，因此研究者们对于行人重识别的研究场景建模逐渐由传统的简单场景逐渐转向实用场景，对行人重识别算法的实用性不断探索，解决制约行人重识别模型应用落地中面临的瓶颈。

1.2.3 行人重识别的实用性研究

域适应问题。域适应问题的起源是研究者们观察到了实验室训练出的行人重识别模型迁移到真实场景中的出现性能下降问题，这主要是由于两者的数据分布存在着巨大的差异，提高模型对跨域场景的适应性，直接关系到行人重识别技术在智能安防任务中的可用性。研究者们试图在算法设计和训练过程中缩小模型训练场景与实际部署的场景之间的差异[33-35]。解决域适应的直接方法无疑是扩充实验室训练使用的数据集，然而为了弥合真实场景，算法对数据集提出的要求十分复杂，比如室内外场景、拍摄时间导致的光照、视角、背景差异，设备本身导致的分辨率、多模态数据的差异等。覆盖丰富场景的行人数据集需要花费大量的资源进行采集和标注，且随着人们对隐私问题的重视，行人数据集的建立受到了越来越多的限制。因此，研究者们不断探索试图提升模型在跨域场景下的识别性能。Xiao 等人在[36]中使用域信息如数据集标签作为模型训练的额外输入，使得模型根据域标签提取对应的特征，结合文中提出的域引导 dropout 机制进行模型的训练优化，最终使模型在跨域的检索中表现更加稳定，提高模型对未知域的泛化能力。Huang 等人在[37]中使用部分对齐池化（Part Aligned Pooling，PAP）提取鲁棒的局部特征，结合局部分割（Part Segmentation，PS）约束目标域图像与源域图像的对齐，较好地应对源域和目标域的差异，并且其与其他方法具有较好的互补性，可以与之相结合进一步地提高其在开一问题中的检索性能。Zhong 等人在[38]中使用范例记忆模块构建一个不断更新的范例记忆库，利用对比学习等方法，引导模型适应域间变化，从而驱使模型学习

更有的域不变特征。Liu 等人在[39]中提出了自适应迁移网络架构，模型利用对抗学习的思想通过域判别器学习域不变的特征，并在模型训练过程中自适应地调整不同任务学习的权重，提高模型在跨域一致性和行人特征判别性的综合性能。Zou 等人在[40]中构建特征解耦的模块，将深度神经网络提取的行人特征解耦[41-42]成身份相关特征和域相关特征，利用对抗学习和联合优化策略，最终学习到更有效的行人特征表示。Zhang 等人在[43]使用了对抗学习的思想构建自适应域对齐模块，通过特征对齐减少源域和目标域特征分布的差异，同时在训练过程中自适应地调整对齐方式，结合多尺度特征和语义特征的辅助，最终在联合优化策略的引导下，使模型在跨域检索更加精确。

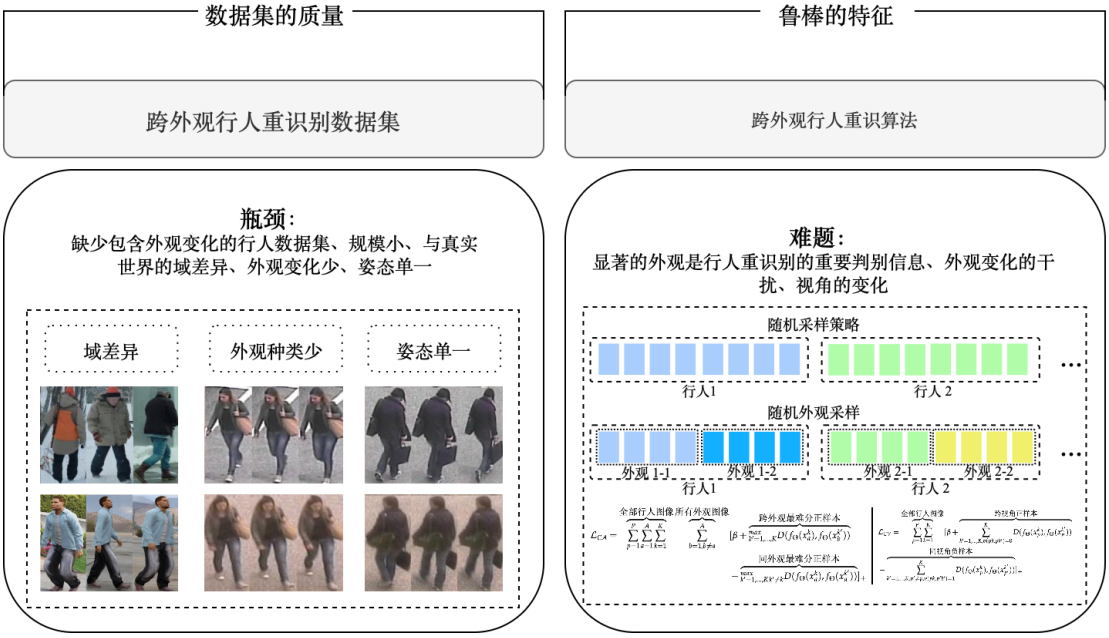


图 1.3 跨外观行人重识别研究的难点

无监督或半监督问题。无监督或半监督问题的研究动机是真实样本数据标注的高成本和不可靠性，常规的行人重识别数据集的标注需要逐帧追踪并匹配监控系统的所有行人图像，十分耗时并且需要昂贵花费[44]。同时，监控系统会随着实际需求与区域发展不断部署新的摄像头，数据集的标注很难随着设备的部署而不断更新，依靠人力标注追逐设备部署脚步并不现实。因此，在有监督的模型训练数据之外，存在大量未标注的数据并未应用于模型的训练。不仅如此，模型使用的行人数据集可能存在身份标签的长尾现象，即常见的行人样本图像数量远大于罕见的行人样本，这会直接影响模型对行人图像的分类概率。在行

人重识别的应用过程中，在无标注的数据样本的场景下应用是不可避免的，为了提高模型的泛化性能和鲁棒性，如何克服无标注的数据和应用场景，也是行人重识别应用中的一个关键挑战。Fan 等人[45]利用聚类算法赋予分组行人图像伪标签，再利用这些伪标签对模型进行训练和优化，经过多次聚类伪标签的迭代训练提取具有判别性的特征标签，模型的检索性能逐步提升。Li 等人[46]充分利用了视频序列的轨迹片段，融合多帧图像的行人特征并构建轨迹关联模型对轨迹相似性进行度量，利用轨迹关联的伪标签对模型微调，通过不同轨迹片段的特征和相似性度量结合时间标签，进一步关联跨摄像头下的行人轨迹，显著提高了无标注的视频序列中的行人重识别精度。Yu 等人[47]使用聚类的算法将行人特征分配多个软标签，软标签是行人图像特征与多个聚类中心的相似性决定的概率值，它反映行人图像与不同身份标签的关联程度，这种思想更符合实际情况中的行人图像的外观多样性和模糊性，软标签可以更加准确地反映行人图像的身份信息。Lin 等人[48]采用了自下而上的聚类策略，从单个样本出发逐渐合并形似样本形成更大的簇，通过这种方式更细致地挖掘样本间的相似性和差异性，从而提取到更具有判别性的行人特征和身份伪标签，降低身份类别粗糙划分导致的误差。Fu 等人[49]构建了一个大型的无标签行人重识别数据集“Luperson”，并利用对比学习的方式在无标签数据集上进行无监督预训练，最终获得了一个可以引导后续模型训练的基准网络，在小规模数据集上进行迁移时也具有显著的性能提升。Dai 等人[50]针对了不同行人图片数量的差异导致的类别不平衡问题，在存储每个簇代表的行人图像特征时，不存储每一张图片的特征，而选择更具有代表性的特征进行存储，这样做使模型更好地学习不同簇间的差异，并且节省了大量计算资源。Cheng 等人[51]提出了一个统一的局部到全局的动态对比学习和自监督蒸馏框架，充分利用了所有聚类和未聚类样本的自监督信号，以指导模型的学习。

开放场景行人重识别。开放场景的行人重识别是突破传统场景下的建模，即在非受控、动态变化、可能包含未知行人的复杂环境进行行人检索与匹配[52-56]。开放场景具有环境开放性、数据开放性和模态多样性的特点，这也是开放场景下的行人重识别模型需要解决的关键问题和挑战[57-60]。在动态环境下对遮挡、光照变化、分辨率特征、背景干扰具有更强的鲁棒性。Miao 等人[61]利用人体姿态的关键点信息即位置信息和置信度来应对遮挡问题，依靠可信的局部特征排除噪声的干扰，提高算法的鲁棒性。Wang 等人[62]强调了如行人间的关系和

拓扑结构这样的高阶信息在遮挡问题的关键指导作用，文章通过多尺度特征、关系建模和拓扑信息融合，对复杂场景的适应性大大增强。Lin 等人[63]利用了 transformer 强大的建模能力，将自注意力机制进行分组获取局部特征表示，鼓励局部信息的多样性和判别性，并利用弱监督学习降低对行人图像的标注信息的依赖，从而取得了良好的结果。Wang 等人[64]同时关注到了行人的鲁棒特征和遮挡物的特征污染，通过特征擦除的方式消除遮挡物的影响，通过特征记忆库和特征扩散机制扩散行人可见部位的特征，对遮挡物和行人的影响做了更好地处理。Somers 等人[65]利用姿态估计的关键点划分人体区域，并适应性地调整网络权重提取更有效的特征，使用遮挡部位补充特征或降低权重的方式融合局部特征学习更具判别性的特征表示。在面对多模态的行人图像数据时，模型对深度图像、可见光红外数据、文本描述和正常 RGB 图像具有泛化性。深度图像捕捉身体形状和骨架信息，Haque 等人[66]提出了一种基于循环注意力机制的模型，用于解决基于深度图像的行人身份识别问题。该方法在强化学习框架下，结合卷积神经网络（CNN）和循环神经网络（RNN），通过动态聚焦人体的小型判别性局部区域实现识别。Karianakis 等人[67]基于大规模 RGB 数据集设计了一种 RGB 图像到深度图像的迁移方法，以弥合深度二者间的差异。其模型进一步引入时序注意力机制，增强视频序列在深度行人重识别任务中的表征能力。文本描述和 RGB 图像间的对应在安防领域也是十分重要的，但是二者之间存在显著的语义鸿沟，是一个困难的任务。可见光红外数据主要是应用于低光照环境下的监控网络。Ye 等人[68]使用双流网络对模态共享特征和模态特定特征分别建模，同时处理模态内与跨模态的差异。Ye 等人在[69]中提出了双注意力机制，包括模态内加权局部注意力模块和跨模态图结构注意力模块，使用动态双聚合学习策略稳定收敛，减少噪声信息的影响。Ye[70]等人提出了分类器级的差异优化，进一步减少分类器层面对不同模态分类时的偏差。Wang 等人[71]通过图像生成网络 GAN 模型生成跨模态的行人图像，从输入数据层面和特征层面较少模态差异。Choi 等人[72]通过图像编码器-解码器结构进行特征解耦，然后利用分层特征学习模块捕捉不同模态图像中与行人身份标签强相关的行人特征。开放场景下的行人重识别是算法落地的必经之路，其研究不仅需要突破算法瓶颈，还需要紧密结合实际需求，解决动态性、多样性和资源约束等多维挑战。

空-地协同的行人重识别问题。Nguyen 等人[73-75]发布了空-地协同的行人重识别数据集，并提出了一种利用行人的属性来识别不同航拍和地面视角下个

体的双流可解释模型，随后进一步扩展了该数据集的版本，包括更多的行人图像以及行人视频[76-77]等。Zhang 等人[78]构建了合成的 CARGO 数据集，并使用视图标记来分层解构视图不变特征。Wang 等人[79]利用视图感知提示来解码局部不变表示，并进一步引入了 LAGPeR 和 G2APS-ReID 数据集。后续的一些研究[80-82]将空-地协同的行人重识别问题扩展到基于视频和多模态的场景中，推动了基准测试和方法的发展。通过研究者所提出的这些数据集，研究人员开发了各种方法来应对空-地协同的跨视角行人重识别挑战。

跨外观行人重识别问题。目前的大部分工作集中于短期场景内的摄像头下的行人重识别问题，因此模型主要依靠衣着的颜色及纹理为主要的判断依据，并且在一些常用的数据集上达到了较高的精度，但在真实场景中模型的性能出现了明显的降低，其原因之一是模型过度依赖行人图像的外观特征，因为外观特征常常不可靠。例如写字楼、工厂等相对封闭环境中的长时间段内的重识别，不同身份的行人图像往往具有相似外观。尤其是在安防任务的追踪场景中，目标行人容易通过改变外观逃避监控的定位追捕。仅依赖外观特征进行识别模型的性能缺乏稳定性，难以应对智能安防的需求，因此长时间段内的跨外观的行人重识别任务被提出，引起了广泛的关注。Yang 等人[83]在短时间段内进行跨外观的行人检索，基于轮廓草图使用特定角度提取器（angle-specific extractor，ASE）提取细粒度的判别特征。Qian 等人[84]强调身体形状的特征，引入形状嵌入模块和衣着消除形状蒸馏模块，消除外观变化带来的干扰信息，强调身体形状特征，为后续研究提供了新的思路。Yu 等人[85]使用两分支网络进行特征提取和检索，在锚点图像的基础上，使用服装模板作为辅助信息引导模型检索跨外观的行人图像。Fan 等人[86]提出了使用射频信号的端到端模型，将射频追踪序列作为输入，并从追踪序列中提取鲁棒特征使模型能够获得精确的人体轮廓信息促进行人检索。Hong 等人[87]提出了一种双流框架，该框架在形状流中学习细粒度的区分性体型特征，并将其迁移到外观流中，补充外观特征中与布料无关的知识，引导模型的检索。有效解决跨外观的行人重识别问题，对公共安全、预防犯罪和刑侦追查等方面有着重大的意义。

与当前热门的换衣行人重识别场景相比，换衣行人重识别任务聚焦于服装更换这一特定干扰因素[88]，为研究外观不变性特征提供了重要的切入点。然而，真实监控环境下的行人外观变化往往是多源复合的，除衣物更换外，还广泛存在光照剧变、季节更替、视角转换等多种干扰。因此，本文研究的跨外观行人重

识别在问题定义上更具普适性，它旨在应对现实场景中因各种因素导致的视觉表象漂移，要求模型具备更强的特征解耦与身份不变特征提取能力，这也是行人重识别技术从实验室走向实际应用必须跨越的关键障碍。如表格1.1所示，比较了换衣行人重识别和跨外观行人重识别的差异。

表 1.1 换衣行人重识别与跨外观行人重识别任务对比

对比维度	换衣行人重识别	跨外观行人重识别	分析说明
变化来源	单一因素：衣物	复合因素：衣物、携带物、视角、遮挡等	变化源复杂要求模型解耦更多干扰
时间跨度	通常短时间内	可长可短，尤其关注跨季节变化	时间越长，外观变化差异越显著
数据集特点	包含服装变化，但场景单一	季节多样性、时段多样性、背景多样性	构建成本更高，对数据多样性要求更苛刻
技术难点	区分衣物变化与身份变化	多种干扰下挖掘身份特征	跨外观需同时解耦服装、光照、视角等多个变量

如图1.3所示，根据跨外观行人重识别中的难点问题，本文提出对应的解决方法。具体的工作和创新点简述如下:

- 跨外观行人重识别模型数据集的制约。本文收集了多个摄像头下超过 300 名行人的监控视频序列，确保每个行人具有两种以上的外观，提出了具有外观多样性、视角多样性、背景多样性的高质量跨外观行人数据集。
- 跨外观行人重识别算法的通用性。本文针对外观变化的特点，融合对外观变化的多模态特征，提出了基于外观标签的采样策略和损失函数，提高行人特征的鲁棒性，提高了跨外观行人重识别模型的检索性能并提供一个通用性的基准。
- 跨外观行人重识别数据中外观变化缺乏多样性。本文通过对抗学习的思想解耦行人图像的外观特征和行人特征，通过外观标签和身份标签优化编码效果，使用生成网络为单个行人生成更多的外观图像种类，外观种类维度的扩充使得模型对外观变化的鲁棒性提高，取得了优异的识别结果。
- 跨外观行人重识别模型的跨视角特征一致性。行人图像的视角差异是限制行人检索性能的关键问题之一，我们观察到统一视角的行人图像的匹配精度显著高于跨视角的行人匹配。行人数据集中不同视角的行人数据分布不均衡，因此本文引入了视角模型训练视角差异，生成跨视角行人图像。在行人重识别算法的训练中，利用损失函数约束模型进行跨视角的行人特征对齐，关注鲁棒的局部特征和关键区域，解决视角问题对跨外观行人重识别的影响。

第三节 论文结构

本文主要围绕跨外观行人重识别数据集的建立和跨外观行人重识别模型的设计进行研究。在跨外观行人重识别数据集方面，本文采集了一个具备外观多样性的长时间行人重识别数据集 NKUP+，并提供了基于现有主流深度学习模型和最优效果 (State-of-the-Art, SOTA) 的行人重识别模型的实验基准; 在行人重识别模型设计方面，本文基于行人的辅助先验知识——行人语义分割、行人轮廓，设计了完整的跨外观行人重识别模型，此外还基于数据集中的行人外观标签改进了批次的样本生成策略和损失函数设计，使网络学习对外观鲁棒的行人重识别特征，进一步提升了算法性能。

围绕跨外观行人重识别研究中的关键问题，本文的具体工作如下:

第一章绪论部分。首先总体介绍了行人重识别模型的研究意义和应用前景。然后根据时间轴阐述了行人重识别相关的研究进展和国内外研究现状。最后介绍了本文研究拟解决的关键问题和研究内容。

第二章主要介绍跨外观行人重识别数据集。本文介绍了目前广泛使用的同外观行人重识别数据集和跨外观行人重识别数据集，对比了数据集的属性并分析目前行人数据集的局限。分析目前行人数据集存在的局限，即不适用于算法应用场景的复杂性，尤其是对于长时间段内的身份识别和目标追踪任务，目标人员的外观很难保持完全一致，这给识别算法带来了巨大的挑战。为了弥合行人重识别任务建模与应用场景之间的差异，提升模型对于复杂应用场景的鲁棒性，提出了包含行人外观变化的行人数据集，支持模型在跨外观行人检索的适应能力。

第三章主要介绍一种新的跨外观行人重识别算法。针对行人图像的外观变化和对应的外观标签，本文引入了除 RGB 图像之外的模态输入，算法融合三种模态特征，提取行人图像中鲁棒的行人特征。在模型的训练和推理过程中，使用加入外观标签的随机采样算法最大化模型训练中的外观多样性，并使用针对外观变化的损失函数约束，显著地提高模型对外观变化的适应性，并可以结合其余的跨外观行人算法的插件和模块进行进一步的优化，为后续的跨外观行人重识别算法提供一种新的基准和参考。

第四章针对目前跨外观行人重识别数据集存在的规模小，外观变化的种类有限的问题展开。基于深度学习的行人重识别的研究发展与数据集的扩展息息相关。从行人身份的数量维度，数据集的身份标签不断上升；从单个行人的图

像数量的维度，行人的图像上升了 1-2 个数量级；从行人姿态变化的维度来说，不同的视角和关键帧下提取的行人图像不断增加，为行人重识别模型应对视角、姿态提供了充分的支持。因此，在行人外观维度的多样性提升，也是十分必要的一个步骤。然而，行人数据集昂贵的成本限制了数据集的自由发展，跨外观的行人数据集尤为如此。本章使用生成框架 GAN 网络进行模型的跨外观图像生成，增加单个行人的外观种类，进一步驱使模型忽略外观相关的特征，扩大行人身体形状、发型等相关的特征的影响。实验结果和可视化分析证明了增强外观种类的策略对跨外观行人检索的提升是十分有效的。

第五章主要介绍一种结合行人的多视角行人图像信息引导模型进行跨外观行人检索的模型。从训练策略层面出发，通过引入视角软标签和跨视角损失，模型在训练中被显式地引导去学习视角不变的身份特征，有效缓解了因视角变化导致的外观混淆问题。实验结果表明，该方法在不同视角分布的数据集上均能稳定提升性能，且与第三章的采样策略和第四章的生成数据可叠加使用，验证了其作为训练策略层面的通用性增强手段的有效性。

最后对本文在一系列研究内容的工作进行归纳总结，并对未来的研究方向进行展望，本文的章节安排如图1.4所示：

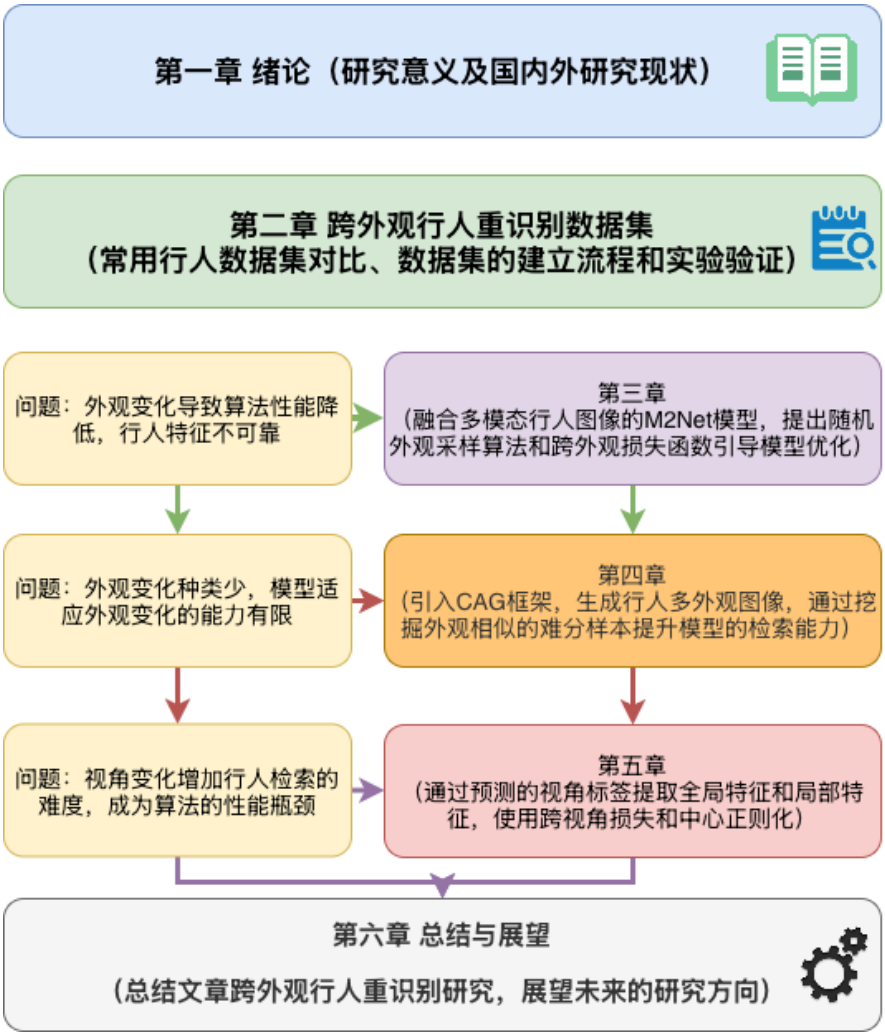

第一章 绪论（研究意义及国内外研究现状）
第二章 跨外观行人重识别数据集
（常用行人数据集对比、数据集的建立流程和实验验证）
问题：外观变化导致算法性能降低，行人特征不可靠
第三章
（融合多模态行人图像的M2Net模型，提出随机外观采样算法和跨外观损失函数引导模型优化）
问题：外观变化种类少，模型适应外观变化的能力有限
第四章
（引入CAG框架，生成行人多外观图像，通过挖掘外观相似的难分样本提升模型的检索能力）
问题：视角变化增加行人检索的难度，成为算法的性能瓶颈
第五章
（通过预测的视角标签提取全局特征和局部特征，使用跨视角损失和中心正则化）
第六章 总结与展望
（总结文章跨外观行人重识别研究，展望未来的研究方向）

图 1.4　文章的章节安排

第二章　面向跨外观行人重识别的大规模数据集构建与基准实验

通过对行人重识别领域的现有研究工作的梳理，揭示了当前跨外观行人重识别面临的两大核心挑战：其一是缺乏大规模数据集导致模型泛化能力不足；其二是外观特征变化对检索的严重干扰。针对第一个挑战（数据集问题），本章将重点阐述本文构建的大规模跨外观数据集——NKUP+ 的过程与细节，为后续章节的方法验证提供数据基础。

行人重识别是在跨场景下检索目标行人的任务。传统的行人重识别任务中假设行人的外观在检索前后保持一致，行人衣着相关的颜色和纹理对特征识别影响十分显著，因此模型对行人图像中的外观特征十分依赖。然而在安防领域中，检索任务的目标更改外观的成本低廉，跨外观的目标检索对模型提出了巨大的挑战。传统的行人重识别模型在跨外观的场景中表现并不理想，因此研究者们探索新的方法以适应新的场景。现在表现优异的模型都基于深度学习的训练和推理，因此跨外观场景下的行人数据集对于新的模型具有重大的意义。首先，本文通过采集真实监控中的视频片段，在数据集的外观、视角、场景以及设备的多个维度拟合真实的跨外观行人重识别场景。其次，本文介绍制作数据集的流程和数据集的优势。最后，本文并通过多种实验证明了行人数据集对于不同模型的性能的判别能力，为后续的研究提供新的基准。

第一节　常用的行人重识别数据集

目前广泛使用的行人重识别数据集都遵守相同的假设，即锚点图像和行人候选图像的外观保持一致。模型在检索目标的过程中仅仅考虑监控设备的差异，并不关注行人外观的差异，因此大部分模型都无法提取到行人本身的鲁棒性特征。跨外观行人重识别的概念的提出来源于安防场景的挑战，研究者们为了使模型在现实场景中的应用达到更好的结果，突破了传统场景的限制，提出来了一系列包含行人外观变化的数据集的研究工作。

2.1.1 同外观行人重识别数据集

行人重识别任务的难度来自于主要来源于现实的大规模监控网络中固有的、无法避免的多种因素导致的类内差异巨大化和类间差异模糊化[89-91]。现代安防主要依靠大规模监控网络，这意味着行人图像具有巨大的差异，主要包含以下几个因素：

- 视角与姿态变化（Viewpoint and Pose Variation）：这是最核心的挑战。行人行走方向的随机性导致摄像头可能从 0° 到 360° 的任何角度捕捉图像。同一行人的正面、背面、侧面视图在像素层面上差异极大。其数学描述是，设 I^A 和 I^B 是同一行人在摄像头 A 和 B 下的图像，其像素级差异 $d_p(I^A, I^B) = ||I^A - I^B||_2$ 可能非常大。而两个不同行人的侧面视图 I^C 和 I^D 的差异 $d_p(I^C, I^D)$ 可能反而较小。本文的目标是学习一个特征映射函数 $f(\cdot)$，使得在特征空间中的距离 $d_f(f(I^A), f(I^B)) \ll d_f(f(I^C), f(I^D))$。
- 光照变化（Illumination Variation）：室内外、昼夜、晴雨天气的光照条件截然不同，严重影响了颜色特征的稳定性和可靠性。从行人图像形成的识别模型可简化为 $I(x) = R(x) \cdot L(x)$，其中 $R(x)$ 是反射分量（物体固有的颜色），$L(x)$ 是光照分量。模型提取的行人特征应主要对 $R(x)$ 敏感，而对 $L(x)$ 鲁棒。
- 遮挡（Occlusion）：行人可能被静态物体（如栏杆、车辆）或动态物体（如其他行人）部分遮挡，导致仅能获取到人体的局部可见区域。遮挡问题的本质是从局部信息推断全局身份，是一个不适定（Ill-posed）问题。算法必须摒弃“脏数据”（遮挡部分）的影响，并高效匹配“干净”的局部区域。
- 低分辨率与运动模糊（Low Resolution and Motion Blur）：远距离拍摄和行人运动导致图像模糊、细节丢失，使得细粒度特征难以提取。行人模型可视为降质过程：$I_{LR} = (I_{HR} \otimes k) \downarrow_s + n$，其中 $\otimes$ 是卷积，k 是模糊核，$\downarrow_s$ 是下采样，n 是噪声。ReID 模型需要对此类降质具有不变性。
- 背景杂乱（Cluttered Background）：自动检测（如 Faster R-CNN, YOLO）得到的行人边界框通常包含不少背景像素，这些无关信息会干扰主体特征的表达。
- 类内差异大 vs. 类间差异小（Large Intra-class Variance vs. Small Inter-class Variance）：这是所有识别任务的性能瓶颈，在行人重识别中尤为突出。同一人的不同图像差异可能远大于两个穿着相似衣服的不同人的图像差异。

这些挑战决定了行人重识别技术不能简单地依赖行人图像的浅层特征进行特征匹配，行人重识别任务要求算法拥有更加强大的特征表征能力和特征匹配能力，因此深度学习的出现是行人重识别技术进行发展的一个重要窗口。从简单文本到复杂图像，深度学习的发展始终伴随着数据集的更新和扩充。行人重识别领域的数据集的发展也经历了单一场景到复杂的实用性需求驱动的复杂场景的演变。早期阶段的行人数据集主要是小规模的简单场景下的数据集。随着深度学习的发展，出现了很多大规模的行人数据集，以支持深度学习的训练。目前同外观的代表性数据集主要包括 VIPeR、CUHK01、CUHK03、Market-1501、DukeMTMC-reID 等。数据集的详细信息如表格2.1所示：

表 2.1　同外观行人重识别的代表性数据集

名称	发表时间	行人数量	图像数量	摄像头数量	检测方法
VIPeR[2]	2007	632	1264	2	手工裁剪
CUHK01[14]	2012	971	3884	2	手工裁剪
CUHK03[14]	2014	1467	14096	10	DPM/手工裁剪
Market-1501[92]	2015	1501	32668	6	DPM
DukeMTMC-reID[93]	2017	1812	36411	8	手工裁剪
MSMT17[94]	2018	4101	126441	15	Faster RCNN

VIPeR 是首个经典的行人数据集，每个行人的数据由 2 个摄像头拍摄的一对图像组成，该数据集来自 2 个监控视频，首次考虑了视角和光照的多样性。但是由于当时设备的限制，数据集的规模较小，且行人图像的分辨率较低，同时每个行人只包括两张行人图像，意味着行人的姿态变化十分有限。这个数据集是早起手工设计行人特征时的常用数据集，并不足以支持深度学习的训练。

CUHK01 沿袭了 VIPeR 数据集的特点，同样来自于一对摄像头拍摄的图像。这个数据集的摄像头的分辨率较之前有明显提升，行人图像的质量相对较好。同时，行人的数量和每个行人的图像数量都有所增加，但仍然受限于数据集的规模。

CUHK03 是第一个规模较大，可支持深度学习训练的行人数据集。这个数据集分别提供了 DPM 行人检测器的行人图像和人工裁剪的行人图像两个版本。这个数据集的测试协议包括两种：第一种是随机挑选 100 个行人作为测试集，其余分别为训练集和验证集，这种测试方法是经典的机器学习的测试协议，广泛应用于相关的学术研究；第二种是大约均分整个数据集为训练集和测试集，这种划分方法也是后续行人重识别数据集最广泛的测试协议，这种划分方式适合

大规模的数据处理和实际的应用场景，特别在智能安防场景中可以显著提升模型的精度和速率。

Market-1501 是目前最常用的行人重识别数据集，其测试协议对以后推出的行人重识别数据集均有重大的影响，前面提到的 CUHK03 新的测试协议也深受其影响，因此这个数据集逐渐成为了主流的行人重识别数据集基准。其不仅在传统的行人重识别场景中被大量使用，研究者们也常常将原始数据集进行相应的处理以应对行人重识别模型的实用性问题，如遮挡问题、域适应问题及跨外观行人重识别问题。

DukeMTMC-reID 来源于 8 个摄像头的监控数据。其中的行人图像是基于视频的行人追踪数据集 DukeMTMC 的一个子集，这个数据集是由视频数据中每 120 帧采集一张图像构成的。

MSMT17 数据集相比于之前的数据集更接近于真实场景。这个数据集突破了早期数据集规模小、场景单一、光照变化不显著等缺点，采集自 12 个室外摄像头和 3 个室内摄像头的监控系统，在不同天气和光照条件下进行采集。同时，MSMT17 使用了更先进的 Faster RCNN 网络获取行人检测框。

2.1.2 跨外观行人重识别数据集

自从深度学习出现以来，行人重识别的突破性进展不断涌现。传统的行人重识别定义简化了行人检索的过程，一方面，简化的场景推动了行人重识别模型的早期发展。另一方面，简单的检索过程也限制了行人重识别模型用于现实世界的实用性发展。以常用的 Market-1501 数据集为例，模型的精度在数值上已经接近完美，然而大量的模型在新的数据集或场景中的精度却大大降低。因此，研究者们不断突破传统行人重识别的定义限制，逐渐转向行人重识别模型的实用性研究。尤其是跨外观的行人重识别对于智能安防意义重大，为了支持跨外观行人检索的模型的进展，研究者们提出了多个跨外观的行人重识别数据集。数据集的详细信息如表格2.2所示：

Celebrities 是最早明确提出用于解决长期跨外观行人重识别问题的数据集之一。囿于跨外观的行人图像的采集难度，它主要来源于名人的街拍照片，数据集中的行人图像覆盖了较大的姿势变化和复杂背景。街拍图像的采集设备与常用的监控摄像头具有较大的差异，因此行人图像与常见的跨外观场景下的监控图像在分辨率等方面显著不同，这造成模型在跨域场景下表现不佳。

PRCC 是目前使用频率最高的跨外观行人数据集。这个数据集的采集过程

表 2.2 跨外观行人重识别的代表性数据集

名称	发表时间	行人数量	图像数量	摄像头数量	数据来源	跨季节采集
Celebrities[95]	2019	590	10842	-	街拍	否
PRCC[83]	2019	221	33698	3	监控	否
COCAS[85]	2020	5266	62382	30	监控	否
LTCC[84]	2020	152	17,138	12	监控	否
VC-Clothes[96]	2020	512	19060	-	3D 引擎	-
Real28[96]	2020	28	4324	3	监控	否
NKUP[97]	2020	107	9738	15	监控	是
LaST[98]	2021	10862	228156	-	影视作品	是
DeepChange[99]	2021	1121	178407	17	监控	是
NKUP+[100]	2022	361	40217	29	监控	是

具有严格的限制，行人在较短时间内在室内的三个摄像头下采集两种外观的行人图像。这意味着行人的轮廓并未发生显著变化，一方面数据集促使模型获得较好的精度，另一方面 PRCC 限制了跨外观行人检索的难度范围，不利于长期的跨外观行人重识别模型的训练。

COCAS 是来自于商品交易市场室内和室外的 30 个摄像头，数据集的时间跨度为 4 天，获得了穿着不同衣服的相同身份的行人。数据集的主要使用聚类的方法进行标注，并通过人类解析模型 LIP 从人物图像中提取衣服，并在互联网上搜索得到相应的服装模板。每个人物有 2-3 套衣服，每套衣服有 5-10 张照片。对于每个检索目标，将他穿着一种衣服的图像移动到候选集中，作为目标图像并提供相应的衣服模板指导模型的检索，其余所有的行人图像都在查询集中。但是，目前数据集仍然不公开。

LTCC 来源于设置在室内的 12 个摄像头，它使用行人检测方法获取行人框，并通过精细手工标记来标注行人标签和外观标签。这个数据采集跨度相对较长，因此它具有光照、视角和姿态的变化，同时包括衣服和携带物品的变化，甚至还包括发型变化。有助于增强模型对不同环境的适应能力，尤其是对不同的光照条件下和不同摄像头的分辨率的泛化能力。

VC-Clothes/Real28 是一篇论文所提出的真实数据集和虚拟数据集。虚拟数据集是基于游戏引擎的任务移动视频，数据集的规模和场景都具有角度的优势，但是它与现实世界的跨域问题仍是无法忽略的挑战。Real28 采集了 4 个包含室内室外摄像头的监控数据，然而它的规模仍然限制了模型的性能提升。

LaST(Large-scale Spatio-Temporal) 是一个具有超大时空范围的行人数据集。其中的行人图像主要来源于影视作品，这使得单个行人具有多个时间空间范围

内的图像，这为跨外观的行人重识别模型的泛化能力提供了帮助。与街拍数据集 Celebrities 相似的是，两个数据集与监控图像数据集都存在跨域问题，导致模型性能的下降。

DeepChange 是一个大规模的监控图像行人数据集。数据集采集于一个真实的大型监控系统，不含有合成数据，该监控系统分布在一个面积约 14 公顷的开放街区，含有广泛的年龄和职业范围，例如哺乳婴儿、青年人、老人、工人、学生、送货人和宗教人士等，含有丰富的行人外观和行人姿态。具有摄像头和环境多样性，以及季节、天气、光照、遮挡等方面的多样性。

NKUP 是采集自大学校园的监控系统，它考虑了光照、背景、分辨率尤其是行人外观差异下采集的跨外观行人数据集。其在室内和室外选取了 15 个摄像头，通过光照和背景多样性提高模型的泛化能力。然而数据集的规模和行人图像的视角仍然存在一定的局限。

第二节 长期的跨外观行人重识别数据集

上一节简要概述了多个行人重识别数据集，这些基准数据集无疑促进了行人重识别模型的不断发展[101]。然而长期的跨外观行人重识别是一个具有挑战性的任务，现有数据集没有显著外观变化、规模小、背景单一、与真实场景不相符等问题，这大大限制了跨外观行人重识别模型的进展。为了解决以上这些问题，本节提出了一个长期的跨外观行人重识别数据集，介绍数据集的形成流程和特点，并通过实验证明数据集对不同模型的判别能力。

2.2.1 数据集概述

随着深度学习的发展，传统的行人重识别模型的检索精度不断提升并逐渐陷入瓶颈，模型的精度数值升无可升。行人重识别的研究进入了复杂场景的新需求阶段，尤其是跨外观条件下对检索目标的长期跟踪需求。针对着季节变化、外观变化的问题，跨外观的行人重识别受到了研究者们的关注，因此涌现出了一批包含外观变化的行人数据集，然而目前提出的跨外观行人数据集仍未满足模型的训练需求。如 Celebrities、VC-Clothes 和 LaST 数据集不可避免的跨域问题，PRCC 和 LTCC 的单一场景问题，Real28 的规模问题，DeepChange 的标注可靠性问题等。这些问题限制了模型对跨外观场景的适应能力，进而导致模型在落地过程中的精度下降。



图 2.1 NKUP+ 数据集的样本示例

针对目前跨外观行人数据集的痛点问题，本文提出了名为 NKUP+ 的长期的跨外观行人重识别数据集。这个数据集来源于校园室内/室外的多个监控的真实视频，设备多样性和场景多样性可以使模型的训练和推理过程尽可能地模拟真实过程。数据集包含了 300 余个行人，每个人包含数十张行人图像，包含多种外观变化，数据集的规模和质量足以支撑深度学习模型的训练，避免模型的过拟合，从而提高了模型的泛化能力。数据集中的行人图像通过人脸识别结合采集日期及顺序给予行人标签和外观标签，保证了行人标签的可靠性，避免了异常数据对模型的误导，同时外观标签可以提供额外的信息引导模型的优化。不仅如此，NKUP+ 采集的时间跨度超过一个自然年，行人图像的外观变化涵盖了春季/秋季、夏季和冬季，长期的监控图像保证了行人外观的显著变化，提升算法对显著外观变化的适应能力。最后，考虑到监控设备的安放位置，数据集涵盖了单个行人的多视角图像，数据集的视角和姿态多样性得到了保障。

NKUP+ 数据集是 NKUP 数据集的全面升级版本，主要包含 361 个行人的 40217 张图像，数据集的规模和质量都得到了角度的提升。如图所示为 NKUP+ 中部分行人的示例，每一行按照单个行人在春季/秋季、夏季和冬季的顺序进行排列。

2.2.2 数据集的建立流程

行人数据集的建立流程一般包括数据采集、行人检测、人工标注、数据集划分等几个步骤。近年来，由于对隐私泄露问题的担忧，一些行人数据集遭到禁用，因此 NKUP+ 数据集对所有行人图像增加了隐私处理的步骤，保障数据集的合规。

数据采集阶段，在多个时间段内，组织大量志愿者在监控网络内的多个摄

像头下正常行走。通过改变采集时间、采集地点、行走轨迹，获取行人在多个摄像头下的多个视角和外观行人图像，同时为了标注的准确性，我们记录了采集时间和行人外观特点。最终，NKUP+ 数据集中的每个行人包含两种以上外观的行人图像。

行人检测阶段，本文选取了统一检测、重识别的多目标跟踪框架 FairMOT 来进行行人检测和粗略的行人标签聚合工作。我们将获取到的监控视频按照帧序输入模型，模型会输出目标的行人图像并给予顺序标签。FairMOT 框架[102]采用了 anchor-free 的目标检测算法，在高分辨率特征图上估计检测目标的中心，缓解歧义问题，这样使得检测模型输出的行人框十分精准，大大提高了行人图像的质量，同时对后续的行人重识别过程十分有益。除此之外，FairMOT 算法对目标行人给予顺序标签，如此在后续的标注阶段简化了标注的繁琐过程，降低了标注难度。不仅如此，FairMOT 在吞吐速率上也具有比较大的优势，可以实现视频速率的推理速度。如图所示，使用 FairMOT 框架的检测和识别流程。

人工标注阶段中，我们根据前一步获取的行人图像，结合采集时间和行人外观，我们将单个行人的所有图像归纳在统一的文件夹中。通过采集日期区分行人的外观变化，并按照顺序给予外观标签。同时，根据采集日期，容易区分季节即外观变化的差异大小，引导的模型的训练和测试。在这一步中，去掉了帧序间隔小和质量过低的行人图像，降低类别不平衡问题对算法的影响。

隐私处理阶段，本文选取了 RetinaFace 的人脸检测算法定位行人图像中的人脸区域。通过高斯模糊目标区域以去除人脸信息，这不仅遵守了隐私保护的原则，并强制模型无法依赖人脸特征指导模型的训练。除此之外，行人姓名、摄像头位置和名称等关键信息被数字化处理并随机排序，最终显著降低了隐私泄露的风险。

表 2.3 NKUP+ 数据集的划分情况

		行人数量	外观数量	摄像头数量	图像数量
训练集		181	503	28	22590
测试集	查询集	181	181	26	3551
	同外观子集	181	181	26	3784
	轻微外观变化子集	140	152	20	3661
	显著外观变化子集	96	100	13	6631

数据集划分阶段，本文受到了目前常用行人数据集的启发，保持了训练集和测试集行人数量相等的规则。显然，训练集和测试集中的行人没有重叠。在

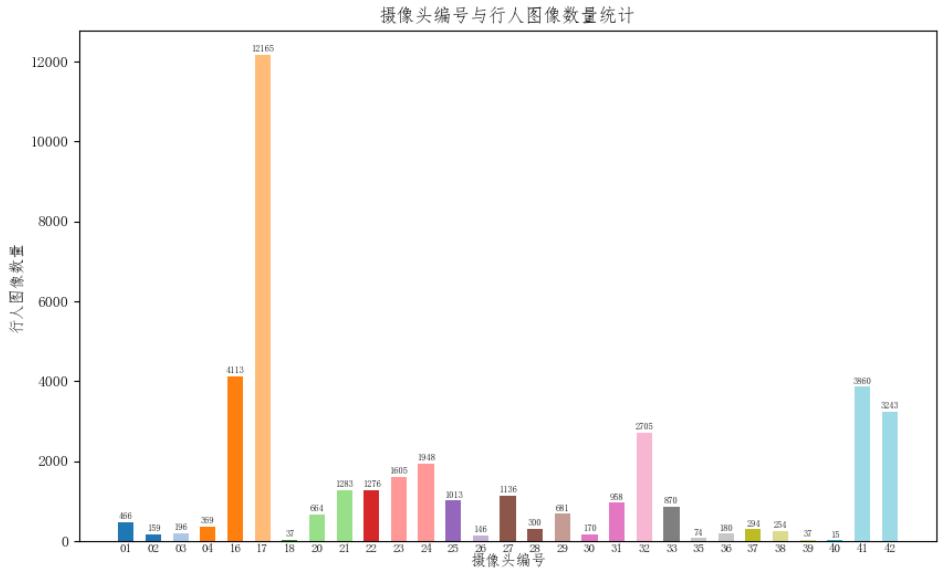


图 2.2 不同摄像头下行人图像数量的分布

测试集中，对于单个行人，本文随机选取一种外观，并选取该种外观的若干张行人图像作为锚点图像即归入查询集。剩余的同外观图像会归入候选集中的同外观子集，以满足多种测试需求。其余的外观图像会归入候选集中的跨外观子集。同时，根据采集日期对应季节，相近温度的季节的外观变化会定义为跨外观子集中的轻微外观变化；反之，定义为跨外观子集中的显著外观变化。根据不同的实验要求和测试协议，本文可以选取对应的候选集进行实验验证。数据集的详细划分情况如表格2.3所示。

2.2.3 NKUP+ 数据集特性分析

NKUP+ 是用于长期的跨外观的行人重识别任务的数据集，如图所示是数据集的样本示例。数据集采集了 29 个监控摄像头的视频数据，标注了 300 余人的 40000 多张行人图像，具有外观多样性、视角多样性、背景多样性和姿态多样性的特点，下面将统计数据集关于不同属性的数据分布情况，以说明 NKUP+ 的特性和优势。

- 数据来源多样性。智能安防的重大挑战之一是识别场景的复杂性，检索目标的移动路线复杂多样。因此我们选取的监控设备包括分布在室内室外的 29 个摄像头，覆盖面积广泛。监控设备的性能具有差异化，使数据集更接

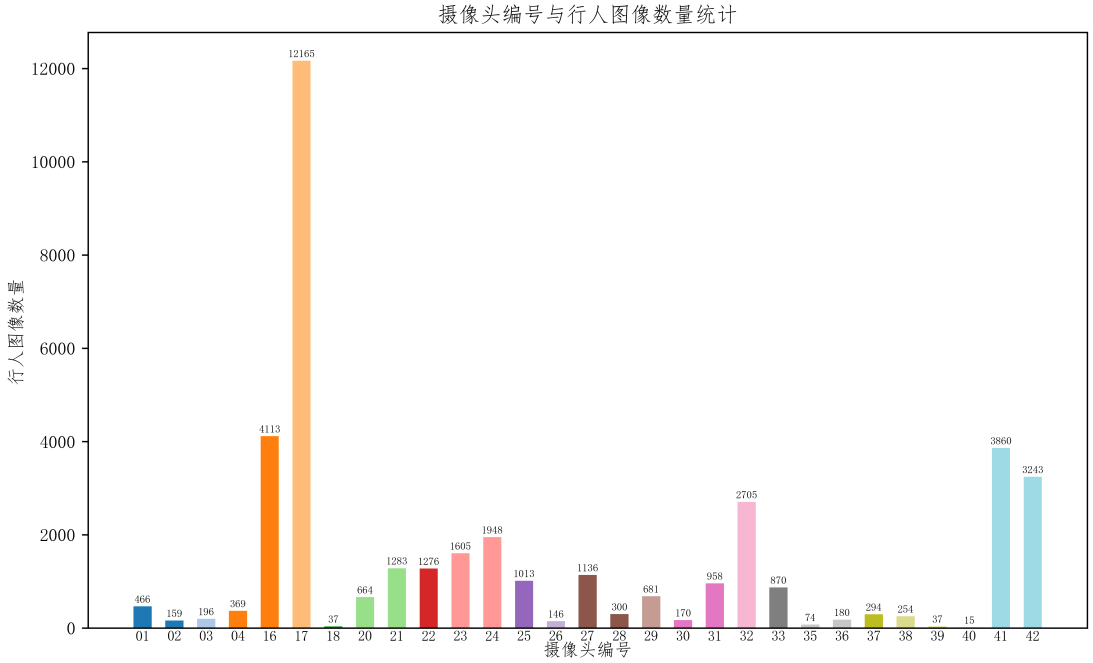


图 2.3 不同摄像头下行人图像数量的分布

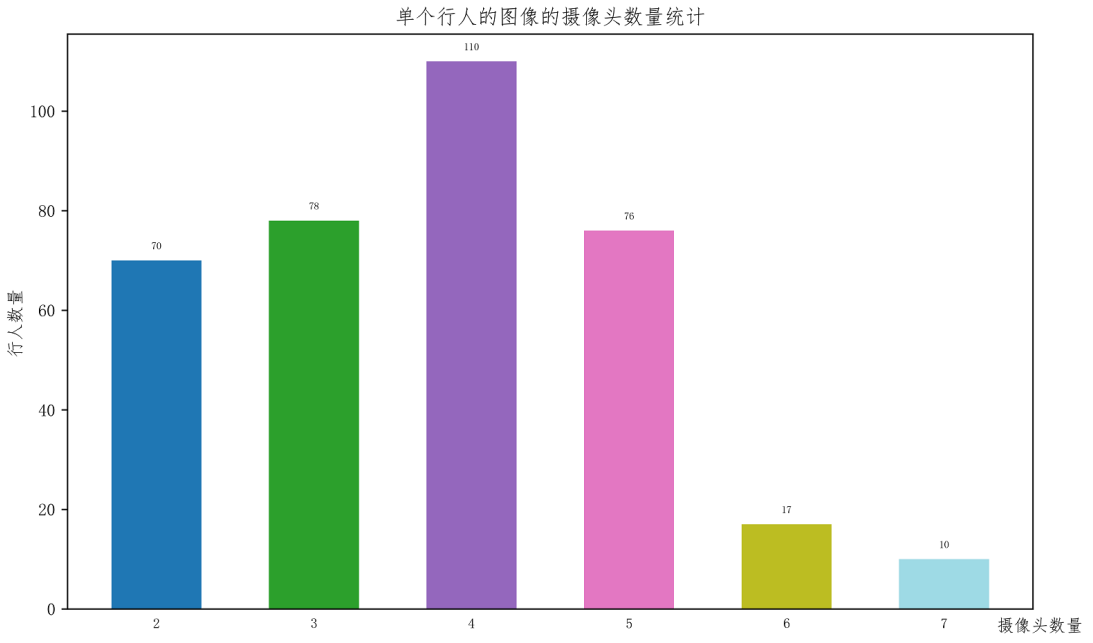


图 2.4 不同摄像头下行人图像数量的分布

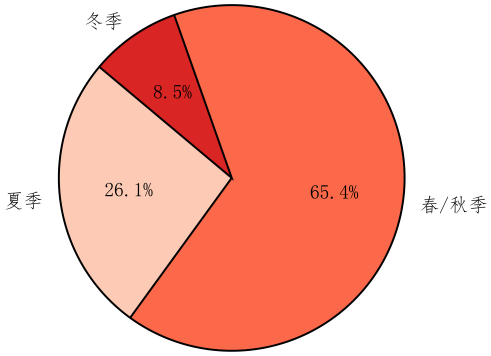


图 2.5 各季节行人数量分布

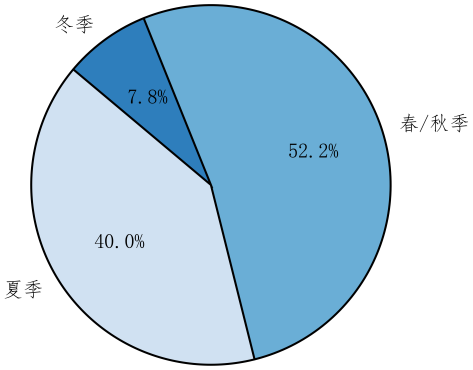


图 2.6 各季节行人图像数量分布

近于真实场景图像。室内和室外的行人图像数据接近，避免了室内室外图像数量不平衡的问题。不同监控设备拍摄的行人数量和行人图像数量的分布情况如图2.2和图2.3所示。尤其是对于单个行人来说，至少被 2 台及以上的摄像头捕捉到，单个行人的图像来源于摄像头的数目的分布如图2.4所示。

- 视角多样性。根据 NKUP+ 的采集规则，采集目标的行进轨迹包含多段，因此行人图像的视角包含正面、背面和侧面多个角度。这使得 NKUP+ 数据集不局限于固定位置的行人图像，与真实监控设备的图像十分贴近。引导模型提升对于多视角的适应能力，避免特定视角的过拟合现象。图展示了 NKUP+ 数据集中的多视角的行人图像样本。
- 外观多样性。包含外观变化是 NKUP+ 数据集最重要的特性。对于每一个行人，采集不同日期的行人图像，保障了行人图像的外观变化。数据集的采集时间跨越了一个自然年，这意味着行人在一年四季中包含显著的外观变化。其在不同季度的行人数量占比和图像数量占比如图2.5和图2.6所示。

第三节 行人重识别算法流程

完整的行人重识别算法通常包括：数据预处理、特征提取、相似度度量、重排序、结果输出几个环节，其中特征提取和、相似度度量和重排序是影响算法性能的核心模块。

2.3.1 特征提取

特征提取的目标是将原始 RGB 图像 $I \in \mathbb{R}^{H\times W\times 3}$ 映射为一个低维、稠密且具有高度判别性的特征向量 $\mathbf{f} \in \mathbb{R}^{D}$，其中 D 是特征维度。对于后续发展出的其他模态的行人数据来说，这个过程是类似的，其区别在于输入模型的原始数据的维度不同。

2.3.1.1 手工设计特征

在深度学习兴起之前，相关领域的研究者依靠经验和领域知识表征行人特征。被广泛使用的几个手工设计特征包括：

1. 颜色特征（Color Features）：颜色直方图（Color Histogram），这是最基础的颜色特征。将图像的颜色空间（如 RGB, HSV, Lab）量化成若干个区间 (bin)，统计每个区间内像素的数量。设颜色空间被量化为 B 个区间，直方图特征向量 $\mathbf{h} = (h_1, h_2, ..., h_B)$，其中 $h_i = \sum_{(x,y)} \mathbb{I}(I(x,y) \in \text{bin}_i)$，其中，$\mathbb{I}$ 是指示函数。因此颜色直方图特征对于图像的旋转和小范围平移并不敏感，但是同时也失去了图像中颜色的空间分布信息。颜色直方图的相似度计算常使用卡方距离（Chi-square distance）进行度量，其公式为：

$$d_{\chi^2}(\mathbf{h}^1, \mathbf{h}^2) = \sum_{i=1}^{B} \frac{(h_i^1 - h_i^2)^2}{h_i^1 + h_i^2} \tag{2.1}$$

2. 纹理特征（Texture Features）：局部二值模式（Local Binary Pattern, LBP）和方向梯度直方图（Histogram of Oriented Gradients, HOG）。前者描述图像局部纹理特征。对于一个中心像素，将其与邻域像素比较，生成一个二进制串，再转换为十进制数。最后统计整幅图像 LBP 值的直方图作为特征。对于中心像素 g_c 和其邻域像素 g_p (p=0,1,...,P-1)，其 LBP 特征的计算公式为：

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) \cdot 2^p, \quad \text{where } s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases} \tag{2.2}$$

后者通过计算和统计图像局部区域的梯度方向直方图来构成特征。主要的步骤包括：a) 图像灰度化; b) 计算水平和垂直梯度; c) 计算每个像素的梯度幅值和方向; d) 将图像划分为细胞单元（cells），统计每个 cell 的梯度方向直方图; e) 将相邻的 cells 组合成块（blocks），对块内特征向量进行归一化; f) 连接所有块的特征。因此能很好地描述物体的轮廓和形状。纹理特征可以克服光照的影响，同

时保留行人图像中像素的空间信息，为模型的识别保留了更多的线索，因此是常用的手工设计特征，甚至在部分工作中和深度学习模型提取的特征组合一起进行识别。

3. 高级语义特征：姿态估计（Pose Estimation）[103-104]：首先利用姿态关键点检测模型（如 OpenPose）定位出人体的 14 或 17 个主要关节点（如头、肩、肘、膝、踝等）。然后根据关键点将人体划分为若干预定义的区域（如头肩区、上身区、下身区）。最后，在每个区域内分别提取颜色和纹理特征，并将所有区域的特征拼接成一个长的综合特征向量。姿态相关的特征实现了结构化的特征表达，对齐了身体部件，减轻了姿态变化的影响。同时姿态估计的结果受到依赖关键点检测的准确性的限制，姿态关键点检测失败会直接导致行人图像的特征提取失败。

2.3.1.2 深度学习特征

卷积神经网络（Convolutional Neural Network）的出现开启了深度学习时代，CNN 模型强大的层次化特征学习能力，彻底取代了传统的手工设计特征。基于深度学习的行人重识别特征提取主要包括的特征类型主要有以下几种：

1. 全局特征（Global Feature）：模型通常采用在 ImageNet 上预训练的分类网络作为特征提取器，即骨干网络（Backbone Network），如 VGG、ResNet、Inception、DenseNet 等。其中，ResNet50 因其优异的性能和良好的深度扩展性成为最常用的 Backbone。骨干网络最后的全局平均池化层（GAP）输出一个固定长度的特征向量 $\mathbf{f}_{\text{global}}$ 作为图像的表征，这就是行人图像的全局特征。全局特征的计算高效，包含了图像的全局语义信息。但是，其对细节和局部区分性特征捕捉不足，容易受背景和遮挡干扰。

2. 局部特征（Local Feature）：为了克服全局特征的缺点，研究者们提出了一系列局部特征学习方法。首先是基于水平分块（Horizontal Strips / Part-based）的方法，分别是 PCB（Part-based Convolutional Baseline）和 RPP（Refined Part Pooling）。PCB 是一个里程碑式的工作，它将 Backbone 最后一层特征图（Feature Map）在高度方向上均匀地划分为 P 个图块。对每个图块进行全局平均池化，就会得到多个局部特征向量 $\mathbf{f}_p$ (p=1,2,...,P)。每个 $\mathbf{f}_p$ 后接一个独立的分类器（全连接层 +Softmax 分类函数），进行身份分类。RPP 是 PCB 的改进版，它针对均匀划分可能导致一个部分落在两个不同的身体部位上（如头和身的连接处）的问题，引入了一个注意力模块，学习特征图上每个空间位置属于哪个预定义部分

的概率，实现更柔和的、基于语义分割的图块划分，从而优化了行人图像的部分对齐。

随后，一系列基于注意力机制（Attention Mechanism）的方法被不断提出[105-109]，包括软注意力（Soft Attention）和硬注意力（Hard Attention）等。软注意力机制的目的是使网络自主学习特征图中哪些空间区域更重要。通常通过附加一个子网络（如卷积层 +Sigmoid 激活层）来生成一个注意力图 $\mathbf{A} \in \mathbb{R}^{H' \times W'}$，其值在 [0,1] 之间。将特征图 $\mathbf{F}$ 与 $\mathbf{A}$ 逐点相乘，得到加权的特征图 $\mathbf{F}' = \mathbf{F} \odot \mathbf{A}$，再对 $\mathbf{F}'$ 进行全局平均池化。注意力机制特征的计算公式为：

$$\mathbf{f} = \mathrm{GAP}(\mathbf{F} \odot \sigma(\mathrm{Conv}(\mathbf{F})) \tag{2.3}$$

其中,σ 是 Sigmoid 函数。这种注意力机制通过调整权重强调行人目标的身体区域，抑制背景的干扰。硬注意力是一种非 0 即 1 的注意力权重，通常不可微，需要通过强化学习等方式训练，在算法中较少使用。

3. 姿态引导特征（Pose-guided Features）：与手工设计特征时代的思路一脉相承，但使用深度学习来实现姿态估计的过程。首先用姿态估计模型预测行人身体的关键点，然后根据这些关键点生成人体部分的热图（Heatmaps），将这些热图作为注意力掩膜或者作为额外的输入引导网络聚焦到具体行人图像中的身体部位。

4. 基于 Transformer 结构的特征提取：研究者提出 ViT（Vision Transformer）结构，将图像切分为一系列小块区域，加上位置编码后输入标准的 Transformer 编码器，它的核心是自注意力机制（Self-Attention），能够动态地建模图像所有块状区域之间的全局依赖关系。自注意力机制对于输入序列 $\mathbf{X} \in \mathbb{R}^{N \times D}$（N 个小块，D 维特征），通过可学习矩阵 $\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V \in \mathbb{R}^{D \times D_k}$ 生成 Query、Key、Value，三者的计算公式如下：

$$\mathbf{Q} = \mathbf{X}\mathbf{W}^Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}^K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}^V \tag{2.4}$$

而注意力权重和输出的公式为：

$$\mathrm{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \mathrm{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{D_k}}\right)\mathbf{V} \tag{2.5}$$

ViT 对图像的强大建模能力对行人重识别任务十分有效，不但可以获得行人图像的全局特征，对行人重识别任务中特殊的视角问题和遮挡问题都具有不错的效果。

2.3.2 度量学习

度量学习（Metric Learning）的核心目标是学习一个距离度量函数 $d(\mathbf{f}_i, \mathbf{f}_j)$，使得行人图像转化成模型学习到的特征空间里时，所有同类样本对的距离尽可能小，不同类样本对的距离尽可能大，使得同类样本对之间的距离小于不同类样本对间的距离，以此模型可以正确对行人图像进行分类。

2.3.2.1 损失函数

损失函数是模型用来衡量模型输出的预测结果与真实结果之间差异的函数，基于深度学习的行人重识别模型通过组合不同类别的损失函数来引导模型学习。

1. 身份损失/分类损失（Identity Loss / Classification Loss）：这是最直接和基础的损失函数。将行人重识别任务视为一个标准的图像分类问题，每个行人的身份是一个独立的类别，通过对于模型输出的预测结果来评估模型的预测过程，身份损失可以直接驱动模型学习对于分类过程更有效的特征表示。对于一张输入图像，模型通过骨干网提取行人图像的特征 $\mathbf{f}$，然后通过一个全连接层（权重 $\mathbf{W} \in \mathbb{R}^{D \times C}$，$C$ 是分类结果的类别数）映射为各类别的分数（logits），然后应用 Softmax 分类函数得到概率分布 $\mathbf{p}$。因此身份损失是标准的交叉熵损失函数，其定义如下：

$$\mathcal{L}_{id} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp(\mathbf{W}_{y_i}^T\mathbf{f}_i + b_{y_i})}{\sum_{j=1}^{C}\exp(\mathbf{W}_j^T\mathbf{f}_i + b_j)} \tag{2.6}$$

其中，y_i 是样本 i 的真实标签，N 是训练批次的大小（Batch Size）。

2. 验证损失/度量损失（Verification Loss / Metric Loss）：这类损失函数直接作用于样本对上，显式地约束特征之间的距离，改变模型学习到的特征空间的映射。度量损失主要包括对比损失、三元组损失、最难三元组损失和四元组损失等。这些损失函数会选取至少两个样本组成样本对来计算损失，同时设置一个边际值（margin）来强制约束类内样本和类间样本的特征距离。

对比损失（Contrastive Loss）同时处理行人图像的正样本对（属于同一身份的行人图像）和负样本对（属于不同身份的行人图像），对于正样本对（$y_i = 1$），最小化其特征距离；对于负样本对（$y_i = 0$），在其距离小于边际值 $m > 0$ 时进行惩罚，使其距离至少大于 m。对比损失的计算公式如下所示：

$$\mathcal{L}_{\text{cont}} = \frac{1}{2N}\sum_{i=1}^{N}\left[y_i \cdot d(\mathbf{f}_{i1}, \mathbf{f}_{i2})^2 + (1 - y_i)\cdot\max(0, m - d(\mathbf{f}_{i1}, \mathbf{f}_{i2}))^2\right] \tag{2.7}$$

其中，d 代表不同样本对之间的特征距离，通常使用欧氏距离进行计算。

三元组损失（Triplet Loss）是行人重识别中最重要、最经典的度量损失。它从一个训练批次中构建三元组（Triplet）样本组，分别为锚样本（Anchor）$\mathbf{f}_a$、正样本（Positive）$\mathbf{f}_p$（与 Anchor 属于同一身份的行人）、负样本（Negative）$\mathbf{f}_n$（与 Anchor 属于不同身份的行人。其核心思想是拉近 Anchor 和 Positive 的特征距离，推远 Anchor 和 Negative 的特征距离，并且推远的幅度要比拉近的幅度至少大于边际值 m。三元组损失的计算公式如下所示：

$$\mathcal{L}_{\text{triplet}} = \sum_{i=1}^{N} \left[d(\mathbf{f}_a^i, \mathbf{f}_p^i) - d(\mathbf{f}_a^i, \mathbf{f}_n^i) + m \right]_+ \tag{2.8}$$

其中，$[x]_+ = \max(0, x)$，是用以最大化分类间隔的 hinge 损失。

最难三元组损失（TriHard Loss）是建立在三元组损失的思想下提出的。对于模型训练依据的数据集来说，随机采样形成的三元组样本组大部分已经满足模型的约束条件，即（$d(a,p) + m < d(a,n)$），这样的三元组样本组对于模型的训练没有贡献，因此随机形成的三元组样本组降低了模型训练的效率，限制了模型学习到更优的特征空间。因此，研究者们关注那些更难识别的行人样本对，即那些类间距离小于或等于类内距离的样本对，这些样本对被定义为困难样本。通过迫使网络区分困难样本可以使模型学习到更具有判别力的特征，可以提高模型的学习速率，加快模型的收敛并提升模型的识别性能。因此研究者提出了在计算三元组损失前增加困难样本挖掘过程，从而获取对模型训练具有贡献的样本对来计算最难三元组损失。最难三元组损失函数的计算公式为：

$$\mathcal{L}_{\text{TriHard}} = \sum_{i=1}^{P} \sum_{a=1}^{K} \left[\max_{p=1\ldots K} d(\mathbf{f}_a^i, \mathbf{f}_p^i) - \min_{\substack{j=1\ldots P \\ n=1\ldots K \\ j \neq i}} d(\mathbf{f}_a^i, \mathbf{f}_n^j) + m \right]_+ \tag{2.9}$$

四元组损失（Quadruplet Loss）：在三元组样本组的基础上额外引入第二个负样本行人图像，为模型的特征空间映射增加更多的约束条件，使得类间距离不仅大于类内距离，而且不同类的负样本对之间也要保持一定距离，从而使各个身份类别的样本映射到特征空间的不同区域。四元组损失函数的计算公式如下：

$$\mathcal{L}_{\text{quad}} = [d(a,p) - d(a,n_1) + m_1]_+ + [d(a,p) - d(n_1,n_2) + m_2]_+ \tag{2.10}$$

3. 联合损失（Combined Loss）：分类损失和验证损失在分别在模型的不同阶段对模型的参数进行优化，实验证明身份损失函数联合最难三元组损失函数的

组合是行人重识别模型获取优异性能的基线方法。研究者们针对不同的行人重识别问题可能定义出更多种类别的损失函数，然后结合这两种损失函数的重要性无可替代。联合损失函数的定义公式如下：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{id} + \lambda \mathcal{L}_{\text{metric}} \tag{2.11}$$

其中，λ 是平衡两个损失函数权重的超参数，其对于不同的应用场景和训练数据可能有不同的取值。

2.3.2.2 采样策略

在度量学习中，损失函数对同类样本对之间的距离最小化过程的有效性与模型训练过程中每个批次的构建方式密切相关，模型构建训练批次的方法被称为采样策略（Sampling Strategy）。

1. 随机采样（Random Sampling）：随机采样的速度较快，是最常用的一种采样方法。但是，随机采样对大规模数据采样的效率低。尤其是对于深度学习模型的训练来说，得到的训练批次容易忽略行人图像中的潜在信息，并且使得模型训练中产生较低的梯度，从而导致学习速率缓慢，降低模型的训练速率。

2.PK 采样（PK Sampling）：当前主流策略。每个训练批次随机选取 P 个不同的行人，对于每个身份的行人来说，随机选取 K 张不同的图像。因此批次大小为 $P \times K$。这种策略保证了每个训练批次内有多个身份的行人图像的多个样本，便于模型构建大量有效且富含困难样本的三元组样本。

2.3.3 重排序

重排序[110]技术是一种利用行人重识别算法的初次检索结果的邻域信息来优化候选框内行人图像排序顺序的后处理技术。重排序过程可以显著提升行人重识别模型的检索精度和识别性能。

k-倒数近邻重排序（k-Reciprocal Nearest Neighbors Re-ranking）：模型通过训练获得合适的特征映射空间，如果一幅图像是查询图像的真正匹配，那么在这个空间中该行人图像的 k-最近邻集合应该具有很高的相似性（即重叠度很高）。算法主要包括以下几个步骤：

（1）初始排序：对查询图像 q 和候选图像集 G，通过某种距离（如欧氏距离）得到初始排序列表 $\mathcal{N}(q,k)$ 和 $\mathcal{N}(g_i,k)$。

（2）定义 k-倒数集：查询 q 的 k-倒数集，$\mathcal{R}(q,k)$ 是那些将查询图像 q 包含

在其 k 近邻集合中的候选图像集 g。

$$\mathcal{R}(q,k)=\{g_i \mid (g_i \in \mathcal{N}(q,k)) \wedge (q \in \mathcal{N}(g_i,k))\} \tag{2.12}$$

（3）Jaccard 距离：计算查询 q 的 k-倒数集 $\mathcal{R}(q,k_1)$ 与每个候选图像集 g_i 的 k-倒数集 $\mathcal{R}(g_i,k_1)$ 之间的 Jaccard 距离，作为新的相似度度量：

$$d_J(q,g_i)=1-\frac{|\mathcal{R}(q,k_1)\cap\mathcal{R}(g_i,k_1)|}{|\mathcal{R}(q,k_1)\cup\mathcal{R}(g_i,k_1)|} \tag{2.13}$$

（4）融合原始距离：将 Jaccard 距离与原始特征距离融合，得到最终的特征距离：

$$d_{\text{final}}(q,g_i)=(1-\lambda)d_{\text{original}}(q,g_i)+\lambda d_J(q,g_i) \tag{2.14}$$

其中，λ 是融合两种距离的权重超参数，然后根据 d_{final} 重新排序。

重排序技术是一种对不同行人重识别算法的通用技术，是提高算法性能的额外流程，不是本文的主要研究内容，因此本文不引入这个流程，这意味着本文中的所有实验数据都是没有重排序过程的实验结果。

第四节 实验评估及分析

2.4.1 评估指标

行人重识别算法通过模型提取的行人特征进行推理，根据相似度选取与锚点行人图像为同一行人的候选集。对于每一张查询图像，根据模型的识别结果返回指定的查询结果，模型认为与锚点图像越相似排序越靠前。为了方便示意和计算，本文假设数据集的查询集包含 5 张行人图像，候选集包含 10 张图像。

表 2.4 行人重识别模型检索结果示意图

锚点图像	查询结果排序 (1-10)									
查询图像 1	×	×	◯	×	◯	×	×	×	×	◯
查询图像 2	×	×	×	×	×	◯	◯	×	×	×
查询图像 3	◯	×	×	×	×	×	×	×	×	×
查询图像 4	×	×	×	×	◯	×	×	◯	×	×
查询图像 5	×	×	×	×	×	◯	×	×	×	◯

如表格2.4所示，◯ 代表检索正确的行人图像，× 代表检索错误的行人图像结果。本文使用常用的 Rank-k 和 mAP 两个指标评估行人重识别算法的识别性能。

Rank-k: 是代表模型返回的前 k 个结果中含有正确结果的比例，也即是说，rank-k 值越大，模型的精度就越高。如表格2.4显示出的查询结果，rank-1 为 $1/5=0.2$，rank-5 为 $3/5=0.6$,rank-10 为 $5/5=1$。

mAP（mean Average Precision）：是平均精度均值，主要体现了算法的搜索能力，对于查询库中所有的锚点图像，正确查询的图像在查询结果中的比例和排序都影响行人重识别模型的识别性能。如表格2.4显示出的查询结果，mAP 的计算过程如公式2.15所示。

$$AP(q) = \frac{1}{R_q}\sum_{i=1}^{R_q}\frac{i}{k_i} \tag{2.15}$$

$$mAP = \frac{1}{Q}\sum_{q=1}^{Q}AP(q) \tag{2.16}$$

其中，$AP(q)$ 是单个查询图像的平均精度，R_q 是查询图像 q 在候选集中正确匹配的总数，k_i 是第 i 个正确匹配在检索结果中的排序位置，Q 是查询集中所有锚点图像的总数。

2.4.2 传统行人重识别方法的实验结果及分析

为了验证跨外观行人重识别数据集对不同模型的评估能力，本文首先选取经典的手工设计特征和度量学习方法进行行人检索。在实验中使用了图像特征提取中常用的手工特征：LBP[111]、HOG[112]和 LOMO[113]，并配合几种对应的度量学习方法 NCA[114]、ITML[115]和 XQDA[113]分别进行实验。实验结果如表2.5所示：

LBP（Local Binary Patterns）特征可以简单地提取行人图像的局部纹理信息，通过比较中心像素和周围像素的灰度值大小的方式，使得特征对光照等变化具有良好的鲁棒性。然而它对于方向信息较为敏感，因此 LBP 特征对于复杂的背景、姿态变化和外观变化都不具有良好的适应性。其在同外观和跨外观行人子集的表现都较差。

HOG（Histogram of Oriented Gradient）特征通过计算局部的梯度方向直方图构成特征，可以较好地描述物体的形状和轮廓信息，在行人重识别中对行人的体型具有较好的表征能力，也即是说，其特征与行人外观的相关性较低，对外观变化鲁棒，因此其在跨外观行人子集的表现是三种特征中优异的。

表 2.5 基于 NKUP+ 数据集的手工特征对比实验结果

特征与度量	同外观子集		跨外观子集	
	R-1	mAP	R-1	mAP
LBP[111]+NCA[114]	61.7	39.6	2.7	2.0
HOG[112]+NCA[114]	60.4	39.4	5.8	3.9
LOMO[113]+NCA[114]	63.0	41.4	4.7	3.4
LBP[111]+ITML[115]	61.8	40.2	1.6	1.2
HOG[112]+ITML[115]	61.0	39.8	8.0	6.2
LOMO[113]+ITML[115]	64.2	42.0	6.4	4.0
HOG[112]+XQDA[113]	66.8	42.2	2.0	1.8
LBP[111]+XQDA[113]	67.6.	42.8	2.4	1.6
LOMO[113]+XQDA[113]	68.9	43.1	2.3	1.6

LOMO（Local Maximal Occurrence）特征强调局部信息的提取和分析，其能够捕捉行人图像中具有代表性的局部特征，对局部的细节变化有较好的描述能力，也就是说，LOMO 特征关注衣着上显著的细节特征，尤其是特殊纹理，但是其对全局信息的把握不足，忽略了行人的整体特征。因此其在同外观子集上的表现较好，甚至在一些场景的性能和部分基于深度学习的方法相媲美。对应的，其在跨外观子集的表现较差，低于其他两种手工设计特征。

NCA 是监督式的局部度量学习，考虑行人标签与行人图像特征的几何关系。其对于训练数据的规模需求大，在数据量较少和数据分布不均匀的情况下，容易出现过拟合现象。其在 NKUP+ 数据集上的表现较差。

ITML 是监督式的全局度量学习，可以充分利用行人标签的身份信息。在复杂的跨外观行人重识别中，可以学到更准确的距离度量，对于行人的外观变化具有鲁棒性，因此三种特征结合此种度量都取得了比其他两种度量更优的结果。

XQDA 是伴随 LOMO 特征一起提出的度量方法，其考虑了视角差异，尤其是对颜色和纹理相关特征适应能力较好，因此和 LOMO 特征相似，在同外观的行人子集上表现优于跨外观行人子集。

2.4.3 基于 NKUP+ 数据集的基准网络和骨干网选择

本文选择了行人重识别算法中最常用的骨干网进行比较，本文设计的基准网络结构如图所示。在不同的网络结构中，使用不同的骨干网进行替换，通过不同的骨干网络提取行人特征，并用于模型训练和后续的推理过程。

通过实验对比可知，对比不同深度的 Resnet 骨干网和 Densenet 骨干网，随

表 2.6 基于 NKUP+ 数据集的常用骨干网络对比实验结果

骨干网络	同外观子集		跨外观子集	
	R-1	mAP	R-1	mAP
Resnet-18[116]	62.0	40.6	6.0	2.9
Resnet-50[116]	71.4	49.2	10.3	3.9
Resnet-101[116]	79.2	60.7	11.7	5.4
SENet[117]	71.7	55.2	9.8	4.7
NLNet[118]	62.5	39.5	8.4	3.5
IBN[119]	74.0	55.8	10.5	4.8
Densenet-121[120]	81.0	67.0	13.8	7.9
Densenet-161[120]	82.2	68.9	14.9	8.7
Swin-B[121]	77.2	65.1	10.5	6.0

着网络层数的增加，模型的识别性能逐渐提升，这说明 NKUP+ 可以引导主流学习模型的收敛，并且未出现过拟合现象。Densenet 骨干网优于 Resnet 骨干网，主要是因此 Densenet 采用密接链接的结构，使得模型可以获取丰富的多层特征，因此模型会更容易收敛并学习到更多的特征。在考虑到模型的训练和推理速率，M2Net 模型拟采用 Densenet-121 网络作为骨干网提取行人图像的特征。

对于 SENet，NLNet 和 IBN 等基于 Resnet 改进的骨干网来说，其性能与 ReNet 基本相近。然而添加注意力机制的 SENet 骨干网并没有充分利用行人图像中的全局上下文信息。而 NLNet 骨干网的性能十分依赖数据集质量，对于跨外观行人检索任务这种复杂的应用场景，表现不如预期。IBN 骨干网更适合处理视觉相关的特征，如颜色和风格等，因此其在同外观子集表现较为优异，而在包含外观变化的跨外观子集上表现平平。

对于 Swin-B 这种基于 Transformer 结构的模型来说，通过层级式结构可以获取行人图像的多尺度特征，在同外观的行人子集上表现较好，然而其对于资源即内存和功耗的需求较大，与 Densenet 相比没有显著的优势。

通过对比手工设计特征和基于深度卷积网络的特征提取算法，我们可以观察到，基于深度卷积网络的算法具有显著的优势。手工设计特征在同外观和跨外观子集中的精度远远低于深度学习提取的行人特征，不同算法在 NKUP+ 数据集上的识别精度差异说明了 NKUP+ 数据集对不同算法具有判别性，可选择出更具有鲁棒性的算法。同样地，我们可以观察到，目前的方法在跨外观行人子集上的精度较低，这说明了 NKUP+ 数据集对于现有行人重识别模型具有相当的挑战，如何获取鲁棒的行人特征和如何度量特征距离都是亟待探索的方向。

第五节 本章小结

本章构建的 NKUP+ 有效填补了大规模跨外观数据的空白，以支持深度学习模型的训练。数据集采集自真实监控数据，弥合了模型训练和推理场景与真实监控网络的差异，避免了模型应用落地迁移时的域适应问题。数据集具有北京多样性、视角多样性、姿态多样性等特点，这提升了数据集的质量，行人重识别数据集适应无关因素对模型特征的影响，避免模型的过拟合问题，提高模型的泛化性。NKUP+ 数据集突破了传统行人重识别算法的假设，测试集中锚点图像和候选集的行人图像具有外观上的差异，因此引导模型减少对行人外观的依赖，挖掘行人重识别算法在刑侦追查中的应用潜力。最后，本文在 NKUP+ 数据集上训练了使用经典的手工设计特征和基于深度学习网络的算法，证明了数据集对行人重识别算法的判别性和挑战性, 验证了其在模型训练中的价值。

然而，实验数据同样揭示了一个严峻的问题：在仅有 RGB 图像的情况下，现有模型面对外观剧烈变化时性能急剧下降。这表明，单纯依赖数据规模扩充不足以完全解决问题，必须从特征层面进行革新。因此，下一章将重点研究如何引入多模态信息，以弱化外观特征在检索中的主导地位。

第三章　基于多模态行人图像的跨外观行人重识别算法

随着行人重识别算法的发展，对常用的行人重识别数据集的检索性能逐渐提升进而遇到瓶颈。行人的外观变化在模型检索过程中的改变作为一种突破了行人重识别最初建模假设的关键问题，这种变化使得依赖衣着等外观相关的特征信息成为了模型检索的错误信息。为了突破这个关键问题，本章致力于在特征表达层面缓解外观变化对行人重识别模型的干扰。第二章构建的 NKUP+ 数据集已充分揭示，长时间跨度下行人衣饰、携带物等外观属性可发生剧烈改变，导致依赖 RGB 图像的外观线索的深度模型性能骤降。尽管现有方法尝试通过多模态融合等方式引入额外线索，但其往往依赖于特定的辅助网络或繁复的特征对齐，部署灵活性受限。我们追问一个更为根本的问题：能否在不引入过多外部模态的前提下，仅通过改进特征学习范式本身，使模型自主地降低对外观敏感特征的依赖，并增强对身份不变特征的提取能力？

为此，本章提出一种通用的跨外观行人重识别算法。核心思路是设计全新的样本采样策略与损失函数，促使模型在训练过程中主动关注外观无关的身份判别性特征。具体地，我们观察到标准随机采样算法不关注外观变化，从而导致算法对外观的过拟合现象。因此设计了一种基于外观标签的样本采样策略，迫使模型在高外观差异、低身份差异的困难样本对上进行深度挖掘。同时，本章引入一种多外观损失函数，显式地约束模型在不同外观状态下对同一身份的特征分布一致性，从而在特征空间中拉近跨外观正样本对，推远负样本对。该方法结构简洁、即插即用，可与后续章节的数据增强及训练策略方法无缝衔接，为从表示层面降低外观依赖提供了一种高效基准方案。通过本章研究，我们期望验证：即使在不扩充数据的前提下，通过针对性的采样与损失设计，模型的身份不变特征表达能力亦可获得显著提升，从而为第四章从数据层面进一步突破外观瓶颈奠定基础。

第一节　引言

2018 年，Xue 等人提出了一种淡化服装变化而强调面部信息的行人重识别算法，这是直接对外观变化这一挑战的首次尝试，也开启了研究者们对更换衣

着引起外观变化的行人重识别的探索。但是突破行人重识别外观一致性的假设造成了当前绝大多数数据集的失效，因此跨外观行人数据集的出现伴随对应的方法开始不断出现。随后，Yang 等人提出了一种主要依靠行人的轮廓草图而提取鲁棒特征的方法试图提升跨外观行人检索的能力，然而这只对短期内无剧烈的轮廓变化的行人检索具有促进作用，而对于长时间段下的跨外观行人检索性能较差。同样的，轮廓线索作为对外观变化鲁棒的一种重要特征，研究者们通过不同特征提取方法[122]引导模型检索。此外，使用人脸特征、目标衣着模板、发型或随身物品细节特征是引导行人检索的另外一类特征。除此之外，使用射频信号技术获取精确体型信息或连续行人图像以获取步态特征等方法也是排除外观特征的重要手段。但是现有方法大多伴随数据集提出的，不适用于长时间段内的跨外观行人重识别的场景：

1. 跨外观行人重识别是注重算法实用性的研究，对真实场景的准确建模是十分必要的。诸如使用射频信号或衣服模板这样的线索很难获取，这是对跨外观行人重识别检索的重要提示信息之一，但难以在检索任务中获取这样的结果。除此之外，利用街拍图像和影视剧中的图像也是很难在真实场景中具有通用性。

2. 一些方法尝试使用了人脸相关的行人特征。行人重识别一般作为一种人脸识别失效的一种补充，其主要原因是大部分监控设备只能捕获低分辨率的行人图像，这导致行人图像中的人脸区域模糊而丢失细节特征，依靠人脸相关的特征无疑是不可靠的。现在常用的行人重识别数据集尤其是跨外观行人数据集中不具有人脸信息，这挑战了行人图像的隐私保护原则。

为了解决上述问题，本文分析了跨外观行人重识别中的难点和关键性线索。通过志愿者对一些跨外观行人图像进行匹配，对于正确匹配的结果进行原因分析。因此本文通过人的直觉感知为依据，通过行人图像的轮廓草图和人体语义分割结果作为对于外观变化鲁棒的源图像为模型提供鲁棒的特征，并结合行人图像的 RGB 原图获取细节信息和域适应能力。行人的轮廓草图是行人主体的边缘，主要包含着人体的体型信息。行人图像的人体语义分割结果是使用分割模型对行人的局部信息的反应，包含着行人的头部，四肢和主要躯干的大小和位置，可以获取行人的比例和姿态信息。这些信息源在真实的场景中也是极易获取的，其鲁棒性对行人检索的性能具有巨大的提升。而在行人重识别算法的约束中，使用与外观标签相关的损失也引导模型忽略外观的引导，从而使模型对外观变化具有较好的抗干扰能力。本章的主要研究工作总结如下：

- 通过行人轮廓草图和人体语义分割结果图降低模型对于外观变化的敏感，结合原始的 RGB 图像，为模型提供多模态的特征线索，使模型忽略外观信息的误导，而专注对外观变化鲁棒的特征信息。
- 通过模型的批次训练方式，在建立模型的训练批次时，本文在选取行人的身份标签之外，针对模型的外观标签，对不同外观标签的行人图像进行采样，建立具有外观多样性的模型批次。
- 通过外观标签和多外观的训练批次，本文设计了对应的外观损失（APP loss）和多外观损失（MA loss），邀约数同身份不同外观的特征距离小于不同身份相似外观的特征距离，最终使模型在同外观和跨外观的场景中提取关键的特征。
- 本文将提出的 M2Net 网络在前述的 NKUP+ 数据集和其他常用的跨外观行人重识别数据集上进行多次实验。并根据模型与其他方法的实验结果和对比分析证明模型的性能优势和通用性优势。

第二节 预备知识

3.2.1 行人轮廓草图

行人轮廓草图主要是行人主体外部轮廓的简单勾勒描述，这属于图像处理中的边缘检测任务。传统的边缘检测算法主要是利用基于梯度算子、带方向的算子和基于多次求导的方法，通过不同尺寸的模板进行固定方向和多方向的卷积和求导来获取明显的边缘，但这些算法对噪声较为敏感，或忽略细致的边缘信息，这对于行人图像这种具有复杂背景的图像并不适用。在深度学习引入图像处理中后，利用深度学习模型可以自动学习多尺度特征的特性，将不同尺寸的特征图融合，并结合行人图像的上下文信息，提高了边缘检测的精度和完整性，并忽略噪声的影响。

因此本文选取了基于深度学习的边缘检测模型 RCF 算法获取行人的轮廓草图。如图3.1第一行所示是行人图像对应的轮廓草图。需要注意的是，边缘检测模型的参数固定，这意味着在行人重识别模型的训练和推理过程中，数据集中所有行人图像对应的轮廓草图是保持一致的。

行人的轮廓草图是跨外观行人重识别重要的线索之一。它去除了行人图像中包括的大部分纹理、颜色等细节信息，重点关注行人的形状特征，比如身体的外部形状、四肢的姿态等。行人的轮廓草图在行人重识别任务中受到光照变

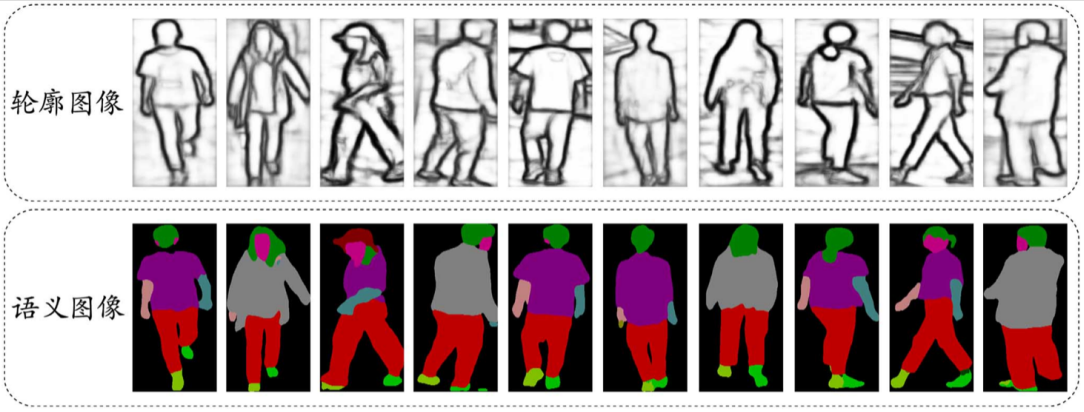


图 3.1 行人图像的轮廓草图和语义分割结果示例

化的影响较小，因此其在不同光照情况下均具有稳定可靠的特征指导模型的训练。针对这个特点，一些可见光红外行人重识别工作中具有广泛的应用。同时，轮廓草图作为一种简单高效的特征表示，这意味着相较于复杂的纹理特征等信息来说，轮廓草图的信息量更小，在计算和存储过程都更加高效。

因此，在步态识别的研究中，使用连续的轮廓草图可以更加高效地提供行人的动作信息，忽略纹理等无关细节对步态特征的影响。不仅如此，在超大大规模的行人识别中，系统可以更快地进行特征提取和匹配以缩小范围，从而大大提高模型检索的效率。

然而行人的轮廓草图可以提供行人体型的特性信息，但对于长时间段内的行人图像的轮廓变化仍然可能导致轮廓草图的巨大差异。除此之外，对于一些特殊的服装可能导致行人的轮廓草图和体型的差异较大。这导致了轮廓草图可能损失行人体型相关的细节信息，单一的模态特征限制模型获取行人鲁棒特征的潜力。因此，本文依据人的直觉感知，利用与体型信息强相关的边缘信息获取行人的轮廓草图提供鲁棒的线索，但单一模态的特征忽略行人的细节特征，需要与其他模态的行人图像互相佐证，丰富行人的细节特征信息，提高模型的检索性能。

3.2.2 人体语义分割

人体的语义分割结果主要是行人的各个局部的准确分割图，这是计算机视觉中的语义分割任务。早期的语义分割方法使用边缘检测结果进行分割，但这些方法极易受到噪声的影响。随后，一些从初始像素逐渐生长或聚类来吸纳相似特征的像素进而获取同一个目标的分割结果的方法不断出现，但是其在复杂

图像的分割效果比较有限。类似地是，随着深度学习的兴起，语义分割的精度和效果都有了大幅度的提升，通过空洞卷积、金字塔池化模块等方法，捕捉图像的多尺度信息，减少信息的损失，提高了分割结果的准确性。而人体语义分割是针对行人目标的子任务，通过对行人区域的像素进行分类从而获取行人的头部，发型，上半身，上肢，下肢，脚部，配饰及其他物品[123-125]。

本文选取了语义分割算法 PSPNet 算法获取行人的语义分割结果。如图3.1第二行所示是行人对应的语义分割结果。同样的，语义分割算法的参数在行人重识别算法的训练和推理过程也被冻结固定，所有行人图像的语义分割结果是不变的。

行人的人体分割结果包含了行人的细节特征线索。经过语义分割获取到行人对应的特征区域，就可以对精确的区域进行进一步的特征提取，例如使用尺度不变特征和其他行人图像的分割结果进行匹配。此外，行人的人体分割结果可以与其他模态的信息结合，在行人的运动过程中根据各个部位的位置和形状信息，可以分析身体各部分的运动轨迹和速度等运动特征，可以辅助行人重识别模型判断是否为锚点目标。

行人的语义分割精度会影响行人运动特征的提取，尤其是在复杂提天气或低光照条件下，语义分割的结果并不理想。因此，依据人的直觉感知，利用行人的身体细节信息可以获取鲁棒的人体局部的运动特征线索，但单一模态的特征容易出现精度问题误导行人检索，需要与其他模态的行人图像互相佐证，丰富行人的细节特征信息，提高模型的检索性能。

第三节　算法设计与实现

跨外观行人重识别是考虑模型在检索过程中，目标行人的图像包含外观变化的一种特殊情况。传统的行人重识别任务是定位目标行人短时间内在跨摄像头下的轨迹，行人的外观并不发生变化，行人外观作为一种显著的特征[126-127]，最易引起算法的注意，因此行人外观相关的颜色纹理等特征是模型检索目标时以来的主要特征。但是在跨外观的行人重识别中，包含最重要线索的外观成为了模型判别目标的误导信息。

为了解决上述问题，本文探索了对外观变化鲁棒的线索。在前两节中本文介绍了除了原始的 RGB 模态的行人图像外，轮廓草图和人体语义分割可以引导模型提取对外观变化鲁棒的行人特征。因此，在传统的 RGB 行人图像的基础上，

本文融合了行人轮廓草图和行人语义分割结果共三种模态的线索。如图3.2所示是本文提出的基于多模态（Multi-modality）的跨外观行人重识别模型 M2Net 的网络结构图。

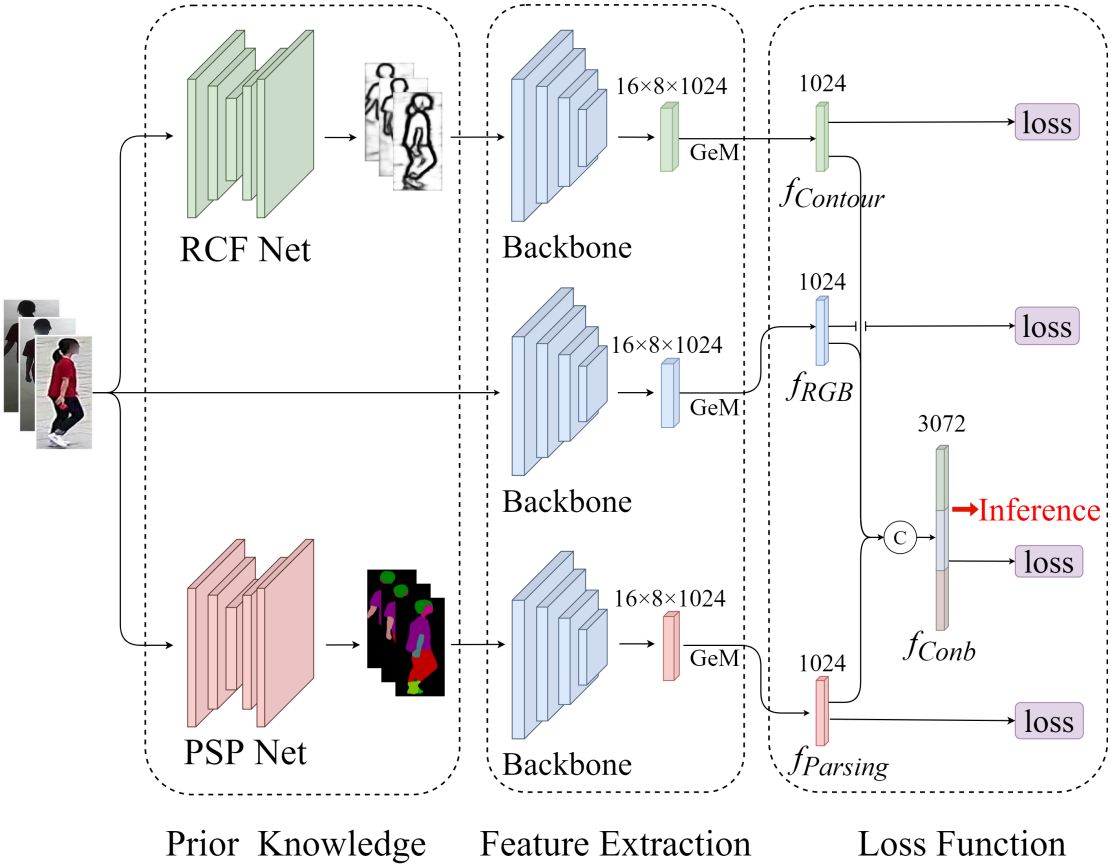


图 3.2 M2Net 模型的网络结构图

首先，本文将原始的 RGB 图像通过边缘检测网络 RCF Net 和行人语义分割网络 PSP Net 获取行人的轮廓草图和人体语义分割结果。然后由三个骨干网络提取三种模态的行人图像的行人特征。也就是说，M2Net 首先将行人图像 $X_{RGB} \in \mathbb{R}^{H_1 \times W_1 \times C_1}$ 输入到 F_{RCF} 和 F_{PSP} 中，从而获取每张行人图像对应的 $X_{Contour} \in \mathbb{R}^{H_1 \times W_1 \times C_1}$ 和 $X_{Parsing} \in \mathbb{R}^{H_1 \times W_1 \times C_1}$。三种模态的行人图像的尺寸保持一致。在模型的训练过程中，RCF Net 和 PSP Net 中的参数被冻结，不参与更新。值得注意的是，RCF Net 的预训练基于数据集 BSDS500 完成，而 PSP Net 的寻训练基于数据集 LIP 完成。

为了获取鲁棒的行人特征，模型的骨干网络本文选择了行人重识别算法中常用的 ResNet、DenseNetNet、SENet 等经典深度网络模型进行统一的训练和测

试，在精度和计算效率两个维度对不同的骨干网络进行评估并选定最适配的骨干网。利用不共享的三个骨干网络和池化层，模型可以获得三种模态的行人特征图。融合三种模态的行人特征，模型就可以获取包含对外观变化鲁棒的行人特征。三个模态的行人图像在通道层级和像素级均具有较大的差异，也即是说，算法对三个模态的行人图像期待的特征信息的关注点并不相同，因此三个特征提取网络必须保持其差异化。

M2Net 网络获取行人特征的过程如公式所示：

$$\begin{aligned} X_{Contour} &= F_{RCF}(X_{RGB}, \Theta_{RCF}) \\ X_{Parsing} &= F_{PSP}(X_{RGB}, \Theta_{PSP}) \end{aligned} \tag{3.1}$$

$$\begin{aligned} f_{RGB} &= GeM(F_{RGB}(X_{RGB}, \Theta_{RGB})) \\ f_{Contour} &= GeM(F_{Contour}(X_{Contour}, \Theta_{Contour})) \\ f_{Parsing} &= GeM(F_{Parsing}(X_{Parsing}, \Theta_{Parsing})) \end{aligned} \tag{3.2}$$

$$f_{Conbine} = f_{RGB} f_{Contour}, f_{Parsing} \tag{3.3}$$

其中，Θ 代表对应网络的参数，F_{RGB}、F_{RGB} 和 F_{RGB} 是三个并行的特征提取网络，GeM 代表网络的池化层即广义平均池化（Generalized Mean Pooling）。特征提取骨干网获取三种模态的行人特征以后，为了综合三种模态的优势，本文使用三种特征拼接后的融合特征引导模型的训练和行人检索。

第四节 M2Net 网络的损失函数设计

3.4.1 行人重识别的常用损失函数

对比损失（Contrastive Loss）。它通常用于训练对比学习（Contrastive Learning）模型，对比模型主要是为了学习数据中的相似性和差异性，将同属于一个行人的样本映射到相近的位置，而将不属于同一行人的样本映射到较远的位置。对比损失的定义如公式3.4所示：

$$\mathcal{L}(Contrastive) = \sum_{y_{ij}=1} D_{ij} + \sum_{y_{ij}=0} [m - D_{ij}]_+ \tag{3.4}$$

$$D_{ij}X_i, X_j = (\sum_{n=1}^{P}(X_i^n, X_j^n)^2)^{1/2} \tag{3.5}$$

其中，D 代表两个样本特征的欧氏距离，如公式3.5所示为欧氏距离的定义。而 $[x]_+ = \max(0,x)$，P 代表样本特征的维度，y 是两个样本是否匹配的标签（值为 1 时匹配，值为 0 时不匹配）。而 m 是人为设定的阈值，当不匹配的样本对特征距离大于这个阈值，本文就认为损失函数的值为 0，这意味着这个特征距离符合我们的期望，不对网络进行更新，反之则保留。对比损失的阈值是固定的，这导致在行人重识别中不同行人的特征距离是不同的，设定较大的阈值会导致不匹配的样本对识别成匹配的样本对，而设定较小的阈值又会使匹配的样本对识别为不匹配的样本对，造成模型的过拟合。

三元组损失（Triplet Loss）。它的主要思想为让目标行人与负样本之间的特征距离大于其与正样本之间的特征距离。三元组损失的优势在于更细节的区分，即区分非同类的相似样本。三元组损失的定义如公式3.6所示：

$$\mathcal{L}(Triplet) = \sum_{(i,j,k),y_{ij}=1,y_{ik}=0}[D_{ij} - D_{ik} + m]_+ \tag{3.6}$$

其中，i 代表锚点样本，j 代表与锚点图像为同一行人的正样本，k 代表不同行人的负样本，m 是设定的阈值。在行人重识别中，三元组损失的效果优于对比损失，因为它将相互匹配的样本对的特征距离拉近，使其小于不匹配的行人样本对。

最难三元组损失（TriHard Loss）。最难三元组损失顾名思义是三元组损失的改进版，它不同于随机挑选正样本和负样本的过程，而是在同一个批次中选出最相似的负样本和最不相似的正样本，这也就是行人重识别在检索中最难分辨的样本，通过这种筛选过程，提高行人重识别算法对于极端样本的分辨能力，进而提高模型检索目标行人的性能。

交叉熵损失（Cross-Entropy Loss）。交叉熵损失是深度学习的分类任务中最常用的损失函数，不同于以上使用特征距离来度量样本之间的相似性，交叉熵损失是比较模型预测的概率分布与真实概率分布之间的差异来评估模型的性能。也即是说，算法的交叉熵损失越小，代表着模型预测的分类结果越准确。交叉熵损失通常与 Softmax 函数结合使用，行人重识别模型中 Softmax 函数将模型输出的特征转换为各个行人类别的概率分布，通过交叉熵损失来评估预测分布与样

本类别的真实分布的差异进而引导模型的优化。交叉熵损失的定义如公式3.7所示：

$$\mathcal{L}(CE) = -\sum_{i} p(x_i) \log q(x_i) \tag{3.7}$$

其中，$p(x_i)$ 是样本的真实标签，$q(x_i)$ 是算法预测的样本标签的概率分布。使用交叉熵损失可以直接使用行人的身份标签对行人重识别算法进行监督，对于一些异常的行人图像样本具有较好的鲁棒性。大多数行人重识别方法会使用联合交叉熵损失和度量损失如最难三元组损失，可以有效地提升模型的判别能力。

3.4.2 基于外观标签的损失函数

基于深度学习的行人重识别算法在训练时，受限于设备的计算量，通常不会一次性使用所有的数据进行训练，而是将所有的样本数据随机采样，按照人为设定的大小分为较小的批次来完成训练，这样做不仅可以有效地管理设备的内存资源，通过并行计算提高模型的训练效率，并且可以一定程度上提高模型的泛化能力。行人重识别算法的批次一般是指定每个批次中包含 P 个行人且每个行人包含 K 张图像，行人重识别算法中使用的最难三元组损失定义如公式3.8所示。

$$L(TriHard) = \sum_{p=1}^{P} \sum_{k=1}^{K} [\max_{k' \neq k} D(f_\theta(x_p^k), f_\theta(x_p^{k'})) - \min_{p' \neq p} D(f_\theta(x_p^k), f_\theta(x_{p'}^{k'})) + m]_+ \tag{3.8}$$

其中，$f_\theta(x_p^k)$ 是随机选择的一个行人图像的特征，max 函数是从同一个批次中选择与该行人图像最不相似的正样本，类似地，min 函数是从同一个批次中选择与该行人图像最相似的负样本，挖掘模型最难分辨的样本，就可以提高算法在模糊边界的分类能力。

然而在跨外观行人重识别中，外观因素成为了一个重要干扰项。因而，为了模型适应外观变化的普遍存在，提升模型分辨外观变化的行人图像的能力，在每一个训练批次中，提升单个行人的外观多样性才能够促进模型学习鲁棒的行人特征。因此本文提出了一种基于外观标签的随机外观采样算法（Random Appearance Sampling, RAS），具体来说，除了指定每个批次中包含 P 个行人，模型指定每个行人包括 A 种外观，每种外观包括 K 张行人图像。如图3.3所示是 RAS 采样算法和传统的随机采样算法形成的训练批次行人图像属性的示意图。

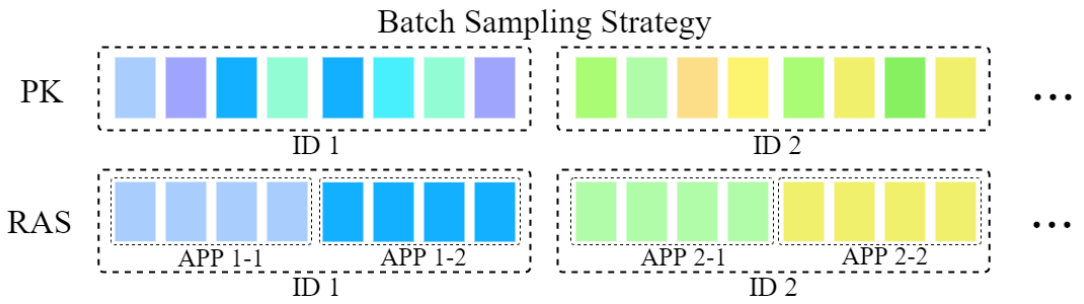


图 3.3 不同摄像头下行人图像数量的分布

行人重识别算法中，外观特征是一种显著的特征，在最终识别的特征中的权重过大，因此相似外观行人图像与锚点图像的特征距离一般小于外观显著变化的行人图像与锚点图像的特征距离。对于包含外观变化的行人图像批次，本文在每一个训练批次中，假设锚点图像是第 p 个行人、第 a 种外观的第 k 张图像，本文使用跨外观损失（Cross-Appearance Loss, CA loss）引导模型的训练。具体来说，本文对批次中的每个行人 p，遍历其 A 种外观，使用同外观中最难分辨的行人图像特征距离为标准，限制跨外观行人图像与锚点图像的特征距离，从而使算法提取的行人特征与外观的关联性降低，即对外观变化鲁棒的行人特征。本文延续使用欧式距离 D 作为特征度量的方式，计算数据集的跨外观损失的公式如3.9所示：

$$\mathcal{L}_{CA} = \overbrace{\sum_{p=1}^{P}\sum_{a=1}^{A}\sum_{k=1}^{K}}^{\text{全部行人图像}} \overbrace{\sum_{b=1,b\neq a}^{A}}^{\text{所有外观图像}} [\beta + \overbrace{\max_{k'=1,\dots,K} D(f_\Theta(x_a^k), f_\Theta(x_b^{k'}))}^{\text{跨外观最难分正样本}} - \overbrace{\max_{k'=1,\dots,K k'\neq k} D(f_\Theta(x_a^k), f_\Theta(x_a^{k'}))}^{\text{同外观最难分正样本}}]_+ \tag{3.9}$$

通过跨外观损失函数的约束，模型提取的行人特征可以有效地应对行人的外观变化。其主要原因是，同外观下行人的特征距离在行人检索的精度已经得到了有效验证，跨外观下行人图像与锚点图像的特征距离更近，可以使模型识别出最难分的跨外观行人图像，提高其提取鲁棒特征的能力。

行人重识别会综合使用分类损失和度量损失，因此本文也在常用算法的基础上利用外观标签获取分类损失。外观标签是对于相同衣着、配饰等外观信息的分类标注，与行人图像的身份标签对应，本文通过其预测的外观种类的概

率分布与真实分布对应，计算外观分类的交叉熵损失，本文称之为外观损失（Appearance Loss, AP loss），其公式如3.10所示：

$$\mathcal{L}_{AP} = -\sum_{i} p(x_i)\log(q(z_i|x_i)) \tag{3.10}$$

其中，$p(x_i)$ 是样本的真实外观标签，$q(z_i|x_i)$ 是算法预测的外观标签的概率分布。

最终，通过使用特征度量的最难三元组损失和跨外观损失，联合使用身份标签和外观标签的分类交叉熵损失共同训练 M2Net 模型。最终，本文使用的总体损失函数定义如3.11所示：

$$\mathcal{L}_{Total} = \mathcal{L}_{ID} + \mathcal{L}_{TriHard} + \lambda_1\mathcal{L}_{CA} + \lambda_2\mathcal{L}_{AP} \tag{3.11}$$

其中，$\mathcal{L}_{ID}$ 是基于身份标签的交叉熵函数，其定义与 $\mathcal{L}_{CE}$ 相同。λ_1 和 λ_2 是模型使用的超参数，是为了平衡两种损失函数的权重已达到模型在多种测试下的最优水平，超参数设置的相关实验会在下一节中具体描述。

第五节 实验评估及分析

本节将介绍算法相关的实验细节，包括实验设置、数据集选择、评测协议、消融实验及对比实验结果分析等。

3.5.1 实验设置和训练细节

本文的实验设备均为配置 2 块 NVIDIA GeForce RTX 3090 GPU 和 128GB 内存的工作站上进行，下文不再赘述。本章中使用的数据集选取了最广泛使用的行人重识别数据集，具体为和常用的跨外观行人重识别数据集, 即 NKUP+、PRCC 和 DeepChange。以上数据集的详细信息和属性可参考本文的第二章内容。

对于跨外观行人数据集来说，PRCC 可以通过摄像头标签获取简单的外观标签，通过选取不同的摄像头下的行人图像，可以完成同外观和跨外观行人检索的测试。对于 NKUP+ 数据集来说，本文根据数据集的划分情况直接获取同外观和跨外观的行人检索的子集，对于 DeepChange 数据集来说，所有的候选集行人图像不具有外观标签，因此跨外观行人重识别算法使用全部的候选集行人图像进行测试。

网络输入的行人图像经过统一的预处理：图像大小缩放至 [256128]，使用均值 [0.4850.4560.406] 和标准差 [0.2290.2240.225] 对行人图像进行归一化。通过水平翻转、随机裁剪、采集擦除等策略对行人图像进行随机处理以消除模型的过拟合。模型的学习率从 3.5×10^{-6} 初始化，经过上升再逐渐下降使模型逐步收敛。

3.5.2 超参数预实验

在本章中，本文提出了基于行人特征的跨外观损失和基于外观标签的外观损失，二者分别以整体的鲁棒特征和局部的细节线索引导模型的训练。在3.5.3中，本文进行了消融实验详细讨论了两个损失函数对于网络模型的影响，为了平衡两个损失函数的约束效果，使用不同的参数组合进行了超参数预实验。针对定义的引导模型优化的损失函数 $\mathcal{L}_{Total}$，其中的参数 λ_1 和 λ_2 是平衡跨外观损失和同外观损失的超参数，其实验结果如表3.1所示:

从实验结果，我们可以更加清晰地看到跨外观损失和外观损失的作用。其中 λ_1 的值越大，则跨外观损失的权重越大。同样的，λ_2 的值越大，则外观损失的权重越大。两种损失分别对两个检索场景有较为明显的促进作用。显而易见的是，跨外观行人检索是本文主要的应用场景，且跨外观行人检索的难度是远大于同外观行人检索的，因为外观特征最为显著的，这意味着模型不能完全忽略外观特征，因此我们容易推断出 λ_1 的值应该明显大于 λ_2。实验结果证明了 λ_1 的值更大时，模型总体的检索性能更加优越，对比所有结果，本文最终设置 $\lambda_1 = 1.0$ 和 $\lambda_2 = 0.2$。

3.5.3 消融实验

表示学习追求特征空间的解耦，即不同维度控制不同语义因素。RGB 图像提供全面外观但噪声多；轮廓图提供体态、姿势的结构信息；语义分割图提供部件级语义（头、上身、下身）。融合这三种模态本质上是构建一个**协同互补的表示空间**：

- **共享表示**：三种模态共同指向的身份核心特征，如整体体态。
- **特定表示**：各模态独有的补充特征，如 RGB 的发色、轮廓的精确肩宽、语义部件间的空间关系。

通过设计恰当的融合策略，模型能动态权衡不同模态的重要性，迫使特征提取网络关注跨模态一致且判别性强的信息，从而实现解耦。

表 3.1 基于 NKUP+ 数据集下参数 λ_1 和 λ_2 的平衡实验

λ		同外观子集		跨外观子集	
λ_1	λ_2	R-1	R-10	R-1	R-10
0.1	0.1	84.8	70.1	23.5	10.6
	0.2	86.6	72.1	23.4	10.9
	0.5	86.5	73.2	23.2	10.7
	0.8	86.6	73.3	22.8	11.0
	1.0	86.6	72.5	22.8	10.8
0.2	0.1	83.7	69.7	23.9	10.6
	0.2	85.5	71.3	23.9	10.9
	0.5	85.8	71.8	23.7	10.9
	0.8	86.8	73.1	22.4	10.5
	1.0	85.7	73.0	22.7	10.7
0.5	0.1	85.1	70.6	**24.0**	11.0
	0.2	85.7	71.8	23.8	10.9
	0.5	85.7	71.7	22.5	10.6
	0.8	87.1	73.0	23.0	10.9
	1.0	86.0	72.8	22.6	10.7
0.8	0.1	84.2	69.6	22.6	10.6
	0.2	85.9	71.9	23.4	10.7
	0.5	86.1	72.9	23.7	**11.0**
	0.8	86.7	72.9	22.9	10.6
	1.0	86.6	72.8	23.2	10.9
1.0	0.1	85.1	70.1	**24.0**	**11.0**
	0.2	86.2	**76.3**	**24.0**	**11.0**
	0.5	85.8	72.5	22.0	10.7
	0.8	85.8	72.7	23.2	10.6
	1.0	**87.5**	73.4	21.7	10.5

在本小节中，本文在 NKUP+ 和 PRCC 两个数据集上组织消融实验，验证本文提出的方法中的关键创新点的效果。多模态输入、随机外观采样策略。跨外观损失和外观损失。总计来看，对比没有引入任何模块的基准模型（方法 1），本文提出的 M2Net（方法 10）在两个行人数据集上都取得了显著的性能提升。这说明了本文提出的 M2Net 在同外观行人检索和跨外观行人检索中具有鲁棒性，融合多模态的输入信息为模型提供了额外的辅助信息。

多模态输入的效果：对比方法 1（2/3/4/5）和对比方法 6（7/8/9/10），在其他策略相同的情况下，我们可以观察到每一组实验的对比，融合多输入的行人图像在两种识别场景中都提升了模型的检索性能。在同外观行人重识别检索中，RGB 图像提供了可靠的外观特征，而轮廓草图和人体解析图像提供了行人的细节特征；在跨外观行人重识别检索中，RGB 图像和轮廓草图、人体语义分割图像的对比，模型可以重点关注不受外观变化的轮廓草图和人体语义分割图像。多模态的输入为模型检索提供了额外的辅助信息，模型自适应地调整使模型提取具有判别性的特征。

随机外观采样策略的效果：对比方法 1 和方法 2 以及方法 6 和方法 7，随机外观采样策略也显著提高了模型的检索性能。随机外观采样提升了外观多样性，结合最难三元组损失的优化，模型可以挖掘到更难的样本对，使得模型对困难样本的分辨能力提高。尤其是在跨外观行人重识别检索中，模型可以提取到包含外观变化的困难样本的鲁棒特征，大大提高了特征的判别力。

跨外观损失的效果：跨外观损失需要计算一个批次中包含外观变化的困难样本，因此跨外观损失的计算需要随机外观采样策略的配合。从实验结果可以看出，其对两个行人数据集中的跨外观行人检索具有更加显著的提升作用，证明了其对于跨外观行人鲁棒特征的关注大于相似的外观特征。当模型引入随机外观采样策略和跨外观损失函数时，模型的在同外观行人检索上的提升并不明显，尤其是在 NKUP+ 数据集上，因为跨外观损失的约束，模型更倾向于选择不同外观的行人图像，在同外观行人检索时，这成为了一种错误引导。

外观损失的效果：同外观损失是约束模型识别相同外观的一种能力。对比方法 3 和方法 4 以及方法 8 和方法 9，我们可以观察到外观损失的直接效果。模型在两个数据集的同外观子集上的提升十分显著，这主要是外观标签促进模型更关注与外观标签相关的特征，即行人衣着颜色和问题等。同时，这也造成了模型关注外观变化，这和本文的跨外观行人检索的目标是背道而驰的。然而，对比

表 3.2 多模态输入（MM），随机外观采样策略（RAS），跨外观损失（CA），外观损失（AP）的消融实验

方法	MM	RAS	CA	AP	NKUP+				PRCC			
					同外观		跨外观		同外观		跨外观	
					Rank-1	mAP	Rank-1	mAP	Rank-1	mAP	Rank-1	mAP
1	×	×	×	×	75.8	60.3	15.7	7.9	98.4	95.7	28.6	31.1
2	×	✓	×	×	82.1	67.7	20.6	9.0	99.9	99.5	50.1	50.0
3	×	✓	✓	×	76.6	59.2	23.7	9.1	99.8	99.0	58.4	55.7
4	×	×	×	✓	78.3	64.9	15.5	8.4	99.5	98.4	28.4	32.6
5	×	✓	✓	✓	83.3	68.9	22.5	10.1	99.8	99.5	56.8	55.0
6	✓	×	×	×	76.6	59.7	17.6	8.8	99.1	97.6	36.2	37.2
7	✓	✓	×	×	84.5	69.7	22.4	10.2	99.7	99.2	56.8	53.8
8	✓	✓	✓	×	79.9	61.1	25.9	9.8	99.8	99.1	61.7	57.1
9	✓	×	×	✓	81.9	68.9	15.1	8.1	98.6	98.1	32.0	35.2
10	✓	✓	✓	✓	86.4	72.5	24.7	11.4	99.5	99.0	59.5	57.8

方法 3 和方法 5 以及方法 8 和方法 10，我们同样可以观察到在其他损失函数的基础上，添加外观损失同样具有明确的正向反馈。当然，其在同外观行人重识别检索中的作用我们可以预料，其在跨外观行人检索中的微弱促进作用，主要是因为外观标签变化时，行人的一些关键配饰如书包等细节特征可能成为模型的重点关注区域，使模型关注整体的形状信息之外，包含可靠的局部特征，对于行人重识别模型的积极作用也不可忽视。

总体而言，多模态输入图像提供给模型更多的可用信息，随机外观采样策略增加了同一个批次中困难样本的难度，使得模型在最难三元组损失和跨外观损失的引导下，对困难样本的分辨能力逐渐提升，并因此促进行人检索的性能。跨外观损失和外观损失的结合，可以使模型在两种检索场景中都取得最好的结果，大大提高了模型的综合检索能力。

为了探索多模态输入图像中每一种模态输入对于模型检索的影响，本文对 RGB 原图像、轮廓草图和人体语义分割图像的单一输入和组合输入分别进行实验。也即是说，本文分别使用三种模态的单一模态输入，任意组合两种模态的输入以及三种模态的输入，模型根据不同输入提取特征，并进行后续的池化、融合和行人匹配。其实验结果如表3.3所示。

移除 RGB 模态后，模型在标准场景下性能下降最为显著（mAP 降低 35.7%），但在跨外观场景下仅下降 5.1%，表明 RGB 携带了大量与身份相关但外观敏感的判别信息；移除轮廓模态在换衣场景下造成性能骤降（Rank-1 降低 1.8%），说明轮廓编码了体型、姿态等外观无关的结构性身份线索；语义分割模态的移除则在背景干扰强烈的场景下影响最大，表明其提供了前景聚焦的注意力引导，间

表 3.3 多模态输入的消融实验

Feature	同外观		跨外观	
	R-1	mAP	R-1	mAP
单输入 M2Net				
f_{RGB}	83.1	69.0	22.4	10.0
$f_{Contour}$	60.1	36.1	15.4	6.2
$f_{Parsing}$	16.5	7.0	4.2	1.6
双输入 M2Net				
$f_{RGB+Contour}$	85.4	72.1	22.9	11.1
$f_{RGB+Parsing}$	82.5	69.2	23.2	10.5
$f_{Contour+Parsing}$	61.2	36.8	17.7	6.3
三输入 M2Net				
$f_{RGB+Contour+Parsing}$	86.4	72.5	24.7	11.4

接提升了特征的鲁棒性。这一定量结合定性的分析揭示：真正的“身份不变特征”并非某一模态独立承载，而是由轮廓提供的结构几何约束、语义分割提供的前景注意力引导，以及 RGB 中经多外观损失筛选后保留的局部不变纹理三者互补构成。其中，轮廓与语义分割作为外观不敏感的稳定模态，为 RGB 特征的学习提供了“结构锚点”，使得后者在训练过程中逐渐脱敏于衣饰颜色等外观相关的线索捷径。

3.5.4 SOTA 模型的对比实验

为了验证本文提出的 M2Net 模型在多个任务场景中的识别能力，我们在多个跨外观行人重识别数据集上进行了充分的实验。本文选取了目前最具有代表性的基于局部特征、注意力机制和 Transformer 结构的深度学习模型。NKUP+ 数据集和 PRCC 数据集同时具有跨外观候选子集和同外观候选子集，而 DeepChange 数据集只具有跨外观候选子集。根据现有行人重识别研究的测试场景分别进行实验。实验结果如表格3.4所示。每个数据集或子集的最好结果通过加粗进行标注。

通过比较所有模型的检索结果，我们很容易观察到所有模型在同外观子集上的识别精度均高于跨外观子集，这说明了外观变化是对行人重识别算法的巨大挑战。在先进的算法中，Trans-reID[31]在三个数据集上的表现是最为优异的。rans-reID 具有全局信息建模能力，更好地适应视角和姿态变化，同时可以提取行人的关联特征，对行人不同部分间的关联信息也是区分行人的一个重要提示，灵活的注意力机制可以自适应地调整模型关注的区域，更好地提取鲁棒性特征。

表 3.4 M2Net 模型和其他 SOTA 模型的对比实验结果

模型	NKUP+				PRCC				DeepChange	
	同外观		跨外观		同外观		跨外观		测试集	
	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
PCB[19]	76.0	60.9	9.3	5.1	**99.8**	97.0	41.8	38.7	13.9	4.0
MGN[20]	81.6	69.3	15.4	9.0	99.5	98.4	33.8	35.9	25.4	9.8
Strong Baseline[128]	78.1	60.4	11.0	5.4	98.0	96.8	39.8	40.4	25.5	8.8
ABD-Net[25]	81.6	67.7	17.6	9.0	98.6	98.1	41.4	42.8	24.2	8.5
FastReID-SBS[129]	58.6	34.7	11.8	3.8	97.6	94.0	32.2	33.0	13.9	3.3
RGA-SC[130]	79.4	62.2	15.4	7.3	98.3	97.7	34.0	34.0	28.9	8.6
Trans-reID[31]	81.1	69.6	19.7	10.9	99.6	98.7	44.6	46.5	35.9	14.4
AGW[131]	53.8	34.2	9.3	3.8	94.2	86.8	36.1	34.6	17.7	4.9
Baseline(Resnet50)	74.6	61.1	18.7	8.6	97.5	92.5	43.5	38.7	48.9	15.7
M2Net(Resnet50)	84.8	70.6	24.6	11.3	99.5	98.2	57.2	52.6	55.2	19.2
Baseline(Densenet121)	75.8	60.3	15.7	7.9	98.0	96.8	33.1	35.4	48.0	15.5
M2Net(Densenet121)	**86.4**	**72.5**	**24.7**	**11.4**	99.5	**99.1**	**59.3**	**57.7**	**57.2**	**19.6**

表 3.5 经典网络模型的参数和 NKUP+ 数据集上的训练时间对比

方法	总参数量	可训练参数	训练时间	NKUP+(R1)
ABD-Net[25]	64.2M	64.2M	5h	17.6
RGA-SC[130]	28.8M	28.8M	2.9h	15.4
Trans-reID[31]	96.8M	96.8M	4h	19.7
Baseline	7.3M	7.3M	3.5h	15.7
M2Net-F	63.4M	23.9M	6h	24.0

与本文的 M2Net 模型相比，在三个数据集的同外观和跨外观子集上均保持了显著的优势。使用 Densenet 骨干网的 M2Net 在 PRCC 的同外观子集上的精度与最优结果，除此之外，取得了所有数据集上测试任务的最优结果。M2Net 在三个行人重识别数据集的识别性能说明了本文的算法提取到了最鲁棒的行人特征，算法可以很好地应对同外观和跨外观两种识别场景。

3.5.5 SOTA 模型的参数对比

本文对比了表现较为优异的几种行人重识别模型的参数量、训练时间和性能，其结果如表格3.5所示。

通过对表格数据的分析，可以发现模型参数量与性能之间存在复杂而非线性的关系。

参数效率分析。Baseline 模型参数量最小（7.3M），但性能相对有限（R1=15.7），表明模型容量不足难以捕捉复杂的重识别特征。RGA-SC 模型在参数量（28.8M）和性能（R1=15.4）之间取得了较好平衡，训练时间最短（2.9h），体现了较高的

参数效率。

大规模模型的性能表现。Trans-reID 拥有最大的参数量（96.8M），性能（R1=19.7）显著优于轻量模型，证明 Transformer 架构在大参数量下的强大表征能力。ABD-Net 参数量（64.2M）与 M2Net-F 相近，但性能（R1=17.6）明显落后，说明单纯增加参数量而不优化架构设计效果有限。

M2Net-F 的卓越参数效率。总参数量 63.4M 与 ABD-Net 相当，但可训练参数仅 23.9M，这主要是因为模型的多模态数据导致的，但是行人数据集的多模态行人图像不需要重复训练，因此其训练时间不影响模型的训练时长。在可训练参数远少于 Trans-reID 的情况下，取得了最佳性能（R1=24.0），体现了极高的参数利用效率。训练时间 6h 虽然最长，但是其在跨外观行人重识别任务中具有巨大的性能优势，这一时间成本是可接受的。M2Net-F 通过创新的架构设计，在参数效率方面获得了较大的优势，证明了在行人重识别任务中，优化模型架构比单纯增加参数量更为重要。

3.5.6 可视化结果及分析

如图3.4对比了三种引入不同模态分支的 M2Net 算法在同一个查询图像（Query）下的消融实验的检索结果，来探究使用不同模态的分支网络提取的特征对算法的识别最终性能的贡献。

1. Baseline 网络使用与 M2Net 网络相同的骨干网络 Densenet 提取可见光拍摄的 RGB 行人图像的全局特征，使用行人重识别算法中经典有效的身份损失和最难三元组损失函数约束行人特征。算法返回的检索结果存在明显误差，在 Rank-10 的结果中全部错误匹配，检索结果的外观与查询图像十分相似，即使在身体形状上差异较大，仍然被模型判别为同一个目标。这印证了传统行人重识别算法对于衣着相关的外观信息的依赖，说明了跨外观行人匹配对算法的挑战。Baseline 的检索结果说明基线网络具备了最基础的行人匹配能力，主要关注颜色和纹理信息，依靠显著的信息进行匹配。然而，基线网络的这种匹配能力对外观变化、遮挡和背景干扰非常敏感，特征区分度不足，容易发生误检。这表明仅依赖单一或基础的视觉特征，模型鲁棒性较差，缺乏对细节（如鞋子、背包、局部纹理）的聚焦能力[132-133]，导致在复杂场景下容易失效。

2. M2Net-B 网络使用可见光拍摄的 RGB 行人图像和行人的轮廓草图作为 M2Net 模型的输入，使用本章节前述的损失函数对识别算法进行约束。对比基线网络的检索结果，外观相近的行人图像仍然被模型预测和查询图像同属一个



图 3.4 不同数目分支的 M2Net 网络的可视化结果示意图

行人，然而在 Rank-10 的结果中，检索到了存在外观变化的目标行人，返回的正确结果与查询图像的视角相近，由于光照的影响，外观特征中的颜色差别较小，使模型识别为同一类别的结果。M2Net-B 网络的检索结果说明了引入轮廓草图可以使得模型开始关注行人图像中对目标行人鲁棒的体型信息信息等，外观相关的特征距离被拉远，不再只依靠显著的外观特征。然而，轮廓草图不包含行人图像的细节信息，忽略了行人图像中的细节信息，仍然存在不足。

3.M2Net-F 网络引入了可见光拍摄的 RGB 行人图像和行人的轮廓草图以及行人图像的语义分割结果作为 M2Net 模型的输入，同样使用针对外观变化的损失函数来引导模型的训练，对比 Baseline 网络和 M2Net-B 的检索结果，其检索性能得到了显著的提升，Rank-10 的结果中，正确的检索结果的比例明显增加，且排名较为靠前，这说明模型对于外观变化具有较好的适应性。M2Net-F 整合了多个分支特征后的融合输出，它结合了全局和局部信息，融合了来自不同网络层的特征，从而得到了更具判别力的综合特征表示。M2Net-F 的性能提升证明了多模态特征融合的有效性，尤其是行人的语义分割结果的提升较为明显，在第一个查询图像的示例中，模型的返回结果十分突出，这主要是因为行人图像中的细节特征信息，比如背包等，在外观变化中保持一致，且十分醒目，这说明细节信息对应的局部特征对于跨外观行人的检索十分有效。然而，这种细节信息并不总是有效，应该平衡全局特征和局部特征的权重，以获得综合更优的检索结果。

关于基于多模态行人图像的分支网络相关的消融实验清晰地展示了行人图像的模态对跨外观行人的匹配的影响：使用行人 RGB 图像的全局特征（Baseline）是基础，提供了对行人图像基本的特征匹配，但不足以应付跨外观的行人图像的检索。引入了行人轮廓草图这一模态之后，模态可以降低外观变化的对识别过程干扰，返回姿态相似、身体形状相近的行人图像，但模型对细节不敏感，不能关注目标行人跨外观图像的一致性因素。而人体语义分割结果可以使行人的局部区域进行对齐，因此局部区域的一致性特征的权重增加，显著增加了模型对跨外观行人检索的能力。

多模态融合方法（融合 RGB 图像、轮廓图、语义分割图）的核心思想在于，通过引入先验知识（即轮廓和语义是身份的不变属性），来引导模型忽略与身份无关的噪声（主要是外观/clothing），从而在特征空间中对数据进行更有效的压缩和表示。从信息论的角度看，行人重识别的目标是学习一个映射函数 f，将

高维的输入数据 $X \in \mathbb{R}^{H\times W\times C}$ 压缩成一个低维的特征表示 $Z = f(X)$，同时要求 Z 是关于身份标签 Y 的**最小充分统计量**。这意味着最大化 Z 与 Y 的互信息 $I(Z;Y)$，同时最小化 Z 与输入 X 中冗余信息的互信息 $I(Z;X)$。这对应于**信息瓶颈理论**：

$$\max\ I(Z;Y) - \beta I(Z;X)$$

其中 β 是平衡参数。纯 RGB 输入中 $I(Z;X)$ 包含大量衣着等外观噪声。当引入轮廓特征图 X_s 和语义分割图 X_p 时，相当于提供了两条与衣着无关的额外信息通道，模型可以直接利用这些“干净”信号，从而在压缩过程中更容易丢弃 RGB 中的外观噪声，使得最终特征 Z 能以更低比特数高效编码身份信息 Y。

第六节 本章小结

本章从特征表达层面出发，提出了一种通用且高效的跨外观行人重识别算法。我们首先分析了标准采样在跨外观场景下的缺陷，进而设计了基于外观标签的样本采样策略，使模型聚焦于那些外观差异大但身份相同的困难样本对，有效抑制了模型对外观相关的特征的学习。在此基础上，提出的多外观损失函数通过显式约束跨外观正样本对的特征一致性，进一步增强了身份不变特征的判别力与紧凑性。在 NKUP+、PRCC 等多个数据集上的实验表明，本章方法在仅引入采样策略和损失函数改进的条件下，即可取得与部分多模态方法相当甚至更优的性能，且计算开销极小，展现出良好的通用性和可组合性。

然而，实验过程中我们也观察到，当训练集中某类外观变化（如季节性换装）严重缺乏时，模型对该类变化的泛化能力仍然受限。这揭示了特征表达优化的瓶颈：采样与损失函数的设计再精巧，也难以弥补训练数据本身在外观多样性上的先天不足。换言之，若数据中缺少“夏装 → 冬装”的对应样本，此类映射的数据量不足以支持模型的优化。因此，单纯从特征表示层面很难进一步突破算法性能瓶颈，下一步必须从数据层面主动扩充外观多样性，为特征学习提供更丰富的跨外观正样本支撑。这正是第四章工作的出发点——通过生成式方法合成多样化的跨外观行人图像，从根本上打破数据稀缺的桎梏。

第四章　基于生成模型的跨外观行人数据集的外观增强

第三章通过改进采样策略与损失函数，在特征表示层面有效抑制了模型对外观捷径的依赖。但实验同时揭示出一个根本性瓶颈：训练数据的外观种类的数量不足已成为制约性能进一步提升的主要因素。在真实跨外观场景中，同一行人在不同季节、不同场合下的外观可发生彻头彻尾的改变，而人工采集穷尽所有外观组合几乎不可能。我们进一步系统探究了模型容量与训练数据规模对跨外观性能的影响，发现即使增大模型参数量，在现有数据集上性能增益也迅速饱和，证明数据本身的局限已构成首要矛盾。因此，要持续推动跨外观行人重识别的前进，必须从数据层面着手，主动扩充行人外观的多样性。

本章提出一种基于外观与体型特征解耦的行人图像生成算法，旨在为任意行人图像生成具有不同外观的新样本，从而低成本地增加训练数据的外观种类。该算法将行人图像分解为外观编码（如衣饰颜色、纹理）和体型结构编码（如姿态、体型轮廓），并通过对抗性训练实现跨外观的重组与生成。与已有生成方法不同，我们特别强调在生成过程中保持身份关键特征（尤其是体型与步态线索）的不变性，确保生成样本可作为可靠的正样本用于特征学习。通过将生成图像加入训练集，模型得以接触大量“同一身份、迥异外观”的配对样本，从而更本质地学习到不受外观特征干扰的身份表征。本章工作可视为对第三章表示学习框架的数据级补充，两者结合有望实现“更好的特征学习 + 更丰富的数据供给”的协同增效，并为第五章引入视角约束提供了更加完备的数据基础。

第一节　引言

基于深度学习的行人重识别算法一般包含三个常规流程，即输入数据，特征提取和损失函数优化。在第三章中，本文着重对于特征提取的网络设计和损失函数优化进行了深入探索，提出了多模态行人图像输入下的跨外观行人重识别网络融合特征设计以及基于行人外观标签的随机外观采样策略和对应的损失函数。

除了新颖的网络结构和损失函数，输入数据对现有的深度学习算法存在着很大影响。一方面，深度神经网络使用的训练集与测试集虽然互相独立但是一

般具有相同的分布，根据有限的训练集数据对网络模型进行优化，对未知的其他测试集或真实场景下进行类别或概率预测时，测试集的分布差异不可避免。因此小规模的训练集会给模型精度带来很大的影响，使得训练集的精度极高，然而在测试集或现实应用中精度大大降低。与其他计算机视觉或图像分类的数据集相比，现有的行人重识别数据集尤其是包含外观变化的行人数据集普遍较小，属于中小样本的行人细粒度分类问题，不足以满足深度网络训练的泛化性能要求，有限的训练集数可能导致对小规模行人图像数据的过拟合从而带来精度性能损失。另一方面，随着对行人重识别任务的逐步研究，更加多样化的行人重识别任务场景会使得不同的行人数据集间存在着分布差异，比如行人的光照、视角、天气、遮挡或外观变化等因素，这种分布差异会使得模型对行人图像的种类的概率预测产生错误倾向。由以上现象本文可以观察到，数据集的规模和质量对跨外观行人重识别的性能有着至关重要的影响，甚至是限制了现有模型的性能。如何解决数据上数量不足尤其是外观多样性的不足，同时避免数据集的域间差异的问题是带来的性能损失亟待解决的关键性问题。本章中，本文将从输入数据出发，探讨数据尤其是外观变化属性对跨外观行人重识别性能的影响，通过生成模型和数据增强策略解决行人的外观变化轻微和缺乏外观多样性的问题，从而进一步提升行人重识别的性能。

近年来，对抗生成网络做数据生成引起了较大关注[134]。利用对抗机制引领网络生成相应的数据变换，可以解决数据间变化过于单一带来的过拟合问题，从而对现有数据进行有效扩充。然而现有的普适数据生成方案无法控制和量化生成数据对行人重识别课题的有效性。扩充数据的性能往往具有比较大的随机性。如何提出一个针对性的数据生成框架，从而引导行人重识别数据生成是一个亟待解决的问题。因此，本文分析了现有行人重识别数据中存在的问题，并提出了对应的数据生成方案，基于深度生成对抗网络，从端到端的背景替换到视频帧预测网络，来解决由杂乱背景、有限数据对基于视频的有监督行人重识别的影响。

此外，数据间的分布不一致问题也能通过数据变换与迁移进行差异间的消除。进一步地，这种网络间的对抗学习思想启发本文解决更具实用价值的从虚拟到现实的行人匹配问题。本文注意到，随着多媒体领域和计算机视觉技术的快速发展，智能安防监控对多摄像机网络布局下多模态下的行人重识别，特别是跨外观行人图片的重识别，如从犯罪嫌疑人穿脱外套前后的匹配，有着很大

的需求和发展空间。传统行人重识别受限于不同摄像机视角下光线和行人姿势变化的挑战。多模态下的行人重识别，除了数据量不足和特征提取算法方面的挑战，关键性问题还在于源数据在外观维度不具有多样性。为此，本文提出了基于生成框架的行人图像的外观增强方法，通过编码器和解码器得到不同外观的行人图像，并结合对抗学习来提升生成图像的质量以及标签的可靠性，从而引导跨外观行人重识别模型提取更鲁棒的特征信息，进而得到更好的识别性能。

综上所述，本章的主要贡献在于：

- 提出了针对外观变化扩展行人图像数据集的图像生成方案，用于跨外观行人重识别中数据集的外观种类数量不足带来的性能限制。通过真实的行人图像的外观丰富单个行人的外观多样性，促进模型对外观变化的适应性。
- 使用外观标签约束和身份标签约束编码器的特征提取，进一步解耦行人图像的外观特征和行人本体特征，并约束生成图像的质量，提高生成图像的标签的可靠性。
- 通过消融实验证明行人外观生成框架的有效性，验证每个策略对模型训练的影响。本文的生成框架生成的行人图像对所有行人重识别算法均具有提升作用。

第二节 算法设计与实现

4.2.1 CAG 模型概述

如图4.1所示，本文提出了一个基于对抗学习的图像生成网络 CAG(Cross-appearance images generation)。其主要的结构包括编码器、解码器 (生成器) 和判别器构成。

4.2.2 CAG 框架的设计

行人特征解耦。模型的输入是真实的行人图像，即 RGB 图像，本文使用 $X \in \mathbb{R}^{H \times W \times C}$ 来表示。第 i 张行人图像都具有身份标签 $Y = y(i)_{i=1}^{N}$ 和外观标签 $Y_a = y_a(i)_{i=1}^{N}$。对于每一张输入图像来说，本文使用外观编码器 E_a 和行人编码器 E_i 两个编码网络解耦行人图像中与外观变化相关的特征和对外观变化鲁棒的特征。对于所有的行人图像来说，使用相同的编码器提取对应的行人图像特征。编码特征提取的过程如公式4.1所示。

$$\begin{aligned} f_a &= E_a(X) \\ f_i &= E_i(X) \end{aligned} \tag{4.1}$$

自重构行人图像。对于行人图像 x_i 和 x_j 来说，编码器输出两种行人特征编码分别为 $f_a(i)$ 和 $f_i(i)$ 以及 $f_a(j)$ 和 $f_i(j)$。而解耦后的外观特征和行人特征通过生成器 G 可重建行人图像 $\bar{x_i}$ 和 $\bar{x_j}$。自重构行人图像是引导生成器 G 学习恢复行人图像，其过程如公式4.2。

$$\bar{x_i} = G(f_a(i), f_i(i)) \bar{x_j} = G(f_a(j), f_i(j)) \tag{4.2}$$

交叉特征重构行人图像。通过自重构损失和标签损失的优化，本文优化了编码器和生成器。对于行人图像 x_i 和 x_j 来说，通过外观编码器和行人编码器可获得 $E_{appearance(i)}$、$E_{identity(i)}$ 以及 $E_{appearance(j)}$、$E_{identity(j)}$。通过交换两种行人图像的外观编码特征和身份编码特征，本文分别将其输入到生成器中，本文就可以获得新的生成图像，丰富单个行人增加更多的外观种类。模型交换编码特征生成图像的过程如公式4.3所示。

$$\begin{aligned} G : (E_{appearance(j)}, E_{identity(i)}) &\rightarrow x_i^j \\ G : (E_{appearance(i)}, E_{identity(j)}) &\rightarrow x_j^i \end{aligned} \tag{4.3}$$

4.2.3 CAG 生成框架的损失函数设计

对于编码器的相似性度量函数。基于外观编码器和行人编码器分别获取的行人特征编码，为了约束编码的相似性，本文设计了基于编码特征的正则化损失。约束外观特征编码和行人特征编码的损失函数如公式4.4所示。

$$\begin{aligned} \mathcal{L}_{APcode} &= \mathbb{E}[\| E_{appearance(i)} - E_a(x_j^i) \|] \\ \mathcal{L}_{IDcode} &= \mathbb{E}[\| E_{identity(i)} - E_i(x_i^j) \|] \end{aligned} \tag{4.4}$$

对于生成器重构行人图像，本文设计一个自监督损失函数，模型使用像素级的自监督损失优化生成器的生成能力。约束生成器的损失函数如公式4.5所示。

$$\begin{aligned}\mathcal{L}_{recon}^{1} &= \mathbb{E}[\|x_i - \bar{x_i}\|] \\ \mathcal{L}_{recon}^{2} &= \mathbb{E}[\|x_j - \bar{x_j}\|]\end{aligned} \tag{4.5}$$

基于标签的重构。对于每一张输入图像和重构图像来说，本文可以获取对应的外观标签和身份标签，在模型使用解码器提取对应特征时，本文对应的编码特征赋予特征标签。经过生成器恢复行人图像时，本文期望生成的行人图像的外观标签和行人身份标签保持一致。也就是说，身份标签 y 和外观标签 y_a 跟随对应的编码特征的标签，生成器生成的行人图像的标签取决于编码特征的标签。对于生成图像来说，本文同样使用编码器解耦其外观编码和行人编码，对于所有的编码特征，本文使用确定的外观标签和身份标签进行约束。本文计算两种损失为 $\mathcal{L}_{IA}$，其公式如4.6所示。

$$\mathcal{L}_{IA} = \mathcal{L}_{ID} + \mathcal{L}_{AP} \tag{4.6}$$

其中，$\mathcal{L}_{ID}$ 和 $\mathcal{L}_{AP}$ 都属于标签的交叉熵损失函数，其公式可参考第二章。

基于对抗学习的对抗性损失。模型使用判别器 D 分辨生成图像和真实图像，以拟合生成数据和真实数据之间的分布。判别器计算对抗损失如公式4.7所示。

$$\begin{aligned}\mathcal{L}_{adv} =& \mathbb{E}[\log D(x_i) + \log(1 - D(x_i^j))] + \\ & \mathbb{E}[\log D(x_j) + \log(1 - D(x_j^i))]\end{aligned} \tag{4.7}$$

总体损失函数设计。最终，本文综合使用以上各个损失优化编码器和生成器对行人图像的特征编码提取和图像恢复过程。本文认为自重构损失和对抗损失是影响行人图像生成的重要损失函数，因此赋予对应损失函数较高的权重。对于编码器的优化，本文主要使用交叉熵损失和特征编码的相似性度量，为了平衡二者的效果，本文最终定义损失函数如公式4.8所示。

$$\begin{aligned}\mathcal{L}_{Total} =& \mathcal{L}_{recon}^{1} + \mathcal{L}_{recon}^{2} + \mathcal{L}_{IA} + \\ & \mathcal{L}_{IDcode} + \mathcal{L}_{APcode} + \mathcal{L}_{adv}\end{aligned} \tag{4.8}$$

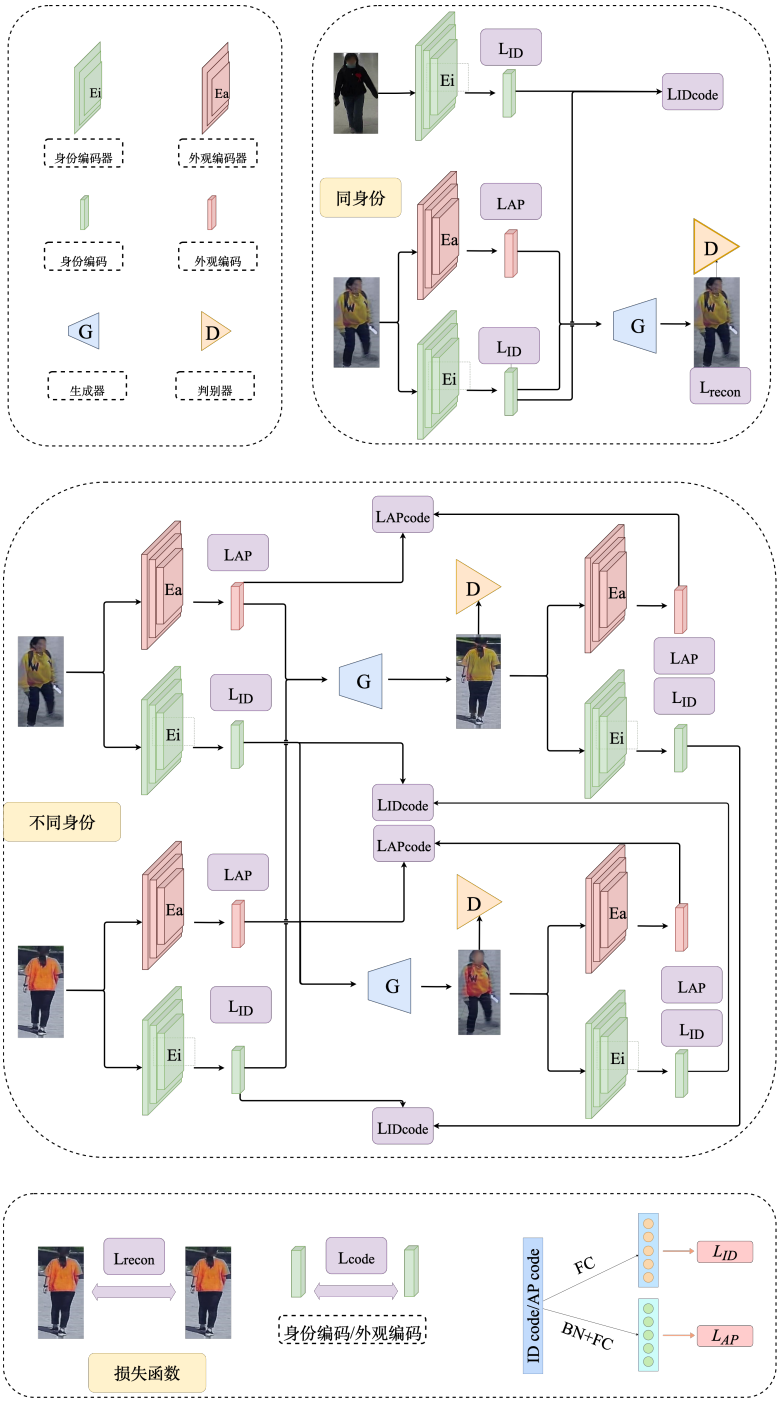


图 4.1 CAG 网络的结构图

4.2.4 生成框架的优化

本文使用循环训练来优化编码器和生成器，并使用像素级和图像集的多重监督来引导模型对于特征的解耦和重构。循环训练既可以保证行人图像的特征编码的鲁棒性，又可以增强行人图像的质量，最终生成不同行人身体特征和外观特征的新的组合的行人图像。

该行人图像生成网络的优化过程是一个多阶段、多目标协同的精细平衡艺术，其核心目标是生成高质量、高保真度且身份信息一致的跨外观或跨视角行人图像。整个过程紧密围绕生成对抗网络（GAN）的训练范式展开，并通过引入多种专用损失函数来引导模型学习。

首先，优化过程的基石是对抗性训练。生成器（Generator）致力于将输入的行人外观编码（如服装纹理、颜色）与行人的身份编码（主要包括目标姿态关键点等鲁棒性信息）融合，生成以假乱真的图像。而判别器（Discriminator）则需区分真实图像和生成图像。通过二者的动态博弈，生成器被迫学习真实行人图像数据分布中的复杂细节，如衣物质感、光照阴影和身体轮廓的自然过渡。然而，单纯的对抗损失容易导致模式崩溃或身份信息丢失。

因此，优化过程的关键在于引入强大的身份保持约束。这是通过一个预训练好的、且参数冻结的行人重识别（ReID）特征提取网络来实现的。在每次迭代中，生成图像和对应的原始真实图像都会被送入该 ReID 网络，提取高维特征向量。随后，计算二者之间的特征距离损失（如三元组损失或余弦相似度损失）。该损失函数直接惩罚那些导致身份特征发生变化的生成结果，强制生成器在改变外观或姿态时，必须保留诸如体型、步态、面部特征（若可见）等与身份相关的深层、不变属性[135-136]。这是确保生成图像能有效用于 ReID 数据增强的根本。

此外，优化过程还深度融合了像素级和感知级的重建损失。对于有明确对应关系的任务（如姿态转换），会计算生成图像与目标真实图像之间的 L1 或 L2 损失，确保在像素层面保持基本结构的一致性。同时，感知损失（Perceptual Loss）利用 VGG 等网络中间层的特征图来计算差异，它比像素损失更能捕捉视觉内容的相似性，有助于生成图像在视觉上更自然、更连贯。

最后，为了处理跨外观生成中可能出现的边缘伪影和背景扰动，优化过程通常还会加入语义分割掩码损失或背景稳定损失，确保模型专注于行人生成，并保持背景的连贯性。

表 4.1 M2Net 选用不同骨干网的实验结果

骨干网	同外观		跨外观	
	R-1	mAP	R-1	mAP
ResNet50	79.9	65.2	3.8	3.0
NonLocal	80.8	66.4	4.4	3.1
SE Net	79.6	64.1	4.1	2.7
Swin Transformer	65.9	54.7	3.1	2.5
DenseNet121	81.9	69.5	5.1	3.5

综上所述，该网络的优化是一个通过对抗损失驱动生成真实性、利用身份损失保障身份一致性、重建损失维护结构准确性的协同过程。训练中需要精心平衡各项损失的权重系数，使生成器最终能学会解耦行人的外观特征与身份特征，从而可控地生成既多样又可靠的训练数据，极大增强下游行人重识别模型的鲁棒性。

4.2.5 行人重识别算法的设计

对于跨外观的行人检索，本文对比了多个骨干网络和多种池化层。对于不同的骨干网，本文都使用了同样的数据集、输入图像、采样策略和损失函数。实验结果如表格4.1所示。

DenseNet121 具有特征复用机制，契合行人重识别任务的细粒度需求。DenseNet 的核心思想是“密集连接”，即每一层都与其后续所有层直接相连，而行人重识别是一个典型的细粒度图像识别任务，不同行人的区别可能仅在于背包的细微条纹、鞋子的款式或衣服的褶皱等微小特征。DenseNet 的密集连接机制完美契合了这一需求。在行人重识别任务中，低层的边缘、纹理信息和高层的高级语义信息都至关重要。DenseNet 确保了这些不同层级的特征都能畅通无阻地传递到网络末端，使模型能够综合利用多尺度、多层次的细节信息来区分相似行人。这直接解释了为何其 mAP（平均精度均值）指标尤其突出（69.5%），因为 mAP 综合考虑了检索的全面性和准确性，对特征区分度非常敏感。其最高的 R-1 也证明了其在首要匹配上的优势。

NonLocal 与 SE Net 这两者都引入了注意力机制，但侧重点不同。NonLocal 注重捕获空间维度上的长距离依赖关系。一个像素点的特征可以由图像中所有其他像素点的特征加权得到，非常适合建模全局上下文信息。SE Net 则注重捕获通道维度上的依赖关系。通过“压缩-激励”操作，自动学习每个特征通道的重要性权重，增强有用通道，抑制无用通道。对于行人重识别任务的需求来说，

行人的关键判别区域（如头部、背包、鞋子）可能出现在图像的任意位置，且与整体外观存在复杂关联。NonLocal 模块能够让网络“看到”全局。例如，当识别一个人时，网络可以同时关注到其头部的帽子和脚上的鞋子，即使它们在图像中距离很远。这有助于生成更具判别力的全局特征，因此其同外观的表现（R-1: 80.8, mAP: 66.4）仅次于 DenseNet121。而 SE Net 通过强化重要特征通道来增强模型的特征表示能力。在行人重识别任务中，某些颜色或纹理的特征通道可能对区分特定行人更为关键。SE Net 能自适应地突出这些关键特征，因此也取得了与 ResNet50 相当甚至略优的表现（R-1: 79.6, mAP: 64.1）。

ResNet50 是一种性价比极高的基线模型，ResNet 通过残差连接解决了深层网络的梯度消失问题，是计算机视觉领域最经典、最稳健的骨干网络之一。它结构均衡，在性能和计算成本之间取得了良好平衡。ResNet50 作为一个强大的特征提取器，在行人重识别任务中始终是一个可靠的基线，其表现（R-1: 79.9, mAP: 65.2）证明了该骨干网络的有效性。然而，与专门引入了密集连接或注意力机制的模型相比，其在特征重用和自适应特征校准方面存在固有局限，因此性能被 DenseNet121 和 NonLocal 超越也在情理之中。它是一个“优秀但非顶尖”的选择。

Swin Transformer 是视觉 Transformer 的代表，它通过自注意力机制全局建模图像信息，并采用分层设计和滑动窗口，高效地处理多尺度特征。理论上，Transformer 强大的全局建模能力应对行人重识别任务非常有潜力，许多基于 Transformer 结构的行人重识别算法也印证了这个判断。但其在此次实验中表现最差（R-1: 65.9, mAP: 54.7），可能源于以下原因：数据量不足，Transformer 模型通常需要在大规模数据集（如 ImageNet-21K）上进行预训练，才能在特定任务上发挥优势。本次实验使用的跨外观行人数据集规模有限，可能无法充分激发 Swin Transformer 的潜力，导致其欠拟合。训练策略不匹配：Transformer 需要精心设计的训练策略（如更复杂的数据增强、更长的训练周期、特定的优化器设置）。如果直接沿用为卷积神经网络设计的训练超参数，很可能无法使其达到最佳状态。位置信息的敏感性：行人重识别任务中，行人的结构信息（头-身-腿）很重要。标准的卷积神经网络具有内置的平移不变性，而 Transformer 对位置信息更加敏感，可能需要更精细的位置编码设计来适应行人重识别任务。

本次实验结果表明，DenseNet121 凭借其卓越的特征复用能力，与行人重识别这类细粒度的识别任务十分匹配，在这几个经典的骨干网中表现最为卓越。

表 4.2 M2Net 选用不同池化层的实验结果

池化层	同外观		跨外观	
	R-1	mAP	R-1	mAP
GMP pooling	85.3	74.2	5.9	3.9
Max pooling	86.1	74.8	4.4	3.3
Avg pooling	83.8	71.1	5.1	3.5
Mix pooling	84.3	71.6	5.3	3.3
Soft pooling	82.3	70.3	5.3	3.5
Dual pooling	85.8	73.1	4.9	3.4

引入了注意力机制的 NonLocal 网络, 对提升 ReID 性能有明确助益，它们能帮助模型聚焦于关键区域和特征通道。ResNet50 作为一个稳健的基线，表现良好但在这个特殊任务场景中已被更加适配任务需求的骨干网超越。Swin Transformer 的糟糕表现很可能与数据和训练策略有关，而非其架构本身不适合 ReID。在更优的条件下，它仍有巨大潜力。最后，所有模型在跨外观行人重识别场景下的性能都急剧下降（R-1 均低于 5.2），这凸显了主流的行人重识别方法对照、视角、着装季节等引起的外观变化的鲁棒性仍然是一个极其严峻的挑战，是未来研究的重点方向。

根据使用不同骨干网的实验结果，本文又选取了不同的池化层对特征进行池化处理。对应实验结果如表格4.2所示。

从实验结果来看，Max Pooling（最大池化）在相同外观场景下的识别任务中取得了最佳性能（Rank-1: 86.1%, mAP: 74.8）。GMP（Generalized Mean Pooling，广义平均池化）和 Dual Pooling（双池化）表现紧随其后，同外观的识别性能优异。然而，所有池化方法在跨外观的行人重识别场景下的性能均出现急剧下降（Rank-1 均低于 6%），这凸显了跨外观重识别是一个极其困难的挑战，单一的池化策略难以解决根本问题。值得注意的是，GMP 在跨外观的 Rank-1 上取得了最好成绩（5.9%），表明其在外观剧烈变化时仍具有一定的检索能力。综合来看，若追求模型在标准场景下的峰值性能，应选择 Max Pooling。若更关注模型在困难场景下的鲁棒性潜力，可考虑 GMP。由于本文主要解决跨外观行人重识别的任务，因此本文选取在两种识别任务中综合排名的最优策略，即 GMP 池化方法。

池化层的核心作用是在保留主要特征的同时，对特征图进行降维，增加模型的平移不变性和感受野。对于行人重识别任务，池化策略直接影响着如何从骨干网络提取的特征图中聚合出最终的代表行人的“特征向量”（或称“特征描述子”）。这个特征向量的质量直接决定了重识别的精度。

Max Pooling（最大池化）的设计意图是突出图像的最强判别性特征，最大池化选取局部区域内的最大值作为输出。这种机制能够捕捉特征图中最显著、激活最强的局部特征。在 ReID 中，这对应了行人身上最独特、最具判别力的部分，比如一个醒目的 logo、一个特定颜色的背包或独特的鞋子款式。这些“关键点”特征对于区分不同行人至关重要。因此，Max Pooling 和 GMP 在同外观场景下取得了领先的性能（Max: 86.1/74.8, GMP: 85.3/74.2）。其缺点是容易忽略次要但可能互补的特征信息，并且对噪声和遮挡比较敏感。如果一个关键特征因遮挡或光照变化而消失，整个特征向量的判别力会大幅下降。这可能也是它们在跨外观场景下性能衰减严重的原因之一。

GMP 是一种可学习的幂平均池化，其核心公式的计算如公式4.9所示：对于一个特征图的单个通道，GMP 计算该通道上所有激活值，给定该通道上的所有激活值 $x_1, x_2, ...x_n$，

$$\mathrm{GMP} = \left(\frac{1}{n} \sum_{i=1}^{n} x_i^p \right)^{1/p} \tag{4.9}$$

其中，p 是一个可学习的参数。当 $p = 1$ 时，GMP 退化为标准的全局平均池化（GAP）。当 $p \to \infty$ 时，GMP 趋近于全局最大池化（Global Max Pooling），因为最大值项将主导整个求和的过程。通过训练过程学习到合适的 p 值，GMP 可以自适应地在“取平均”和“取极大值”两种模式之间找到最优的平衡点。

GMP 最大的优势在于其摆脱了固定模式的限制。它不像 Max 或 Avg 池化那样预先设定好聚合规则，而是让网络根据数据和任务目标自行决定特征的聚合强度。对于跨外观行人重识别任务来说，网络可以通过学习到的 p 值来判断，对于当前的数据集，是应该更关注“最突出的特征”（大 p 值），还是应该更关注“整体特征的均衡贡献”（p 值接近 1）。例如，如果数据集中的行人主要依靠携带的独特物品（如亮色背包）来区分，网络可能会学习一个较大的 p 值，使 GMP 的行为接近 Max Pooling，以聚焦于这些关键物品。如果行人区分更依赖于整体服饰的颜色搭配和纹理，网络可能会学习一个较小的 p 值，使行为接近 Avg Pooling，以综合这些全局信息。

基于上述机制，GMP 与跨外观行人重识别任务的匹配度非常高，这完美地解释了其在表格中的优异表现。同外观性能卓越（R-1: 85.3%, mAP: 74.2%，排名第二）的原因。跨外观行人重识别是一个细粒度识别任务，理想的特征提取方式既不能像 Max Pooling 那样过于激进（可能因忽略上下文而脆弱），也不能

像 Avg Pooling 那样过于保守（可能稀释关键特征）。GMP 通过可学习的 p 值，实现了“软性”的特征选择。它能够显著提升重要特征的权重，同时不完全丢弃其他特征的贡献。这种折衷方案恰好适合描述一个行人，即需要突出其最具判别力的部位，也需要整体的轮廓、姿态等上下文信息作为支撑。因此，其生成的特征描述子兼具高判别力和丰富度，从而获得了仅次于 Max Pooling 的优秀性能。跨外观性能领先（R-1: 5.9%，排名第一）的原因，这是 GMP 优势最明显的体现。跨外观任务的核心挑战是特征的不确定性。由于光照、视角、遮挡的变化，行人在不同图像中的“最显著特征”可能是不稳定甚至消失的（例如，一个关键背包在另一个视角下被遮挡）。GMP 的鲁棒性在于 GMP 由于保留了更多特征信息（尽管权重不同），当某个最强特征失效时，其他次强特征仍然能提供有价值的判别线索。换句话说，GMP 生成的特征向量冗余度更高，容错性更强。这使得它在外观剧烈变化的挑战性场景下，依然能保持相对最好的检索能力（最高的 Rank-1 准确率）。

Avg Pooling（平均池化）的设计意图是获取图像中稳健的全局外观信息，平均池化计算局部区域内所有值的平均值。全局平均池化是最常见的做法，它对每个通道的所有特征点取平均值。平均池化能保留特征图的整体分布，反映行人的全局平均外观信息，如整体的衣服颜色、体型轮廓。它对局部噪声和微小变化不敏感，特征输出更平滑、稳健。其问题在于可能会稀释或模糊掉那些细小但关键的判别性特征。对于 ReID 这种细粒度任务，最强特征的信号在取平均过程中被弱化，导致特征区分度不足。这解释了其同外观性能（83.8/71.1）为何显著低于最大池化和广义平均池化。

Mix Pooling（混合池化）和 Dual Pooling（双池化）的设计意图是尝试结合最大池化和平均池化二者的优势，以取得更好的结果。Mix Pooling（混合池化），通常指在训练时随机选择使用 Max 或 Avg 池化，或者将两种池化后的特征进行拼接/加和。Dual Pooling（双池化），明确同时使用 GMP 和 GAP，并将产生的两个特征向量进行融合（如拼接）。这类方法的初衷是同时利用最大池化的判别力和平均池化的稳健性。理论上有望获得更全面、更具鲁棒性的特征表示。然而，本实验中 Dual Pooling（85.8/73.1）和 Mix Pooling（84.3/71.6）的性能虽然优秀，但并未超越单纯的 Max Pooling。这意味着特征融合方式并非最优，简单的拼接或加和可能引入了冗余，甚至产生了轻微的特征冲突，未能实现“1+1>2”的效果。Max Pooling 的特征主导性更强，在行人任务中，最具判别力的特征信息可

能已经足够强大，平均池化带来的“稳健性”收益在标准数据集上不足以弥补其带来的“区分度”下降。

Soft Pooling（软池化）是一种平滑的替代方案，软池化基于激活值的大小计算权重，进行加权平均，是一种介于 Max 和 Avg 之间的平滑方法。它既考虑了所有像素点，又给予高激活值更高的权重。理论上，它兼具了 Max Pooling 的判别性和 Avg Pooling 的稳定性。但本实验中其表现（82.3/70.3）相对较差。可能原因是其平滑特性削弱了最强特征的突出地位，而对于行人重识别任务来说，往往正是这些极端显著的特征点起着决定性作用。

跨外观重识别的挑战源于光照、视角、季节着装等变化导致的行人外观本质改变。本实验最值得关注的发现是：无论采用哪种池化策略，跨外观性能都极其低下。这指向了一个核心结论：池化层主要影响的是如何从“一张图片”中提取最佳特征，但无法解决“不同外观下同一行人的特征本身发生剧烈变化”这个根本性问题。应对这一挑战，需要模型具备更强的不变性特征学习能力，这远非池化层所能独立承担。解决方案可能在于：更强大的数据增强模拟外观变化，专门设计的损失函数（如强调不变性的度量学习），引入额外的模态信息（如轮廓、姿态、语义分割掩码）来辅助外观变化下的匹配等方法。本文提出的一些方法有效提升了模型在跨外观行人重识别场景的性能。

综上所述，对于跨外观行人重识别的算法，GMP Pooling 具有较大的应用潜力。因为它能最有效地提取行人的关键判别特征，在标准评测中表现最佳。同时不可以忽略的是，当前实验表明改善跨外观性能不能依赖于更换池化层，而需要从特征学习的前端和模型整体结构上寻求突破。池化层的选择优化，主要影响的是模型在同外观下的性能上限。

DenseNet 的核心创新在于其密集块（Dense Block）结构，与行人重识别中常用的 ResNet 的残差相加不同，DenseNet 通过通道维度拼接（Concatenation）来连接所有前面层的特征图。Dense Block 结构如图4.2所示。

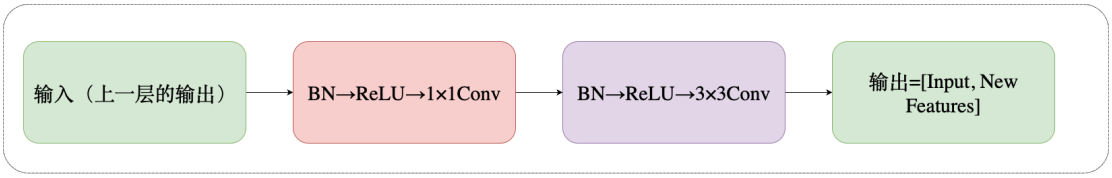


图 4.2　Dense Block 的结构图

这种设计这种设计带来了两个关键特性：特征复用（Feature Reuse）和隐式

深度监督（Implicit Deep Supervision），这意味着后续层可以直接使用前面所有层的原始特征，避免了重复学习，同时每层都通过损失函数的梯度直接监督，缓解梯度消失。标准的 DenseNet 结构有卷积层、池化层和密集块构成。如图4.3所示，展示了 DenseNet 的核心架构和其密集连接机制。

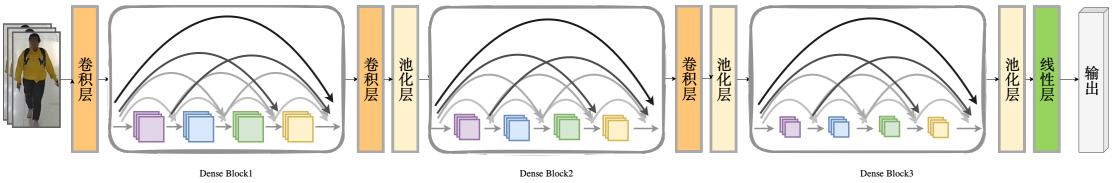


图 4.3　DenseNet 的网络架构图

DenseNet 在行人重识别算法中具有显著的优势，DenseNet 网络在设计上天然拥有了特征多样性的特点，这是因为在密集块中，由于每一层都接收前面所有层的特征，网络中天然存在多尺度的特征（低层的细节、高层的语义）。这种“内置的特征金字塔”非常有利于行人重识别任务，模型可以自适应地选择最有效的特征来区分不同行人。尤其是提取行人图像中的底层细节特征（如鞋子纹理、背包款式），细节特征可以直接传递到高层，不会被网络深度“稀释”而丢失，这对于跨外观行人重识别中的细粒度特征匹配十分重要。密集连接的结构块使得模型具有强大的特征复用能力，这可以有效地缓解梯度消失的问题，改善模型泛化能力，减少过拟合。这意味着模型的深度对于算法优化的限制减少，深层次的网络也可以快速地有效训练，特征复用机制类似于一种隐式的正则化，使模型更倾向于学习冗余的特征表示，而不是过度依赖少数特定与外观相关的特征，从而在跨外观的行人重识别的场景中表现更鲁棒。

DenseNet 网络的参数效率高，计算量更小。DenseNet 网络通过 1×1 卷积的降维和过渡层的压缩，使得该网络可以使用更少的参数和计算量（FLOPs）就能达到与 ResNet 相当甚至更好的性能。这意味着以 DenseNet 网络作为骨干网的模型结构更加紧凑和轻量化，有利于算法在设备端的部署。

4.2.6　行人重识别算法与生成图像的融合训练

通过 CAG 生成框架，生成了单个行人更多的外观种类的图像，并通过损失函数的约束保障生成图像具有可靠的身份标签和外观标签。在跨外观行人重识别模型的训练中，外观多样性可以有效地促进模型在跨外观行人检索的性能。不仅如此，CAG 生成框架使用其他行人图像的外观特征编码对行人图像进行重

构，这意味着生成的行人重识别数据集中拥有具有相同外观标签的不同行人图像，即数据集中存在外观极度相似的不同行人，相似外观的行人图像给跨外观行人重识别模型的检索带来了极大的难度。

在行人重识别模型的训练中，模型通过随机采样算法将数据集中的行人图像样本分成不同批次进行优化。本文在第三章中介绍了传统的采样算法和随机外观采样算法。本章节中对行人重识别算法的随机采样算法进行调整。本文提出一种相同外观采样算法（Random same-appearance Sampling，RSAS），也就是说，本文根据行人的外观标签检索其他行人的行人图像，将具有相同外观标签的生成行人图像采样到同一个批次中。RSAS 策略生成的行人图像批次如图4.4所示。该策略可以更有效地挖掘跨外观行人检索中的最难样本，并通过损失函数的限制，显著降低外观相似性对跨外观行人检索的影响。同时，每个训练批次不仅具有外观多样性，也保证了特定外观标签的行人多样性，从而提升模型对外观变化的适应能力，促进模型的识别。

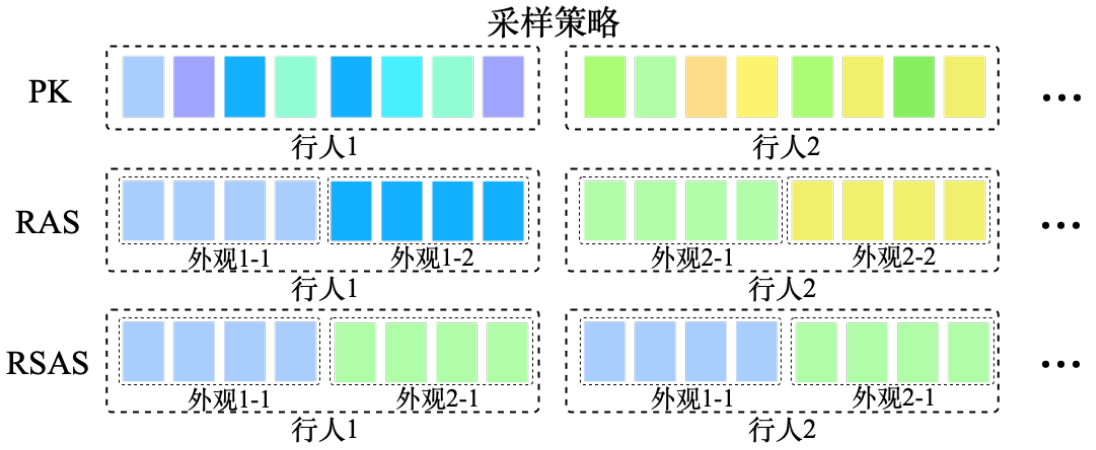


图 4.4 RSAS 采样策略与其他采样策略生成的训练批次对比

第三节 生成网络解耦外观特征和行人特征的理论分析

行人图像 $X \in \mathbb{R}^{H\times W\times C}$ 的信息包含身份信息 I_{id} 和外观信息 I_{app}：$I(X) = I_{id} + I_{app} + \epsilon$。生成模型学习两个编码器 E_i 和 E_a，分别提取 f_i 和 f_a。信息论上希望：

1. 最大化 $I(f_i;Y)$：身份特征与标签高度相关。
2. 最小化 $I(f_i;f_a)$：身份与外观特征互信息为零（解耦核心）。

3. 最小化重构误差 $minH(X|f_i,f_a)$，即 f_i,f_a 共同包含 X 的绝大部分有效信息。

身份损失（分类损失）优化第一个目标，迫使 f_i 包含判别信息。**外观损失、重构损失和对抗损失**服务于第三个目标，并间接促进第二个目标：若 f_i 已包含身份，为完美重构图像，生成器迫使 E_a 捕捉剩余变化因素（外观、背景等）。这种基于信息瓶颈的竞争与合作实现了解耦。

在表示学习中的理论中，该过程可视作多玩家博弈：

- **生成器** G：利用 E_i 和 E_a 生成图像。
- **身份提取器** E_i：希望仅提供核心身份信息，将其他变化推给 E_a。
- **外观提取器** E_a：捕获所有与身份无关的视觉模式。

博弈的纳什均衡点对应于 f_i 与 f_a 在语义上完全解耦。这带来了可控生成能力：固定一个人的 f_i，替换另一个人的 f_a，可以生成“同一个人穿别人的衣服”，这是解耦成功的直接证明。

CAG 模型的构成主要包括以下几部分：

- **核心组件**：预训练 ReID 模型提取身份特征 f_i，人体语义分割模型选定外观相关的区域，结合金字塔编码器提取行人的外观特征 f_a。
- **生成过程**：以身份编码 f_i 和外观编码 f_a 为条件，通过 GAN 网络生成新图像。模型需隐式理解哪些特征是身份核心，哪些可变换。
- **损失函数**：同时使用**身份损失**（保证生成图像与原始图像身份一致）和**像素级重构损失**保证外观服从指定编码。

为了探索本文提出的 CAG 生成框架生成的行人图像能够稳定改善而非扰乱判别边界的原因，我们从数据增强的正则化效应和特征空间的流形平滑两个角度给出解释。（1）数据增强作为隐式正则化。我们提出的生成框架在重组外观与体型编码时，引入了外观编码的随机扰动（如噪声注入与插值），使得同一身份对应外观变化样本。从优化角度看，这相当于在参数更新时引入了对身份特征对外观变化的雅可比矩阵的约束，迫使模型在“外观扰动”方向上具有更平坦的损失景观，形成隐式的平滑正则化，从而避免分类器在训练分布边缘产生过于陡峭的决策面。

（2）提升的上限与风险。生成增强的上限取决于生成样本对“真实外观分布”的覆盖度。当生成器无法覆盖某种极端外观组合时，该方向上的判别边界仍由真实样本决定，生成增强不造成改善也不造成损害。风险在于：当生成质

量下降（如纹理模糊）时，劣质样本的特征可能落入选定的身份特征聚类边缘，从而模糊类内分布，表现为类内距离增大。为此，我们通过对抗损失和身份保持损失双重约束，将生成失真控制在特征空间中对判别任务影响较小的维度上。另外，本文在将行人图像解耦成外观特征和体型特征时，对于行人图像的解耦粒度较大，因此行人图像较少发生肢体错误的情况。

第四节 实验评估及分析

本节将介绍算法相关的实验细节，包括实验设置、消融实验及对比实验结果分析等。

4.4.1 实验设置和训练细节

本章中使用的数据集选取了最广泛使用的跨外观行人重识别数据集，分别为 NKUP+、PRCC 和 DeepChange。对于跨外观行人数据集来说，PRCC 可以通过摄像头标签获取简单的外观标签，通过选取不同的摄像头下的行人图像，可以完成同外观和跨外观行人检索的测试。对于 NKUP+ 数据集来说，本文根据数据集的划分情况直接获取同外观和跨外观的行人检索的子集，对于 DeepChange 数据集来说，所有的候选集行人图像不具有外观标签，因此跨外观行人重识别算法使用全部的候选集行人图像进行测试。

网络输入的行人图像经过统一的预处理：图像大小缩放至 [256128]，使用均值 [0.4850.4560.406] 和标准差 [0.2290.2240.225] 对行人图像进行归一化。通过水平翻转、随机裁剪、采集擦除等策略对行人图像进行随机处理以消除模型的过拟合。模型的学习率从 3.5×10^{-6} 初始化，经过上升再逐渐下降使模型逐步收敛。

对于生成框架 CAG 来说，其外观特征编码器 E_a 可以使用传统的行人重识别网络，本文中采用 Densenet-121 骨干网提取外观特征编码。E_a 引入了最大池化层，代替之前的全局平均池化层和全连接层，输出维度为 $2048 \times 4 \times 1$ 的外观特征编码。而行人特征编码器 E_i 由四个卷积层和四个残差块构成。生成器 G 与编码器的特征结构相反，由四个残差块和四个卷积层组成，并且在每个残差块都引入了两个自适应样本归一化层。判别器 D 和 PatchGAN 的结构相同，在三个不同尺度上对生成图像进行分辨。

CAG 输出的行人图像带有相应的标签，包括身份标签和外观标签。像素级

表 4.3 生成框架 CAG 模型中的损失函数消融实验

方法	外观损失	身份损失	编码损失	NKUP+				PRCC				DeepChange	
				同外观		跨外观		同外观		跨外观		测试集	
				R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
1	×	×	×	81.0	65.9	20.2	9.6	97.2	95.3	35.7	35.5	51.5	9.2
2	×	✓	×	82.7	67.2	20.9	9.7	98.5	96.6	35.9	36.1	52.7	11.6
3	×	×	✓	85.4	70.8	25.7	11.1	99.3	99.0	56.5	57.0	54.9	18.2
4	×	✓	✓	88.9	73.0	27.5	13.7	99.8	99.1	61.8	58.6	59.5	22.3
5	✓	✓	✓	89.3	74.1	28.4	14.2	99.9	99.1	63.0	59.3	-	-
6	数据增强对比实验			86.2	72.1	24.1	11.0	99.6	99.0	59.3	57.4	57.3	19.6

和图像级的多重监督确保了合成行人图像的标签可靠性。与之前使用标签平滑正则化参与行人重识别模型训练的生成框架不同，CAG 模型生成的行人图像被用作额外的图像来指导行人重识别模型的训练。

4.4.2 消融实验

在本小节中，本文在 NKUP+、PRCC 和 DeepChange 三个数据集上组织消融实验，验证本文提出的方法中的关键创新点的效果。主要是外观特征编码和行人特征编码的编码损失、基于标签的外观损失和身份损失。总计来看，对比没有不包括对应损失的基准生成网络生成的行人图像（方法 1），本文引入 CAG 生成的行人图像（方法 5）在三个行人数据集上都取得了显著的性能提升。这说明了本文提出的 CAG 生成模型使用的损失函数很好地促进了生成的行人图像的质量，并为生成图像赋予了可靠的标签，这些包含准确标签的生成行人图像对模型的训练是有促进作用的。基于生成框架，本文在行人重识别模型的训练集中额外添加了一些行人图像。为了控制训练集图像数量给模型训练带来的影响，本文采用了包括复制和翻转在内的传统数据增强方法，构建了数量相同的训练集。其对应的实验如表格4.3的方法 6。由于行人图像没有外观标签，因此本文未对 DeepChange 数据集的生成图像应用外观损失。

本模型在三个数据集上的消融实验结果如表格4.3所示，与普通的数据增强数据集（方法 6）相比，引入 CAG 生成的行人图像后，跨外观行人重识别模型的检索性能有了显著提升。

编码损失的效果：从表格4.3的消融实验结果来看，我们可以发现编码损失极大地促进了检索性能的提升。对比方法 1、方法 3 和方法 6 的结果可知，在引入编码损失之前，即便引入了对应方法生成的行人图像，其检索性能不及方法 6。而在添加了编码损失之后，模型的检索性能得到了大幅提高，这一现象在三个数据集中都有明显体现。与方法 1 相比，方法 3 中的编码损失显著提高了

NKUP+ 数据集中相同外观子集的准确率和平均精度均值。编码损失的作用在于确保编码器能够有效地分离外观特征和身份特征，并使两个编码器所提取的身份特征编码和外观特征编码保持一致。也就是说，编码损失保障了外观编码和身份编码的鲁棒性。

身份损失和外观损失的效果：通过对比表格4.3中的方法 1 和方法 2，我们可以发现，对身份编码施加身份损失的监督，能够降低不可靠标签对行人重识别（Re-ID）模型的影响。同样的，对比表格4.3中的方法 4 和方法 5，我们可以看到，对外观特征编码施加外观损失的监督，同样有助于提升模型的性能。

在缺少编码损失的情况下，身份标签和外观标签对生成框架的监督在图像质量方面并没有显著的促进作用。不过，从方法 3 和方法 5 的结果来看，我们可以推断出，身份损失和外观损失在行人图像的特征解耦方面依然有效。其主要原因在于，在缺乏图像级监督的情况下，CAG 中的身份编码和外观编码无法与行人图像的标签对应起来。也就是说，生成图像的标签不可靠，这会干扰模型的训练。而通过多重监督，模型的检索性能得到了大幅提升，并且这一提升在三个数据集中都清晰可见。

4.4.3 SOTA 模型的对比实验

将本文提出的 CAG 方法与其他和行人重识别相关的生成框架进行了比较。这些方法在三个常用的跨外观行人数据集上的实验结果，可在表格4.4 中查看。

通过引入由生成模型生成的行人图像，M2Net 能够被引导去提取更具鲁棒性的特征。根据实验结果，由 CAG 生成的带有外观标签的跨外观行人图像，能够更有效地提升跨外观行人重识别的性能，而对于相同外观的行人重识别任务，其性能提升并不明显。原因在于，对行人图像外观的增强会导致模型倾向于选择具有外观差异的行人图像。由于受设备和光线的影响，在相同外观下的识别效果会受到限制。对于早期的方法，我们可以观察到它们对模型有负面反馈作用，这主要是因为这些方法通常针对的是域差距问题，行人图像缺乏有效的监督，并且一般对训练不足的模型才有促进作用。M2Net 这类针对跨外观问题的模型，很难获取行人特征。DGNet++ 在跨域的基础上使用行人身份进行监控，并且很好地适配了像 NKUP+ 这样的采集自多个监控设备、采集于长时间段内的数据集。CAG 通过监督外观标签和行人标签来提高生成图像的质量，并通过对模型的迭代训练，提取出跨外观行人图像的共同特征。

我们可以看到，本文提出的 CAG 方法优于所有对比方法。与取得最佳效果

表 4.4 不同生成框架生成的行人图像引入行人重识别模型的对比模型，最好结果使用**加粗**标注以及次好结果使用下划线 标注

Re-ID	Method	NKUP+				PRCC				DeepChange	
		同外观		跨外观		同外观		跨外观		测试集	
		R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
M2Net	No generation framework	86.2	72.3	24.0	11.0	99.5	99.1	59.3	57.7	57.2	19.6
	SPGAN[137]	85.1	71.4	23.8	9.8	99.0	98.2	51.8	48.7	53.9	17.0
	PTGAN[94]	85.6	71.5	24.0	10.5	98.3	97.8	53.8	49.9	53.7	16.8
	DGNet[138]	86.4	72.0	24.5	10.9	99.6	98.0	59.8	56.4	58.5	21.0
	StyleGAN+[139]	86.8	72.1	24.7	11.0	99.6	98.1	58.4	55.5	57.8	20.5
	DGNet++[40]	87.1	72.5	25.2	11.5	99.7	98.6	58.5	55.9	58.3	20.1
	FSLSD-HiRes[140]	86.1	72.1	24.3	10.7	99.3	98.0	56.7	54.0	56.2	18.4
	CAG(Ours)	**89.3**	**74.1**	**28.4**	**14.2**	**99.9**	**99.1**	**63.0**	**59.3**	**59.5**	**22.3**

表 4.5 基于不同数据增强方法的行人重识别模型的对比实验，最好结果**加粗**表示以及次好结果下划线 表示

数据增强方法	行人重识别模型	NKUP+				PRCC				DeepChange	
		同外观		跨外观		同外观		跨外观		测试集	
		R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
×	MGN[20]	81.6	69.3	15.4	9.0	99.5	98.4	33.8	35.9	25.4	9.8
	ABD-Net[25]	81.6	67.7	17.6	9.0	98.6	98.1	41.4	42.8	24.2	8.5
	Trans-ReID[31]	81.1	69.6	19.7	10.9	99.6	98.7	44.6	46.5	35.9	14.4
	M2Net(Resnet50)	84.8	70.6	24.6	11.3	99.5	98.2	57.2	52.6	55.2	19.2
	M2Net(Densenet121)	86.2	72.3	24.0	11.0	99.5	99.1	59.3	57.7	57.2	19.6
✓	Pos-Neg[141]	-	-	-	-	99.6	98.7	54.9	**65.8**	-	-
	CCFA[142]	-	-	-	-	99.6	98.7	61.2	58.4	-	-
CAG	MGN[20]	82.2	70.1	16.9	9.2	99.5	98.4	35.3	36.6	27.0	10.7
	ABD-Net[25]	83.0	69.2	19.0	9.8	99.0	98.3	42.9	43.4	26.2	9.9
	Trans-ReID[31]	83.0	72.6	21.2	13.1	99.6	98.9	46.9	48.1	37.2	16.1
	M2Net (Resnet50)	86.8	72.9	28.0	13.9	99.5	98.7	59.8	55.0	57.2	20.2
	M2Net (Densenet121)	**89.3**	**74.1**	**28.4**	**14.2**	99.7	**99.1**	**63.0**	61.5	**59.5**	**22.3**

的 DGNet++ 相比，在三个常见的跨外观数据集的跨外观子集上，CAG 生成的行人图像的检索精度提升了 3.2%、4.5%、1.2%，平均精度均值提升了 2.7%、3.4%、2.2%。CAG 生成模型通过身份标签和外观标签的监督，将行人图像中与身份和外观紧密相关的编码特征进行了解耦，从而提升了交换外观特征编码后生成的行人图像时的质量。

此外，在表格4.5 中，本文将最先进的方法以及进行了数据增强的 M2Net，在 NKUP+、PRCC 和 DeepChange 数据集上进行了比较。在未进行数据增强的情况下，其他方法中的 Trans-ReID[31]在 NKUP+/PRCC/DeepChange 的跨外观子集上取得了最佳结果。综合来看，本文提出的采用两种骨干网的 M2Net 模型，性能均优于所有对比方法。

此外，本文将针对行人图像外观多样性的数据增强方法应用到了几种最先进方法的训练过程中，结果表明，所有方法在跨外观行人重识别的性能上都有

了显著提升。对于最新的数据增强方法，本文引用了原始论文中的结果。然而，我们也注意到，Pos-Neg[141] 在 PRCC 数据集上的平均精度均值方面比本文的方法更具优势。尽管如此，与 Pos-Neg[141] 相比，本文在精度方面具有更明显的优势。在跨外观行人重识别中，这一优势通过诸如重排序等后续处理过程能带来更多益处，甚至可以基于首次检索的结果进行第二次检索，这意味着行人检索的精度比平均精度均值更有意义。综合来说，从结果的数值差异来看，引入 CAG 生成的行人图像的 M2Net 优于所有对比方法。

4.4.4 可视化结果及分析



图 4.5 经典行人重识别方法联合 CAG 生成图训练的检索结果

从图4.5中基准模型的可视化结果来看，我们很容易观察到检索结果都是外观相似的行人图像。这表明以其为代表的大部分模型更加关注颜色或纹理等与外观相关的信息。对于在最先进模型中表现最佳的 Trans-ReID，其检索结果显示特征图包含了对外观变化具有鲁棒性的信息，比如发型或体型。本文使用的 M2Net 模型的可视化结果，其检索性能最为突出。其原因在于，跨外观损失引导模型减少了对外观的关注。

在将 CAG 生成框架生成的跨外观图像添加到模型的训练阶段后，可以看到模型能够检索到外观变化显著的正确目标图像。这些结果表明，对外观的数据增强能够有效地提升模型的跨外观检索性能。此外，模型还能够检索到外观非常相似的行人图像。CAG 是根据外观编码而非随机编码生成行人图像的，所以训练集中存在许多外观相似但身份（ID）标签不一致的行人图像。结合跨外观

损失的约束，与相同身份、不同外观的特征距离相比，不同身份、相同外观的特征距离被拉得更远。综上所述，CAG 生成的行人图像能够提升多种行人重识别（Re-ID）模型的性能，尤其是对于采用了 MA 损失的 M2Net 而言效果更为显著。

第五节 本章小结

本章针对跨外观行人重识别中面临的数据外观多样性不足、分布差异显著等关键问题，提出了基于生成对抗网络的跨外观图像生成框架（CAG）。通过解耦行人图像的外观特征与身份特征，并结合多重监督损失函数，CAG 能够生成外观多样、标签可靠的行人图像，有效提升了模型在跨外观场景下的泛化能力和识别性能。在方法设计上，CAG 通过外观编码器和身份编码器分别提取与外观相关和身份相关的特征，利用生成器实现自重构和交叉特征重构，生成具有新外观的同一行人图像。损失函数方面，除了重构损失和对抗损失外，还引入了基于身份和外观标签的监督损失以及特征编码一致性损失，确保了生成图像的质量和标签可靠性。此外，针对生成数据的特点，提出了相同外观采样策略（RSAS），进一步优化了模型训练过程。实验结果表明，CAG 生成的行人图像能够显著提升多种行人重识别模型在 NKUP+、PRCC 和 DeepChange 数据集上的性能，特别是在跨外观检索任务中表现突出。消融实验验证了各项损失函数的有效性，尤其是特征编码损失和标签监督损失对性能提升贡献显著。与现有生成方法相比，CAG 在多个指标上均达到了最优水平。定量实验表明，生成增强数据可稳定提升多种基线的跨外观检索精度；可视化分析亦证实生成图像具备多样化的外观表现，有效填补了真实数据中的外观空缺。

尽管如此，我们仍发现部分生成图像存在纹理模糊、肢体错位等问题，尤其在极端姿态或遮挡条件下，生成质量会明显下降，这可能为训练引入噪声。此外，当前生成过程未显式建模视角变化，而视角是导致外观在图像层面呈现差异的另一关键因素。行人同一套衣饰在正面、侧面和背面视角下可能呈现截然不同的视觉模式，若仅靠生成外观变化而不区分视角差异，模型易将视角引起的外观变化误判为身份变化。这提示我们，除了特征表达优化和数据扩充外，还需从训练策略层面引入视角感知的约束，以进一步提升模型对视角稳健性。这正是第五章研究的核心内容。

第五章　基于多视角的跨外观行人重识别

前两章分别从特征表达和数据增强两个维度削弱了模型对外观的依赖，但一个重要扰动源仍未得到显式建模——视角变化。在实际监控系统中，同一行人常被不同朝向的摄像机捕获，其图像在轮廓、姿态、可见部位等方面差异显著，这些视角引起的外观改变极易混淆身份判别。视角的差异性将导致行人图像的轮廓特征产生显著性变化如正面视角下，行人图像往往包含细节纹理特征，因此侧面视角和背后视角的特征差异性十分显著。我们发现，即便是经过第三章采样策略优化并利用第四章生成数据训练的模型，在跨视角场景下性能仍出现明显衰减，说明模型尚未学会将“视角导致的变化”与“身份导致的变化”解耦。因此，有必要在训练策略层面引入视角相关的约束与引导，使模型能够利用视角信息作为辅助监督，学习视角不变的身份表征。

本章提出一种基于相近视角线索的跨外观行人重识别方法。核心思想是：在训练过程中，利用视角标签将图像划分为正面、侧面、背后等粗粒度类别，并通过设计跨视角损失函数，拉近同一身份在不同视角下的特征分布，同时配合视角预测任务作为正则化，促使模型在提取特征时显式地感知并补偿视角差异。与简单增加视角分类分支不同，我们特别引入了视角软标签机制和视角正则化损失，以处理监控场景中视角的连续变化与边界模糊问题。该方法本质上是在训练策略上增加了“视角不变性”这一归纳偏置，与第三章的表示学习和第四章的数据增强形成互补：前者决定模型如何学习，中者决定模型从何学习，而本章决定模型在学习过程中接受何种结构性约束。三者构成“表征信息—数据—训练目标”的协同优化体系，共同服务于“降低模型对外观依赖、提升身份不变特征表达能力”这一核心目标。

第一节　引言

随着安防需求和技术的发展，监控网络系统作为一种先进和强大的智能安防技术解决方案在多个场景中发挥着巨大的作用。例如公安的天眼系统覆盖了多个地域和区域，密集布置在在人员密集的公共场合和主要街道上。大量的监控摄像头必定会获取多个视角的行人图像，视角的变化会导致行人图像的特征

发生剧烈的变化。同时，行人数据集和真实场景中可能都存在不同视角的行人图像的数量不一致的问题，导致模型对视角变化的泛化能力不足，降低模型性能。为了提升模型对视角变化的适应能力，我们选择了残差扩散模型，学习不同视角的行人图像的差异，进而生成行人的其他视角图像，以此来引导模型学习不同视角的行人特征。

行人图像的视角变化是行人重识别检索需要克服的难点之一。研究者们在训练中引入新的视角标签，设计与视角有关的损失函数和分类器充分利用视角标签。一些研究者们聚焦于对视角变化鲁棒的特征，利用姿态估计或者注意力机制等方法提取模型的细粒度特征，将行人图像进行分块从而组合行人的局部特征，也是对抗视角变化的的一种重要策略。为了突破行人图像视角的局限性，在摄像头数量有限的行人数据集中，研究者们试图通过数据增强方法来提升数据集的质量。早期的研究者们通过旋转、仿射变换等简单的方法获取行人的多视角图像，然而这对行人图像视角多样性的提升是有限的。逐渐地，研究者们通过生成对抗网络和 3D 引擎建模来生成不同风格和不同视角的行人图像，进而缓解跨摄像头下的特征差异。如图5.1所示是 NKUP+ 行人数据集中不同视角的行人图像的示例。



图 5.1　NKUP+ 数据集中行人图像的视角差异示例

为了解决上述问题，本文探索了视角对跨外观行人重识别的影响。首先，本文引入了三个主要的视角来表示行人图像的方向，通过人工标注视角标签对模型进行训练，模型预测行人图像的视角伪标签。本文引入行人的四个跨视角特

征对齐，利用对抗学习约束跨视角的特征分布，建模全局跨视角关系。

根据实际情况中监控图像的设置的随机性，行人图像的方向与三个主要方向可能发生重叠，因此本文使用软间隔来最终定义行人图像的方向，并通过行人图像的视角相似性来定义相近视角和相反视角的不同网络分支，分别提取行人图像的特征表示。通过约束模型视角差异和身份差异的特征距离；同时结合外观差异和身份差异的特征距离，提升模型对外观变化和视角变化的鲁棒性，提高模型对于跨外观行人识别的性能。

第二节 算法设计与实现

为了解决跨外观行人重识别中的跨视角检索的问题，本文提出了一个多视角下的 MVMA（Multi-view Multi-appearance）网络。模型的网络结构如图5.2所示。首先本文引入了一个行人视角预测器预测行人图像的视角标签，模型将行人图像的视角分为三个类别，也就是说，第 i 张行人图像的预测视角标签 $v_i \in (1),(2),(3)$ 三种。模型将行人图像 $X_{RGB} \in \mathbb{R}^{H_1 \times W_1 \times C_1}$ 分别输入到两个卷积网络的分支中，第一个网络分支是全局分支（Global branch），我们采用前述介绍过的 Densenet121 作为骨干网提取行人图像的全局特征，第二个网络分支是局部分支（Local branch），模型采用经典的多层金字塔结构提取行人图像的局部特征。

行人图像的视角信息对于匹配策略的选择至关重要。对于视角预测网络，视角预测器采用一个轻量级卷积网络 ResNet-18 作为骨干网，本文利用人工标注的视角对模型进行训练，考虑到视角标注存在一定主观性和模糊性（例如“侧面”可能包含从 30° 到 60° 的范围），采用软标签进行训练，即对每个标注的标签进行标签平滑（Label Smoothing）策略。本文定义两种视角的对比情况：1) 视角相同或相近时，行人图像输入第一个全局分支，获取全局特征用于后续的模型训练和推理。根据视角的相似度度量，本文定义前面和前面、侧面和侧面、后面和后面以及前面和后面的三种视角定义为相同或相近视角；2）视角差异较大时，行人图像输入第二个局部特征分支，用于后续跨视角的行人图像匹配的训练和推理，本文定义前面和侧面、后面和侧面定义为视角差异大。

MVMA 获取视角标签的的过程如公式5.1所示：

$$v_i = F_{view}(x_i, \Theta_{view}) \tag{5.1}$$

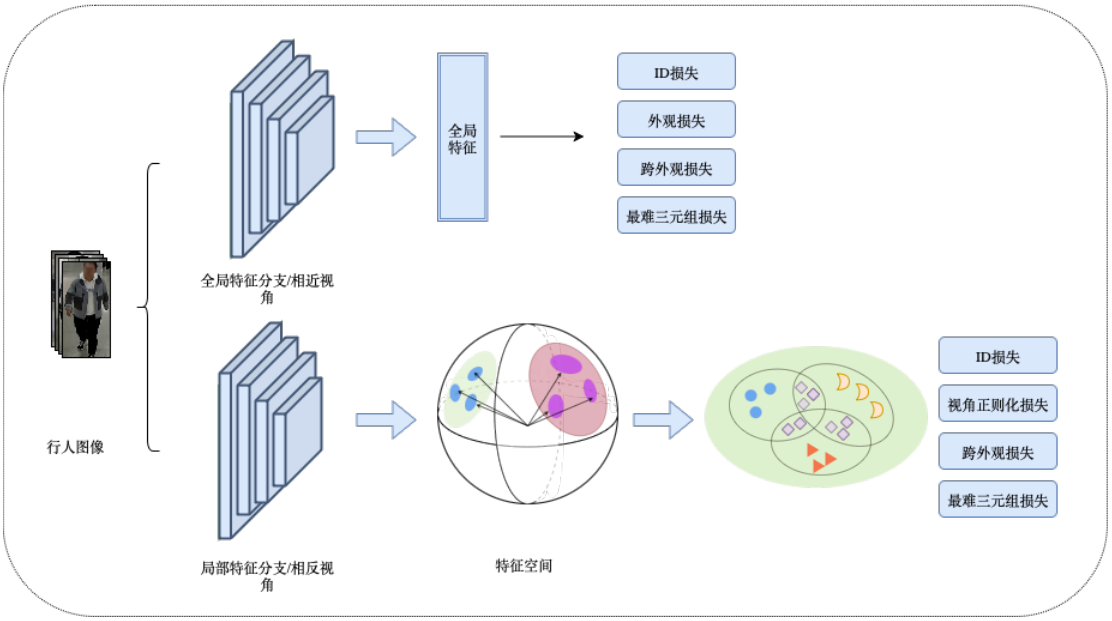


图 5.2 NMVMA 模型框架图

$$f_{global} = GeM(F_{global}(X_{RGB}, \Theta_{global})) \tag{5.2}$$

$$f_{local} = GeM(F_{local}(X_{RGB}, \Theta_{local})) \tag{5.3}$$

其中，Θ 代表对应网络的参数，F_{global} 和 F_{local} 是两个并行的行人特征提取网络，GeM 代表网络的池化层即广义平均池化（Generalized Mean Pooling）。两个特征提取分支获取行人图像的两种特征以后，模型使用局部特征和全局特征共同引导模型引导模型的训练和行人检索。

$$f_{Conbine} = f_{global} f_{local} \tag{5.4}$$

第三节 MVMA 网络的损失函数设计

为了应对模型中复杂的外观变化，本文保留了第三章中 M2Net 模型提出的随机外观采样策略以及针对跨外观行人变化的跨外观损失，其定义以及对模型

的影响本文不再赘述。

同样的，为了应对模型的视角差异，模型优化目标之一是提升算法对视角差异的适应性，也就是说，模型期望同一行人跨视角的行人图像的特征距离小于不同行人相似视角和相似外观的特征距离，因此对具有有视角差异的行人图像提取的全局特征和局部特征进行跨视角的损失约束，即使用基于三元组损失改造跨视角损失（Cross-View Loss, CV loss）引导模型的训练。具体来说，本文对批次中的每个行人 p，遍历其 A 种外观，使用不同外观中相似视角的行人图像特征距离为标准，限制跨外观情况下跨视角的行人图像与锚点图像的特征距离，从而使算法提取的全局特征与外观的关联性降低，即对视角变化鲁棒的行人特征。本文延续使用欧式距离 D 作为特征度量的方式，计算数据集的跨外观损失的公式如3.9所示：

$$\mathcal{L}_{CV} = \overbrace{\sum_{p=1}^{P}\sum_{k=1}^{K}}^{\text{全部行人图像}} [\beta + \overbrace{\sum_{k'=1,\ldots,K,v(pk,pk')=0}^{K} D(f_\Theta(x_p^k), f_\Theta(x_p^{k'}))}^{\text{跨视角正样本}} - \overbrace{\sum_{k'=1,\ldots,K,p'\neq p,v(pk,p'k')=1}^{K} D(f_\Theta(x_p^k), f_\Theta(x_{p'}^{k'}))}^{\text{同视角负样本}}]_+ \tag{5.5}$$

Softmax 函数预测行人图像的类别时，是将输入特征 x 转换成一个概率分布，其中识别成 y 的概率如公式5.6所示。

$$q(y) = \frac{e^{W_y^T x}}{\sum_{j=1}^{K} e^{W_j^T x}} \tag{5.6}$$

其中，K 表示行人身份类别的数量，W_y 是对应身份 y 的权重向量。

同时，本文关注到在具有视角差异的行人图像中，行人的轮廓形状和衣着外观均会发生显著的变化。但是，研究者发现行人下半身的轮廓尤其是腿部的局部特征对于视角变化具有较强的适应性，使用局部特征结合行人的全局特征，并提高局部特征对模型训练和推理的影响，是应对视角变化的有效策略。因此本文基于 Softmax 分类函数的启发，使用正则化约束同一个行人不同视角的行人图像的局部特征之间的相似性，拉近其距离行人图像身份中心的距离，其公式如5.7所示。

$$\mathcal{L}_R = \sum_{k=1}^{K}\sum_{v=1}^{V}\frac{W_k^T \cdot U_{kv}}{\|W_k\| \cdot \|U_{kv}\|} \tag{5.7}$$

其中，K 表示行人身份类别的数量，v 表示模型预测的行人图像的视角标签，W_k 是第 k 个身份中心的权重向量，U_{kv} 是第 k 个身份的第 v 个视角的下的中心权重向量。为了验证 $\mathcal{L}_R$ 对类内视角特征距离的影响，我们选取了部分行人图像进行了 t-SNE 降维可视化。图5.4分别展示了未施加与施加该损失时的特征分布。未施加 $\mathcal{L}_R$ 时，同一身份的前、侧、后视角特征分别形成三个可辨的子簇（红、青、黄三色分别代表三个身份，不同标记形状代表前、侧、后视角。施加后，同一身份的视角子簇趋于融合，特征分布收敛为单一的紧凑簇群，视角导致的内部差异被显著降低。这印证了其对于视角变化在类内特征空间的影响，从而验证了其作为身份不变性正则项的理论有效性与实践合理性。

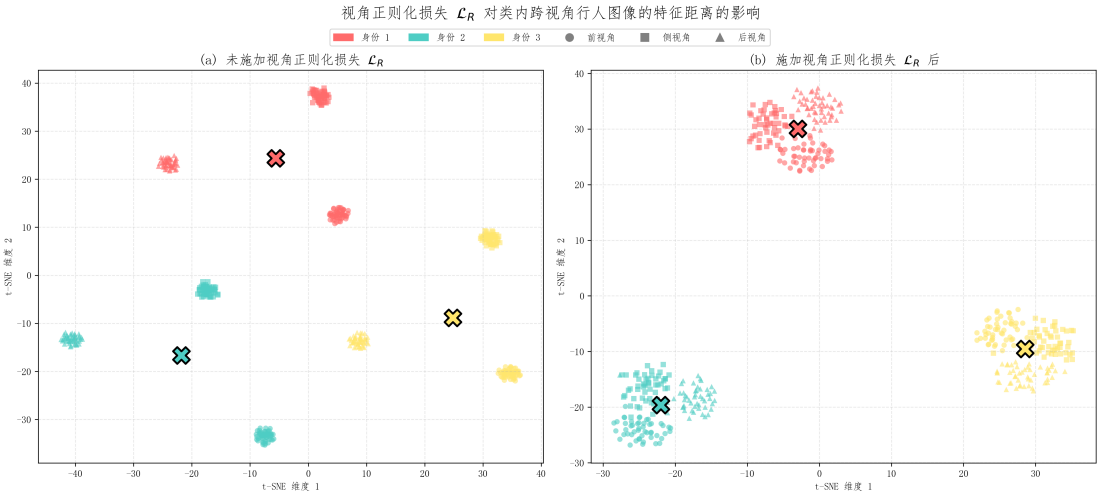


图 5.3 视角正则化对行人特征的影响

最终，本文通过使用特征度量的最难三元组损失、跨外观损失和跨视角损失对全局特征进行约束，使用正则化约束对联合使用身份标签和外观标签的分类交叉熵损失共同训练 MVMA 模型。最终，模型使用的总体损失函数定义如5.8所示：

$$\mathcal{L}_{Total} = \mathcal{L}_{ID} + \mathcal{L}_{TriHard} + \lambda_1\mathcal{L}_{CV} + \lambda_2\mathcal{L}_R \tag{5.8}$$

其中，$\mathcal{L}_{ID}$ 是基于身份标签的交叉熵函数，其定义与 $\mathcal{L}_{CE}$ 相同。λ_1 和 λ_2 是模型使用的超参数，是为了平衡两种损失函数的权重已达到模型在多种测试下的最优水平，超参数设置的相关实验会在下一节中具体描述。

第四节 实验评估及分析

本节将介绍算法相关的实验细节，包括实验设置、数据集选择、评测协议、消融实验及对比实验结果分析等。

5.4.1 实验设置和训练细节

本章中使用的数据集选取了最广泛使用的行人重识别数据集，具体为和常用的跨外观行人重识别数据集, 即 NKUP+、PRCC 和 DeepChange。以上数据集的详细信息和属性可参考本文的第二章内容。

对于跨外观行人数据集来说，PRCC 可以通过摄像头标签获取简单的外观标签，通过选取不同的摄像头下的行人图像，可以完成同外观和跨外观行人检索的测试。对于 NKUP+ 数据集来说，本文根据数据集的划分情况直接获取同外观和跨外观的行人检索的子集，对于 DeepChange 数据集来说，所有的候选集行人图像不具有外观标签，因此跨外观行人重识别算法使用全部的候选集行人图像进行测试。网络输入的行人图像经过统一的预处理：图像大小缩放至 [256128]，使用均值 [0.4850.4560.406] 和标准差 [0.2290.2240.225] 对行人图像进行归一化。通过水平翻转、随机裁剪、采集擦除等策略对行人图像进行随机处理以消除模型的过拟合。模型的学习率从 3.5×10^{-6} 初始化，经过上升再逐渐下降使模型逐步收敛。

文章采用的视角预测网络采用在经典的 Market1501 和 DukeMTMC 上标注的视角数据进行训练的视角预测网络[143]来预测行人图像的视角以进行模型后续训练和推理的依据。模型采用外观批次采样策略（RAS），不引入合成的行人图像这有利于最难三元组损失在批次内构造足够的有效的三元组样本。模型的识别部分训练采用 Adam 优化器，并配合热身策略，模型热启动在前十次进行，模型的学习率从 3×10^{-5} 线性增长到 3×10^{-4}，并采用余步进衰减调度，学习率的衰减系数为 0.1，在模型训练的第 50、100、150 个轮次进行衰减，模型训练总计 180 个轮次，并在测试集上记录 Rank-1、mAP 等指标以评估模型的识别性能。

表 5.1 基于 NKUP+ 数据集下参数 λ_1 和 λ_2 的平衡实验

λ		同外观子集		跨外观子集	
λ_1	λ_2	R-1	R-10	R-1	R-10
0.1	0.1	82.8	71.0	25.2	12.4
	0.2	83.0	71.4	24.9	12.5
	0.5	84.7	73.6	26.3	13.1
	0.8	84.5	72.9	26.0	12.6
	1.0	84.6	72.4	25.8	12.6
0.2	0.1	83.3	71.2	26.7	12.6
	0.2	84.1	72.0	26.2	13.1
	0.5	85.2	71.8	27.4	13.9
	0.8	84.8	73.1	25.4	14.5
	1.0	85.0	73.2	25.7	14.3
0.5	0.1	85.3	72.6	26.2	14.0
	0.2	85.7	72.8	27.3	14.7
	0.5	86.3	73.2	29.2	15.2
	0.8	87.1	73.0	29.3	16.6
	1.0	86.2	73.1	29.0	17.2
0.8	0.1	86.5	72.9	29.2	16.9
	0.2	86.9	73.6	29.3	17.3
	0.5	88.7	**74.9**	**33.7**	**19.3**
	0.8	87.1	73.4	31.2	18.2
	1.0	87.0	72.8	30.2	17.9
1.0	0.1	85.1	71.3	25.7	14.6
	0.2	85.7	72.0	29.4	17.5
	0.5	**89.1**	73.7	30.2	17.6
	0.8	88.8	72.6	28.3	16.1
	1.0	85.1	72.8	26.2	14.5

5.4.2 超参数预实验

在本章中，本文提出了相同行人特征的跨视角损失和对于相同行人的不同视角下特征的正则化约束，二者分别以增加不同行人相近视角的特征距离和拉近行人不同视角行人图像与同类别（相同行人）的特征距离两种方式引导模型的训练。在5.2中，本文进行了消融实验详细讨论了网络模型中不同损失函数对于网络模型的影响，为了平衡两个损失函数的约束效果，文中使用不同的参数组合进行了超参数预实验。对于网络模型定义的损失函数 $\mathcal{L}_{Total}$，本文对损失函数定义中的超参数 λ_1 和 λ_2 在 NKUP+ 数据集上进行了实验，其实验结果如表5.1所示:

表 5.2 MVMA 模型的消融实验

方法	视角标签	视角模糊	跨视角损失	NKUP+				PRCC				DeepChange	
				同外观		跨外观		同外观		跨外观		测试集	
				R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
1	×	×	×	78.3	62.3	18.5	7.8	96.2	94.7	36.9	32.2	47.4	9.6
2	×	✓	×	79.0	64.1	18.7	9.9	98.1	95.8	37.4	33.1	52.2	13.4
3	×	×	✓	83.7	69.8	24.7	13.1	99.3	99.0	58.3	54.1	59.9	24.7
4	×	✓	✓	86.1	72.7	28.4	16.9	99.7	99.0	62.6	59.8	62.5	27.3
5	✓	✓	✓	88.5	74.9	33.7	19.3	99.6	99.2	67.8	63.5	65.9	38.7

从实验结果，我们可以更加清晰地看到两种损失函数的作用。其中 λ_1 的值越大，则跨视角损失的权重越大。同样的，λ_2 的值越大，正则化约束的权重更大。两种损失互相配合，引导模型关注行人不同视角的特征，从而在相近视角下，更多地关注行人的体型特征，降低行人外观的影响。实验结果证明了 λ_1 的值更大时，模型总体的检索性能更加优越，但是仍需要正则化损失来引导模型提取的特征更具有判别性。对比所有结果，本文最终设置 $\lambda_1 = 0.8$ 和 $\lambda_2 = 0.5$。

5.4.3 消融实验

在本小节中，本文在 NKUP+、PRCC 和 DeepChange 三个数据集上组织消融实验，验证本章节中提出的方法中的关键创新点的效果。主要是关于行人图像的视角标签、视角模糊和视角损失。

在三个数据集上的消融实验结果如表格5.2所示，本消融实验通过系统性地增删 MVMA 模型中的三个关键组件——视角标签、视角模糊与跨视角损失，清晰地揭示了各组件在行人重识别任务中的相对重要性及其内在的协同效应。实验结果表明，跨视角损失是整个模型性能的基石，其贡献具有决定性意义。如表格所示，在未使用任何组件的基础模型（方法 1）上引入跨视角损失（方法 3），性能实现了质的飞跃，尤其是在最具挑战性的“跨外观”任务上：在 NKUP+ 和 PRCC 数据集上，跨外观检索的 Rank-1 准确率分别提升了 6.2% 和 21.4%。这一巨大增幅证明，该损失函数通过直接优化特征空间，有效拉近了同一行人在不同视角下的特征距离，从而显著增强了模型对抗衣着外观剧烈变化的鲁棒性。相比之下，视角模糊模块（方法 2）单独使用时仅带来小幅增益，但其核心价值在于与跨视角损失的协同能力。当两者结合（方法 4），在方法 3 的基础上，NKUP+ 跨外观任务的 Rank-1 和 mAP 指标分别进一步提升了 3.7% 和 3.8%，这表明视角模糊作为一种数据增强或特征正则化手段，通过缓解训练过程中的视角过拟合，为跨视角损失的优化创造了更稳定、更泛化的特征学习环境，二者构

成了强有力的互补关系。最终，整合了所有组件，尤其是引入真实视角标签的完整模型（方法 5），在所有设置下均达到了最优性能，这标志着从“隐含”地处理视角信息到“显式”地利用视角标签，模型获得了最全面的视角感知与解耦能力，确立了各组件层层递进、相辅相成的贡献层次。

该消融实验设计的另一精妙之处在于通过三个特性各异的数据集——NKUP+、PRCC 与 DeepChange，全面评估了 MVMA 模型的泛化能力与实用价值。从结果中可以观察到一种一致的改进趋势：无论数据集本身的难度与偏重如何，从方法 1 到方法 5 的每一次有效组件的添加，都带来了相应的性能提升，这强有力地证明了所提出组件的普适性。具体而言，在 PRCC 数据集上，模型在同外观性能的 Rank-1 指标从 96.2% 起步并最终趋于饱和（99.6%），表明该数据集在此任务上相对简单，模型潜力很快见顶；然而，其“跨外观”任务高达 30.9% 的绝对提升（从 36.9% 至 67.8%），则凸显了 MVMA 组件在应对巨大外观差异时的关键作用。更具说服力的是在大规模长期 ReID 数据集 DeepChange 上的表现，该数据集更贴近真实监控场景的复杂性与动态性。完整模型（方法 5）在此取得了 65.9% 的 Rank-1 与 38.7% 的 mAP，相较于基线分别有 18.5% 和 29.1% 的巨大提升，尤其是 mAP 指标的显著改善，说明模型不仅在识别首位命中率上表现优异，在整个检索列表的准确性与完整性上也有了质的飞跃。这一结果深刻表明，MVMA 模型所聚焦的视角不变性特征学习，正是解决长期、跨场景行人重识别核心挑战——即因时间推移、摄像头差异及环境变化所导致的巨大类内差异的有效途径，为其在真实世界安防应用中的部署提供了坚实的实验依据与巨大的实用潜力。

5.4.4 SOTA 模型的对比实验

将本文提出的 MVMA 方法与其他行人重识别进行了比较。这些方法在三个常用的跨外观行人数据集上的实验结果，可在表格5.3 中查看。

在表格5.3 中，本对比实验将提出的 MVMA 模型与多种先进的行人重识别模型在三个数据集上进行了全面比较，结果清晰地表明，无论是以 ResNet50 还是 Densenet121 为骨干网络，MVMA 模型在绝大多数指标上均取得了压倒性的领先优势，尤其是在最具实际挑战性的跨外观行人重识别的任务中。具体而言，在 NKUP+ 数据集的跨外观检索中，性能最佳的 MVMA(Densenet121) 的 Rank-1 达到了 33.7%，这显著超越了之前最好的方法 PN-GAN 和 SPReID，更是基础模型 PCB（9.3%）的三倍以上。在 PRCC 数据集的跨外观任务上，这一优势被进

表 5.3 不同行人重识别模型的对比实验，最好结果**加粗**表示以及次好结果下划线 表示

行人重识别模型	NKUP+				PRCC				DeepChange	
	同外观		跨外观		同外观		跨外观		测试集	
	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
PCB[19]	76.0	60.9	9.3	5.1	**99.8**	98.1	41.8	38.7	13.9	4.0
PCB+RPP[19]	79.5	67.0	16.2	10.7	99.7	98.7	41.6	37.9	15.9	4.4
MGN[20]	81.6	69.3	15.4	9.0	99.5	98.4	33.8	35.9	25.4	9.8
ABD-Net[25]	81.6	67.7	17.6	9.0	98.6	98.1	41.4	42.8	24.2	9.5
PN-GAN[144]	84.0	71.4	23.9	10.8	99.0	97.9	34.2	32.6	21.3	8.2
SPReID[145]	84.7	71.9	24.0	11.0	99.4	98.3	42.1	37.9	25.9	10.4
VA-reID[143]	82.2	70.1	21.9	9.2	99.6	98.0	40.8	37.2	27.0	10.7
VANet[146]	82.1	71.9	20.4	11.2	99.2	98.3	42.9	43.4	26.2	9.9
VDT[78]	83.7	72.0	21.3	11.2	99.5	98.4	47.8	44.5	35.2	10.8
SeCap[79]	82.9	72.0	21.7	11.9	99.4	98.5	48.2	44.9	37.9	12.1
SD-ReID[147]	83.0	72.7	21.8	12.4	99.5	98.5	48.3	45.2	37.4	11.9
MVMA(Resnet50)	85.7	71.4	29.4	16.2	99.4	98.9	61.0	58.9	62.2	28.1
MVMA(Densenet121)	**88.5**	**74.9**	**33.7**	**19.3**	99.6	**99.2**	**67.8**	**63.5**	**65.9**	**38.7**

一步放大，MVMA(Densenet121) 以 67.8% 的 Rank-1 准确率，将其他所有模型（最高为 VANet 的 42.9%）远远甩在身后。这种巨大优势的核心原因在于，对比模型如 PCB、MGN 等多侧重于通过部件模型或全局与局部特征融合来提升对同外观行人的判别能力，这在传统的同外观行人重识别任务（如 PRCC 同外观各项方法均超过 98%）中识别性能极为优越，这也跟 PRCC 数据集的同外观测试集中行人数量较少、识别难度较低有关，但它们普遍缺乏对行人视角、姿态等固有属性变化的显式建模和不变性学习。对比 VDT、SeCap 和 SD-ReID 三个基于空-地跨视角检索行人图像的方法，空-地协同的行人检索中，行人的外观特征提供的线索较少，模型对于外观线索的依赖性较低，因此外观特征对行人检索的干扰较低，模型在跨外观的行人图像检索中的效果较好。而 MVMA 模型通过其引入的视角模糊和跨视角损失等方法，直接致力于解耦外观特征与视角特征，强制模型学习到一种即使行人更换服装即跨外观的情况下也能依据其体型、步态等生物特征进行识别的强大表示[148-149]。这种面向行人身份本质而非外观表象的学习范式，是其在处理剧烈外观变化时表现卓越的根本原因，标志着模型设计思路从提升判别力向增强鲁棒性和不变性的重要转变。

实验结果的另一个关键洞察在于骨干网络的选择对模型性能的显著影响，以及 MVMA 框架在贴近真实的复杂场景中无与伦比的泛化能力。通过对比 MVMA(Resnet50) 和 MVMA(Densenet121) 两行数据可以发现，后者凭借其更密集的连接结构和更强的特征复用能力，在所有数据集的几乎所有指标上均实现

表 5.4 MVMA 模型引入 CAG 框架生成的行人图像的实验结果

行人重识别模型	NKUP+				PRCC				DeepChange	
	同外观		跨外观		同外观		跨外观		测试集	
	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP
MVMA(Resnet50)	85.7	71.4	29.4	16.2	99.4	98.9	61.0	58.9	62.2	28.1
MVMA(Res-CAG 图像)	86.2	73.6	32.1	18.0	99.4	99.0	64.3	60.4	63.5	30.1
MVMA(Densenet121)	88.5	74.9	33.7	19.3	99.6	99.2	67.8	63.5	65.9	38.7
MVMA(Dense-CAG 图像)	88.3	75.2	34.4	20.2	99.6	99.3	68.2	64.2	66.5	39.3

了进一步提升，尤其是在难度最高的 DeepChange 数据集上，mAP 从 28.1% 提升至 38.7%，取得了 10.6% 的绝对增长。这表明，一个更强大的特征提取器能够与 MVMA 的视角不变性学习机制产生积极的协同效应，从而提取出更具判别力和鲁棒性的身份特征。更重要的是，在 DeepChange 这个大规模、长期、跨季节的真实世界数据集上的测试结果，极具说服力地证明了 MVMA 模型的实用价值。该数据集模拟了安防监控中最为常见的长期追踪场景，充满了光照、季节、着装等复杂变化。在此，MVMA(Densenet121) 取得了 65.9% 的 Rank-1 和 38.7% 的 mAP，其性能不仅数倍于其他对比模型（例如，Rank-1 是 VA-reID 的 2.4 倍，mAP 是 ABD-Net 的 4 倍），而且其 mAP 相较于 Rank-1 的显著提升，表明模型不仅在检索到行人目标上有高准确率，在整个检索列表的全面性和准确性上同样优秀，这对于实际智能安防至关重要。综上所述，本对比实验不仅从横向比较上确立了 MVMA 模型的 SOTA 性能，更从纵向深度上揭示了其核心技术对于推动行人重识别技术走向实际应用、解决长期跨外观难题的重要作用。

5.4.5 引入 CAG 框架生成的行人图像

将本文提出的 CAG 生成框架生成的行人图像引入 MVMA 模型的训练阶段，并在三个常用的跨外观行人数据集上的实验结果，可在表格5.4 中查看。

在表格5.4 中可以看到，引入 CAG 框架生成的行人图像后，MVMA(Resnet50) 和 MVMA(Densenet121) 较未引入生成图像的方法均有所提升。尤其是在跨外观的子集上，MVMA(Res-CAG 图像) 在三个数据集上的 Rank-1 分别提升了 2.7%、3.3% 和 1.3%，而 mAP 分别提升了 1.8%、1.5% 和 2.0%；MVMA(Dense-CAG 图像) 在三个数据集上的 Rank-1 分别提升了 0.7%、0.4% 和 0.6%，而 mAP 分别提升了 0.9%、0.7% 和 0.6%。这一优越性主要归因于 CAG 生成式数据增强与前序特征学习框架的协同效应：第四章提出的跨外观图像生成方法通过解耦外观与体型编码，为训练集注入了大量“同一身份、迥异外观”的合成样本，使得

MVMA 在视角对齐学习过程中能够接触到更广泛的外观变异模式，从而学习到更本质的身份不变特征，而非对有限真实外观的过拟合。

5.4.6 可视化结果及分析

从图5.4中基准模型的可视化结果来看，本次可视化检索结果生动地展示了不同行人重识别模型在实际应用中的性能差异，为理解各模型的核心能力提供了直观依据。基准模型的检索效果不尽如人意，其返回的前列结果中存在大量错误匹配。这深刻地揭示了，仅依赖表观特征（如颜色、纹理）的模型极易受到衣着更换（跨外观）的干扰。当目标行人换上不同服装后，基准模型无法从本质身份特征上进行关联，从而导致检索失败，这凸显了早期模型在特征鲁棒性上的严重不足。M2Net 的检索结果中可能检索到了更多正确的行人图像，在排序上也有了极大的进步。这意味着，多模态的行人图像降低了外观对模型识别的干扰，但在一些困难的匹配中，模型很难检索到外观剧烈变化的结果。相比之下，引入视角损失的模型取得了显著进步。从可视化结果中可以清晰看到，该模型不仅能够成功检索到跨外观的同一行人，而且这些正确的匹配项往往与查询图像具有相似的人体姿态和摄像机视角。这一现象强有力地证明，视角损失函数通过显式地约束模型学习视角不变特征，使其能够穿透外观变化的迷雾，捕捉到更为本质的人体结构、轮廓和姿态等生物力学特征。模型学会了忽略外观的差异，转而从行人的体型和行走姿态等稳定特征中进行身份判别，从而在跨外观场景下实现了精准检索。

这表明，单纯增加模型的复杂度并非总是最优解，而针对行人重识别中核心挑战——即视角与外观变化——所设计的特定损失函数（如视角损失），往往能更直接、高效地引导模型学习到更具判别力和鲁棒性的特征表示。综上所述，可视化结果从实证角度证实，通过显式建模视角信息来解耦外观变化，是提升行人重识别模型，尤其是在复杂跨外观场景下泛化能力的关键所在。

第五节 本章小结

为了解决跨外观行人重识别中视角给模型识别带来的挑战，本章从训练策略层面出发，提出了基于视角约束的的 MVMA 算法。算法通过视角预测网络给予行人图像视角标签，利用软间隔进行视角模糊，降低由于视角标签的预测错误引起的后续模型优化的谬误，同时在不同视角（差异较大的行人图像视角）



图 5.4 MVMA 网络的检索结果对比图

下的网络分支中，引入视角损失提升模型在跨视角的识别性能，根据模型的局部特征进行对齐，获取模型的细粒度细节特征，通过视角相似度和轮廓草图的相似度来约束行人图像的特征距离，模型在训练中被显式地引导去学习视角不变的身份特征，从而提升模型检索到跨外观行人图像的提升能力。通过消融实验和 SOTA 方法对比实验，本文验证了方法中每一个组件的有效性，并根据实验结果分析各个组件对模型的影响，并且模型的评估结果显著优于其他局部特征相关或视角相关的行人重识别模型的方法。总体来说，跨外观行人重识别的识别性能仍然是一个挑战性的问题。

与此同时，本章研究也让我们看到，目前特征表示、数据生成和视角约束三个模块仍以相对松耦合的方式协作，尚未形成端到端的统一学习框架。各模块的协同潜力还可进一步挖掘，例如是否可在生成阶段就注入视角控制，或者在表示学习过程中动态融合生成数据与视角约束信号，以实现更紧密的联合优化。此外，系统在轻量化部署和更多样化真实场景下的鲁棒性也有待验证。这些将成为未来研究的重要方向，推动跨外观行人重识别从分而治之的阶段性优化，迈向一体化、高泛化、可实用的下一代智能感知系统。

第六章 总结与展望

行人重识别技术是从实验室研究到技术落地产业的关键技术，其在计算机视觉技术和人工智能技术的生态中，扮演者不可或缺的连接者角色。行人重识别应用场景是与人脸识别的场景相互补充，弥补了人脸识别在远距离、背影视角、遮挡和低分辨率的监控场景失效的空白，构成了完整的对特定人员进行持续追踪和检索的解决方案。在智慧城市、公共安全和智能零售等具体场景中，行人重识别技术具有巨大的应用潜力，为跨境追踪、挖掘犯罪团伙、走失儿童巡回、交通流量分析、顾客动线分析、异常行为检测等提供技术支持，在大数据时代的背景下串联碎片信息。使大规模监控网络真正具有“智能”和“协同”的能力。尤其是跨外观的行人重识别研究，突破了目标行人衣着不变的假设，针对嫌疑人追捕和长时间行人检索的特殊应用场景发挥至关重要的作用。目前，科研人员对跨外观的行人重识别相关研究取得了积极进展，但仍存在一些关键问题和挑战，使得实验室研究和技术落地产业之间存在着难以难以弥合的鸿沟。

第一节 工作总结

本文在行人重识别技术的应用关键问题中瞄准实用性需求，聚焦于行人重识别问题建模和现实应用中的特殊差异，对于长时间段内的跨外观行人重识别问题进行分析，突破限制模型性能的关键因素。在行人重识别模型应用的数据集、行人特征提取、损失函数、模型训练策略等环节中，综合分析了目前相关研究方法中存在的问题，提供可行的解决问题的思路，总结如下：

1. 为了突破早期传统行人重识别对于行人衣着外观一致的问题假设，为基于深度学习技术的模型提供训练依据，本文在超过一个自然年的时间段内，收集了来自于多个室内室外的监控设备、300 余名目标在多个季节的监控视频序列。论文分析了评估行人图像相似度的影响因素，提升数据集的外观、光照、背景、视角等多样性，通过行人图像多样性增强模型对于模型识别的干扰因素的判别能力。此外，本文注意到行人重识别应用领域的特殊性，基于应用场景下人脸失效和人脸关联隐私等问题，数据集的行人图像对人脸进行模糊，使得本文提出的行人数据集的质、量优于类似工作。

2. 对于多数的传统行人重识别问题的研究，与衣着颜色、纹理相关的外观特征是模型识别中最具有判别性的依据，然而其在跨外观行人重识别中不再可靠，是对模型识别有消极影响的干扰因素。为了提升模型克服外观特征的误导，论文挖掘与行人图像相关的深层信息以获得鲁棒的行人特征。本文提出了融合多模态行人图像的算法，获取行人图像的潜在特征，针对跨外观的行人数据设计采样策略和损失函数，提出了一个通用的跨外观行人重识别算法作为新的基线方法，为后续进一步跨外观行人重识别研究奠定了基础。

3. 深度学习算法的性能受到数据质量的限制，尤其是训练数据的规模影响十分巨大，然而行人图像数据的采集和标注的时间和人力成本巨大，更涉及到人员的隐私权的限制，跨外观的行人数据集的采集时间和标注更为复杂。行人重识别算法的性能发展也伴随着行人数据集的发展，模型从原始行人图像映射到有效的特征空间的过程十分依赖行人图像的类内数据量和类间数据量，因此本文使用生成框架来合成行人图像，增加单个行人的外观多样性，提升模型对的行人图像的外观变化的适应能力，为跨外观行人重识别算法的训练提供了有利的支持。

4. 视角问题限制行人重识别算法检索性能的重要因素之一，由于监控设备的位置规划和公共道路的设计，不同监控设备拍摄的角度差异导致视角的变化，使得骨干网络提取的行人特征难以正确匹配，也成为算法的巨大挑战之一，对跨外观行人重识别的匹配尤为如此。因此，本文引入了与行人图像的视角相关的注意力机制，经过实验验证得到行人图像侧面视角的可靠性，通过限制行人不同视角的行人图像的特征空间距离，以促进模型对于跨视角和跨外观的行人图像的检索，通过挖掘相近视角的行人图像的体型特征根等，提升了跨外观的行人重识别算法的性能。

第二节 未来展望

虽然跨外观行人重识别领域已经得到了大量研究者的关注，但是仍存在一些问题有待进一步的研究。

6.2.1 开放场景下的行人重识别（Open-world Re-ID）问题

开放场景下的行人重识别是指将行人重识别算法部署到真实、复杂且动态变化的监控环境中时，所面临的一系列挑战和解决问题的范式。它打破了传统

行人重识别研究中的“封闭世界假设”，即测试集中的行人身份和环境条件都严格控制在训练集已知的分布内。其核心特征是“未知”和“变化”，首先是未知的身份，系统在测试时会遇到在训练集中从未见过的、全新的行人身份；其次是未知的环境，测试环境（光照、背景、摄像头型号、拍摄角度等）与训练环境存在显著差异，即领域偏移；最后是未知的异常，测试图像可能包含训练时未充分考虑的异常情况，如严重遮挡、极端姿态、模糊、噪声等。因此，开放场景下的 Re-ID 的核心目标不再是单纯追求在固定测试集上的最高分数，而是追求模型的泛化能力、鲁棒性和实用性，使其能够快速适应未知的环境和目标。

1. 无监督/跨域行人重识别（Unsupervised/Domain Adaptive Re-ID）问题：在一个源域（如 Market-1501）上训练好的模型，直接应用到另一个目标域（如应用场景的监控网络）时，性能会因领域偏移（Domain Shift）而急剧下降，而对每一个目标域数据标注身份成本很高。针对这类问题，研究者们提出几种不同的解决思路，包括无监督领域自适应（UDA）和纯无监督学习。前者利用源域有标签数据和目标域无标签数据进行训练，研究者们提出了基于聚类的伪标签生成、图像/特征风格转换、对抗生成网络（GAN）减小域差异等不同类型的算法。后者仅使用目标域无标签数据。难度更大，通常依赖于强大的聚类算法和质量估计。

2. 遮挡鲁棒行人重识别（Occlusion Robust Re-ID）问题：现实场景中遮挡无处不在，而现有模型大多在全身图像上训练，对遮挡非常敏感。针对遮挡问题，研究者们引入了遮挡感知设计和强化局部匹配等解决方案，如通过额外分支预测遮挡区域，在特征提取或匹配时将其权重降低；或设计更精细的局部特征提取和匹配机制，如动态对齐可见部分。部分研究者们试图使用同类型的遮挡数据来提高模型应对遮挡的能力，比如合成遮挡数据，使用数据增强技术（如随机擦除）生成大量遮挡样本，提升模型鲁棒性。

3. 端到端的行人重识别（Person Search）问题：也被定义为行人搜索问题，将行人检测和重识别两个独立的任务合并成一个统一的系统。系统输入是原始视频流，输出是行人的 ID 和轨迹。这更符合实际应用需求，但难度也大大增加。现有的方法主要分为两步法和一步法，早期的方法是组合检测和识别的两个网络，后续逐渐出现了共享骨干网的分支网络结构，目前出现了基于查询的方法，不断简化行人搜索的流程。

4. 异构行人重识别（Heterogeneous Re-ID）问题：也被称为多模态的行人重

识别问题，原始的行人数据不再局限于可见光下的行人图像，还包括红外光下的行人图像和行人的文本描述等类型，不同模态之间的行人检索存在巨大的模态鸿沟，需要跨模态的理解与匹配。目前大部分的研究内容分为可见光-红外行人重识别（VI-ReID）和文本-图像行人重识别，需要匹配可见光摄像头下的行人图像和夜晚红外热成像摄像头捕获的行人图像或自然语言描述（如“穿红色上衣、黑色裤子的女子”）。

5. 基于大模型的行人重识别算法[150]。大模型技术的出现推动了行人重识别任务的变革，从单一场景下的简单重识别转化为多任务、多模态扩展，即朝向“通用”行人重识别任务迈进，通过融合图像文本信息，在搜索过程中设计更优的提示。基于大模型的行人重识别正经历从“判别式视觉匹配”到“生成式语义理解”的范式变革。CLIP、GPT 等模型通过视觉-语言对齐、自监督预训练、动态提示增强等技术，显著提升了模型泛化能力与跨模态适应性。未来研究将聚焦于通用模型构建、空地协同感知、具身智能融合等方向，推动行人重识别技术从“实验室优秀”走向“真实场景“中可靠。

6.2.2 其他类型的行人重识别研究挑战

1. 视频序列行人重识别（Video-based Re-ID）问题：模型训练过程可以利用视频片段的多帧信息，而不仅仅是静态图像，视频序列监控数据包含丰富的时空信息，如 gait（步态）、运动模式，可以弥补外观信息的不足，为跨外观的行人重识别算法也提供了新的线索。对于基于视频序列的行人重识别算法来说，如何高效地融合时序信息是关键。研究者们提出了 3D CNN 网络、RNN/LSTM 时序网络、Transformer 结构、时序注意力机制等算法。

2. 跨域行人重识别（Cross-domain Re-ID）问题：真实监控系统中的行人重识别往往面临来自多摄像头、多视角、跨模态以及不同场景下的复杂数据分布差异，这些差异可统一归结为域偏移。具体而言，不同摄像头的成像特性、安装角度与所处环境构成了设备域与场景域；行人被捕获时的朝向（前、侧、后）构成了视角域；可见光、红外等传感器差异构成了模态域。各域之间数据分布的非线性漂移，使得模型在某一源域上学习到的外观判别模式极易在目标域上失效，表现出严重的泛化性能衰减。如何学习可跨域迁移的身份不变特征，成为该方向的核心科学问题。为应对这一挑战，研究者们从域泛化与域自适应两条路径展开了系统探索：在域泛化层面，通过实例归一化与批量归一化的混合设计、域不变对抗学习、以及元学习策略，引导模型从多个源域中挖掘域不敏感的判别

性表征；在域自适应层面，利用伪标签自训练、记忆字典协同更新及熵最小化等方法，在无需目标域标注的前提下逐步将模型适配至新域。此外，一些工作尝试通过神经风格迁移或生成式数据增强扩充源域的视觉多样性，以模拟未知域的分布，并联合多视角特征对齐与跨模态解耦技术，构建覆盖“设备-视角-模态”的统一域不变特征空间，从而在多维度域漂移下保持稳健的跨身份匹配能力。

3. 模型效率与部署（Model Efficiency and Deployment）问题：大型深度学习模型计算开销大，难以在资源有限的边缘设备（如嵌入式 NVIDIA Jetson、华为 Atlas 板卡）上实现实时检索。因此如何获取在保持模型性能的情况下获取轻量模型成为了研究者们的全新挑战。研究者们提出了基于模型压缩、知识蒸馏、网络剪枝、量化等技术的轻量化模型算法，在尽可能保持性能的前提下，大幅降低模型复杂度和计算量。

4. 隐私与伦理（Privacy and Ethics）问题：行人重识别技术是一把双刃剑，在提升社会安全的同时，也可能被用于大规模人员跟踪，引发严重的隐私担忧。算法的应用在技术层面和法律与伦理层面不断改进，一方面制定严格的法律法规和使用规范，明确技术的使用边界，确保技术向善；另一方面，研究者们提出了联邦学习、差分隐私等技术，在不接触原始数据的前提下进行模型训练，从而避免相关人员直接获取原始的行人图像信息，降低隐私泄露的风险。

参考文献

[1] GHEISSARI N, SEBASTIAN T, HARTLEY R. Person Reidentification Using Spatiotemporal Appearance[C]//2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06): vol. 2. 2006: 1528-1535.

[2] GRAY D, BRENNAN S, TAO H. Evaluating Appearance Models for Recognition, Reacquisition, and Tracking[C/OL]//IEEE international workshop on performance evaluation for tracking and surveillance. 2007: 1-7. https://api.semanticscholar.org/CorpusID:15225312.

[3] WANG X, DORETTO G, SEBASTIAN T, et al. Shape and Appearance Context Modeling [C]//2007 IEEE 11th International Conference on Computer Vision. 2007: 1-8. DOI: 10.1109/ICCV.2007.4409019.

[4] GRAY D, TAO H. Viewpoint Invariant Pedestrian Recognition with an Ensemble of Localized Features[C]//FORSYTH D, TORR P, ZISSERMAN A. Computer Vision – ECCV 2008. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008: 262-275.

[5] BAZZANI L, CRISTANI M, PERINA A, et al. Multiple-shot person re-identification by chromatic and epitomic analyses[J]. Pattern Recognition Letters, 2008, 33(7): 898-903.

[6] FARENZENA M, BAZZANI L, PERINA A, et al. Person re-identification by symmetry-driven accumulation of local features[C]//2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 2010: 2360-2367. DOI: 10.1109/CVPR.2010.5539926.

[7] BĄK S, CORVEE E, BRÉMOND F, et al. Person Re-identification Using Spatial Covariance Regions of Human Body Parts[C]//2010 7th IEEE International Conference on Advanced Video and Signal Based Surveillance. 2010: 435-440. DOI: 10.1109/AVSS.2010.34.

[8] PROSSER B, ZHENG W S, GONG S, et al. Person Re-Identification by Support Vector Ranking[J]. DBLP, 2010: 21.1-21.11.

[9] CHENG D S, CRISTANI M, BAZZANI L, et al. Custom Pictorial Structures for Re-identification[C]//British Machine Vision Conference. 2011.

[10] MA B, SU Y, JURIE F. Local Descriptors Encoded by Fisher Vectors for Person Re-identification[C]//Computer Vision – ECCV 2012. Workshops and Demonstrations. 2012: 413-422.

[11] ZHENG W S, GONG S, XIANG T. Person re-identification by probabilistic relative distance comparison[C]//CVPR 2011. 2011: 649-656. DOI: 10.1109/CVPR.2011.5995598.

[12] KÖSTINGER M, HIRZER M, WOHLHART P, et al. Large scale metric learning from equivalence constraints[C]//2012 IEEE Conference on Computer Vision and Pattern Recognition. 2012: 2288-2295. DOI: 10.1109/CVPR.2012.6247939.

[13] HIRZER M, ROTH P M, KÖSTINGER M, et al. Relaxed Pairwise Learned Metric for Per-

son Re-identification[C]//FITZGIBBON A, LAZEBNIK S, PERONA P, et al. Computer Vision – ECCV 2012. Berlin, Heidelberg: Springer Berlin Heidelberg, 2012: 780-793.

[14] LI W, ZHAO R, XIAO T, et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. 2014: 152-159. DOI: 10.1109/CVPR.2014.27.

[15] AHMED E, JONES M, MARKS T K. An improved deep learning architecture for person re-identification[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 3908-3916. DOI: 10.1109/CVPR.2015.7299016.

[16] ZHENG Z, ZHENG L, YANG Y. A Discriminatively Learned CNN Embedding for Person Reidentification[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2016, 14: 1-20.

[17] HERMANS A, BEYER L, LEIBE B. In Defense of the Triplet Loss for Person Re-Identification[J]. ArXiv, 2017, abs/1703.07737.

[18] SUN Y, CHENG C, ZHANG Y, et al. Circle Loss: A Unified Perspective of Pair Similarity Optimization[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 6397-6406.

[19] SUN Y, ZHENG L, YANG Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 480-496.

[20] WANG G, YUAN Y, CHEN X, et al. Learning discriminative features with multiple granularities for person re-identification[C]//Proceedings of the 26th ACM international conference on Multimedia. 2018: 274-282.

[21] ZHANG X, LUO H, FAN X, et al. AlignedReID: Surpassing Human-Level Performance in Person Re-Identification[J]. 2017.

[22] LIU X, HAN H, XU K, et al. Cloth-Changing Person Re-Identification Based on the Backtracking Mechanism[J]. IEEE Access, 2025, 13: 27527-27536. DOI: 10.1109/ACCESS.2025.3538976.

[23] ZHAO J, HOU R, CHANG H, et al. Clothes-Changing Person Re-Identification With Feasibility-Aware Intermediary Matching[J]. IEEE Transactions on Multimedia, 2025, 27: 3307-3319. DOI: 10.1109/TMM.2025.3535357.

[24] LI W, ZHU X, GONG S. Harmonious Attention Network for Person Re-Identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018.

[25] CHEN T, DING S, XIE J, et al. ABD-Net: Attentive but Diverse Person Re-Identification [C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 8350-8360. DOI: 10.1109/ICCV.2019.00844.

[26] DAI Z, CHEN M, GU X, et al. Batch DropBlock Network for Person Re-Identification and Beyond[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 3690-3700. DOI: 10.1109/ICCV.2019.00379.

[27] YANG F, YAN K, LU S, et al. Attention driven person re-identification[J]. Pattern Recognition, 2019, 86: 143-155.

[28] ZHANG Z, LAN C, ZENG W, et al. Relation-Aware Global Attention for Person Re-Identification[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 3183-3192. DOI: 10.1109/CVPR42600.2020.00325.

[29] YANG J, ZHENG W S, YANG Q, et al. Spatial-Temporal Graph Convolutional Network for Video-Based Person Re-Identification[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 3286-3296. DOI: 10.1109/CVPR42600.2020.00335.

[30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, California, USA: Curran Associates Inc., 2017: 6000-6010.

[31] HE S, LUO H, WANG P, et al. TransReID: Transformer-based Object Re-Identification[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 14993-15002. DOI: 10.1109/ICCV48922.2021.01474.

[32] HU B, WANG X, LIU W. Personvit: large-scale self-supervised vision transformer for person re-identification[J]. Machine Vision and Applications, 2025, 36(32): 1-13.

[33] 赵博. 基于域连通性学习和自适应特征学习的跨集换装行人重识别算法研究[D]. 河南大学, 2024. DOI: 10.27114/d.cnki.ghnau.2024.000348.

[34] 张培煦, 胡冠宇, 杨新宇. 一种域增强和域自适应的换衣行人重识别范式[J]. 西安电子科技大学学报, 2023, 50(05): 87-94. DOI: 10.19665/j.issn1001-2400.20221106.

[35] 刘婕. 基于特征融合与域适应的换衣行人重识别研究[D]. 南京信息工程大学, 2023. DOI: 10.27248/d.cnki.gnjqc.2023.000251.

[36] XIAO T, LI H, OUYANG W, et al. Learning deep feature representations with domain guided dropout for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1249-1258.

[37] HUANG H, YANG W, CHEN X, et al. EANet: Enhancing alignment for cross-domain person re-identification[J]. arXiv preprint arXiv:1812.11369, 2018.

[38] ZHONG Z, ZHENG L, LUO Z, et al. Invariance matters: Exemplar memory for domain adaptive person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 598-607.

[39] LIU J, ZHA Z J, CHEN D, et al. Adaptive transfer network for cross-domain person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 7202-7211.

[40] ZOU Y, YANG X, YU Z, et al. Joint disentangling and adaptation for cross-domain person re-identification[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part II 16. 2020: 87-104.

[41] XU H, LI B, NIU G. Identity-aware Feature Decoupling Learning for Clothing-change Person Re-identification[C]//ICASSP 2025 - 2025 IEEE International Conference on Acous-

tics, Speech and Signal Processing (ICASSP). 2025: 1-5. DOI: 10.1109/ICASSP49660.2025.10888292.

[42] LIANG X, RAWAT Y S. DIFFER: Disentangling Identity Features via Semantic Cues for Clothes-Changing Person Re-ID[C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2025: 13980-13989. DOI: 10.1109/CVPR52734.2025.01305.

[43] ZHANG P, DOU H, YU Y, et al. Adaptive cross-domain learning for generalizable person re-identification[C]//European conference on computer vision. 2022: 215-232.

[44] 陈国强. 基于对比学习的无监督换装行人重识别算法研究[D]. 吉林大学, 2025. DOI: 10.27162/d.cnki.gjlin.2025.004646.

[45] FAN H, ZHENG L, YAN C, et al. Unsupervised person re-identification: Clustering and fine-tuning[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2018, 14(4): 1-18.

[46] LI M, ZHU X, GONG S. Unsupervised person re-identification by deep learning tracklet association[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 737-753.

[47] YU H X, ZHENG W S, WU A, et al. Unsupervised person re-identification by soft multilabel learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 2148-2157.

[48] LIN Y, DONG X, ZHENG L, et al. A bottom-up clustering approach to unsupervised person re-identification[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 33: 01. 2019: 8738-8745.

[49] FU D, CHEN D, BAO J, et al. Unsupervised pre-training for person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14750-14759.

[50] DAI Z, WANG G, YUAN W, et al. Cluster contrast for unsupervised person re-identification[C]//Proceedings of the Asian conference on computer vision. 2022: 1142-1160.

[51] CHENG D, ZHOU J, WANG N, et al. Hybrid dynamic contrast and probability distillation for unsupervised person re-id[J]. IEEE Transactions on Image Processing, 2022, 31: 3334-3346.

[52] 张敏, 余增, 韩云星, 等. 面向复杂场景的行人重识别综述[J]. 计算机科学, 2022, 49(10): 138-150.

[53] 马磊. 开放场景下的行人重识别研究[D]. 江南大学, 2023. DOI: 10.27169/d.cnki.gwqgu.2023.000593.

[54] 郑智豪. 复杂场景下基于 Transformer 的行人重识别方法研究[D]. 杭州电子科技大学, 2024. DOI: 10.27075/d.cnki.ghzdc.2024.000788.

[55] 赵志伟. 面向复杂开放场景的行人重识别算法研究[D]. 中国科学技术大学, 2024. DOI: 10.27517/d.cnki.gzkju.2024.000535.

[56] 薛宸. 复杂条件下的行人重识别技术研究[D]. 北京邮电大学, 2025. DOI: 10.26969/d.

cnki.gbydu.2025.000371.

[57] 陈敬天. 基于卷积网络的机场场景下行人重识别方法研究[D]. 吉林大学, 2025. DOI: 10.27162/d.cnki.gjlin.2025.004767.

[58] 李军委. 基于开放监控场景的换衣行人重识别研究及应用[D]. 中国矿业大学, 2025. DOI: 10.27623/d.cnki.gzkyu.2025.001807.

[59] 王馨爽. 复杂场景下行人重识别系统的设计与实现[D]. 北京邮电大学, 2025. DOI: 10.26969/d.cnki.gbydu.2025.002131.

[60] 邵春锐. 复杂场景下的行人重识别方法研究[D]. 哈尔滨理工大学, 2025. DOI: 10.27063/d.cnki.ghlgu.2025.000878.

[61] MIAO J, WU Y, LIU P, et al. Pose-guided feature alignment for occluded person re-identification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 542-551.

[62] WANG G, YANG S, LIU H, et al. High-order information matters: Learning relation and topology for occluded person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 6449-6458.

[63] LI Y, HE J, ZHANG T, et al. Diverse part discovery: Occluded person re-identification with part-aware transformer[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 2898-2907.

[64] WANG Z, ZHU F, TANG S, et al. Feature erasing and diffusion network for occluded person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 4754-4763.

[65] SOMERS V, DE VLEESCHOUWER C, ALAHI A. Body Part-Based Representation Learning for Occluded Person Re-Identification[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2023: 1613-1623.

[66] HAQUE A, ALAHI A, FEI-FEI L. Recurrent attention models for depth-based person identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1229-1238.

[67] KARIANAKIS N, LIU Z, CHEN Y, et al. Reinforced temporal attention and split-rate transfer for depth-based person re-identification[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 715-733.

[68] YE M, LAN X, LI J, et al. Hierarchical discriminative learning for visible thermal person re-identification[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 32: 1. 2018.

[69] YE M, SHEN J, J. CRANDALL D, et al. Dynamic Dual-Attentive Aggregation Learning for Visible-Infrared Person Re-identification[C]//Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 229-247.

[70] YE M, SHEN J, SHAO L. Visible-Infrared Person Re-Identification via Homogeneous Augmented Tri-Modal Learning[J]. IEEE Transactions on Information Forensics and Security, 2021, 16: 728-739.

[71] WANG Z, WANG Z, ZHENG Y, et al. Learning to Reduce Dual-Level Discrepancy for Infrared-Visible Person Re-Identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019.

[72] CHOI S, LEE S, KIM Y, et al. Hi-CMD: Hierarchical Cross-Modality Disentanglement for Visible-Infrared Person Re-Identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020.

[73] NGUYEN H S S, Nguyen K, C F. Aerial-ground person re-id. 2023.

[74] NGUYEN K S S, Fookes C, G D. Ag-reid 2023: Aerial-ground person re-identification challenge results. 2023.

[75] NGUYEN H S S, Nguyen K, C F. AG-ReID. v2: Bridging aerial and ground views for person re-identification. 2024.

[76] NGUYEN H P A, Nguyen K, C F. Ag-vpreid: A challenging large-scale benchmark for aerial-ground video-based person re-identification. 2025.

[77] NGUYEN K S S, Fookes C, S R. Ag-vpreid 2025: Aerial-ground video-based person re-identification challenge results. 2025.

[78] Q ZHANG V P, L Wang, LAI J. View-decoupled transformer for person re-identification under aerial-ground camera network. 2024.

[79] WANG SHINING W R, Wang Yunlong, PENG W. SeCap: Self-Calibrating and Adaptive Prompts for Cross-View Person Re-Identification in Aerial-Ground Networks[C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2025: 22119-22128. DOI: 10.1109/CVPR52734.2025.02060.

[80] SHIZHOU ZHANG D C, Wenlong Luo, ZHANG Y. Cross-Platform Video Person ReID: A New Benchmark Dataset and Adaptation Approach[C]//Lecture Notes in Computer Science: Computer Vision - ECCV 2024 - 18th European Conference, Milan, Italy. 2024: 270-287.

[81] HAMBARDE K A, MBONGO N, MP P K, et al. DetReIDX: A Stress-Test Dataset for Real-World UAV-Based Person Recognition[J]. 2025.

[82] HA RUIYANG L B, Jiang Songyi, JINGYA W. Multi-Modal Multi-Platform Person Re-Identification: Benchmark and Method[C]//2025 IEEE/CVF International Conference on Computer Vision (ICCV). 2025: 10251-10261. DOI: 10.1109/ICCV51701.2025.00955.

[83] YANG Q, WU A, ZHENG W S. Person re-identification by contour sketch under moderate clothing change[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 43(6): 2029-2046.

[84] QIAN X, WANG W, ZHANG L, et al. Long-term cloth-changing person re-identification [C]//Proceedings of the Asian Conference on Computer Vision. 2020.

[85] YU S, LI S, CHEN D, et al. Cocas: A large-scale clothes changing person dataset for re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 3400-3409.

[86] FAN L, LI T, FANG R, et al. Learning longterm representations for person re-identification

using radio signals[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10699-10709.

[87] HONG P, WU T, WU A, et al. Fine-grained shape-appearance mutual learning for cloth-changing person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 10513-10522.

[88] 刘乾, 王洪元, 曹亮, 等. 基于联合损失胶囊网络的换衣行人重识别[J]. 计算机应用, 2021, 41(12): 3596-3601.

[89] 王亦秋. 相似衣着行人重识别技术研究[D]. 华中科技大学, 2022. DOI: 10.27157/d.cnki.ghzku.2022.002958.

[90] 黄宇坤. 面向降质图像的行人重识别方法研究[D]. 中国科学技术大学, 2023. DOI: 10.27517/d.cnki.gzkju.2023.000852.

[91] 武之越. 换衣行人重识别技术研究[D]. 中国人民公安大学, 2024. DOI: 10.27634/d.cnki.gzrgu.2024.000409.

[92] ZHENG L, SHEN L, TIAN L, et al. Scalable person re-identification: A benchmark[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1116-1124.

[93] RISTANI E, SOLERA F, ZOU R, et al. Performance measures and a data set for multi-target, multi-camera tracking[C]//European conference on computer vision. 2016: 17-35.

[94] WEI L, ZHANG S, GAO W, et al. Person transfer gan to bridge domain gap for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 79-88.

[95] HUANG Y, XU J, WU Q, et al. Beyond scalar neuron: Adopting vector-neuron capsules for long-term person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(10): 3459-3471.

[96] WAN F, WU Y, QIAN X, et al. When person re-identification meets changing clothes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020: 830-831.

[97] WANG K, MA Z, CHEN S, et al. A benchmark for clothes variation in person re-identification[J]. International Journal of Intelligent Systems, 2020, 35(12): 1881-1898.

[98] SHU X, WANG X, ZANG X, et al. Large-Scale Spatio-Temporal Person Re-identification: Algorithms and Benchmark[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021.

[99] XU P, ZHU X. Deepchange: A large long-term person re-identification benchmark with clothes change[J]. arXiv e-prints, 2021: arXiv-2105.

[100] LIU M, MA Z, LI T, et al. Long-Term Person Re-identification with Dramatic Appearance Change: Algorithm and Benchmark[C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 6406-6415.

[101] WANG L, ZHANG X, HAN R, et al. A New Benchmark and Algorithm for Clothes-Changing Video Person Re-Identification[J]. IEEE Transactions on Information Forensics and Security, 2025, 20: 1993-2005. DOI: 10.1109/TIFS.2025.3539079.

[102] ZHAN Y, WANG C, WANG X, et al. A Simple Baseline for Multi-Object Tracking[J]. 2020.

[103] 古小诗. 基于姿态引导的化工厂区行人重识别技术研究[D]. 淮阴工学院, 2025. DOI: 10.27944/d.cnki.ghygy.2025.000170.

[104] 周思瑶, 夏楠, 江佳鸿. 姿态引导的双分支换装行人重识别网络[J]. 浙江大学学报 (工学版), 2026, 60(01): 71-80.

[105] 贾雪梅. 基于互补性增广和自适应注意力的长时行人重识别方法[D]. 武汉理工大学, 2022. DOI: 10.27381/d.cnki.gwlgu.2022.001848.

[106] 钟建华, 邱创一, 巢建树, 等. 基于语义引导自注意力网络的换衣行人重识别模型[J]. 计算机应用, 2023, 43(12): 3719-3726.

[107] 李鹏辉, 王洪元, 张继, 等. 基于多重注意力机制和空间变换网络的换衣行人重识别[J]. 南京大学学报 (自然科学), 2025, 61(02): 202-213. DOI: 10.13232/j.cnki.jnju.2025.02.002.

[108] 胡涌涛, 黄洪琼. 结合特征融合和通道注意力的多分支换装行人重识别[J]. 计算机工程, 2025, 51(01): 225-234. DOI: 10.19678/j.issn.1000-3428.0068392.

[109] 卢洋. 基于差异注意力和图文互学习的换衣行人重识别方法研究[D]. 安徽理工大学, 2025. DOI: 10.26918/d.cnki.ghngc.2025.000810.

[110] 丁钰, 毕晓君. 融合样本关系优化和重排序的换衣行人重识别[J]. 智能系统学报, 2025, 20(01): 101-108.

[111] OJALA T, PIETIKÄINEN M, MÄENPÄÄ T. A Generalized Local Binary Pattern Operator for Multiresolution Gray Scale and Rotation Invariant Texture Classification[C]//International Conference on Advances in Pattern Recognition. 2001.

[112] DALAL N, TRIGGS B. Histograms of Oriented Gradients for Human Detection[C]//IEEE Computer Society Conference on Computer Vision & Pattern Recognition. 2005.

[113] LIAO S, HU Y, ZHU X, et al. Person re-identification by Local Maximal Occurrence representation and metric learning[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 2197-2206.

[114] GOLDBERGER J, ROWEIS S, HINTON G, et al. Neighbourhood components analysis [C]//Proceedings of the 18th International Conference on Neural Information Processing Systems: 8. Cambridge, MA, USA: MIT Press, 2004: 513-520.

[115] DAVIS J V, KULIS B, JAIN P, et al. Information-theoretic metric learning[C]//ICML '07: Proceedings of the 24th International Conference on Machine Learning: 8. Corvalis, Oregon, USA, 2007: 209-216.

[116] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[117] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[118] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C]//Proceedings of

the IEEE conference on computer vision and pattern recognition. 2018: 7794-7803.

[119] PAN X, LUO P, SHI J, et al. Two at once: Enhancing learning and generalization capacities via ibn-net[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 464-479.

[120] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.

[121] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.

[122] SHU X, LI G, WANG X, et al. Semantic-guided pixel sampling for cloth-changing person re-identification[J]. IEEE Signal Processing Letters, 2021, 28: 1365-1369.

[123] 张攀. 基于人体高级语义的换衣行人重识别算法研究[D]. 天津理工大学, 2024. DOI: 10.27360/d.cnki.gtlgy.2024.000288.

[124] 王凯锐. 基于人体语义解析和对抗性学习的换衣行人重识别研究[D]. 西安电子科技大学, 2024. DOI: 10.27389/d.cnki.gxadu.2024.000449.

[125] 邹明东. 基于语义解析的换衣行人重识别算法研究[D]. 河南大学, 2024. DOI: 10.27114/d.cnki.ghnau.2024.000330.

[126] 程玮. 基于知识引导学习的换衣行人重识别研究[D]. 大连理工大学, 2024. DOI: 10.26991/d.cnki.gdllu.2024.004582.

[127] W K. 面向换衣行人重识别的衣着无关特征学习[D]. 中国科学技术大学, 2024. DOI: 10.27517/d.cnki.gzkju.2024.001671.

[128] LUO H, GU Y, LIAO X, et al. Bag of tricks and a strong baseline for deep person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2019: 4321-4329.

[129] HE L, LIAO X, LIU W, et al. Fastreid: A pytorch toolbox for general instance re-identification[J]. arXiv preprint arXiv:2006.02631, 2020.

[130] ZHANG Z, LAN C, ZENG W, et al. Relation-aware global attention for person re-identification[C]//Proceedings of the ieee/cvf conference on computer vision and pattern recognition. 2020: 3186-3195.

[131] YE M, SHEN J, LIN G, et al. Deep learning for person re-identification: A survey and outlook[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021.

[132] BEGUM R, DEB K. Clothes-Changing Person Re-identification with Unique Identity-Specific Attribute Details[C]//Data Science, AI and Applications. Cham: Springer Nature Switzerland, 2025: 61-75.

[133] 葛斌, 卢洋, 夏晨星, 等. 基于文本图像互学习的换衣行人重识别方法[J]. 模式识别与人工智能, 2024, 37(11): 960-973. DOI: 10.16451/j.cnki.issn1003-6059.202411002.

[134] LIU H, ZHAO Y, NIU G. Try Harder: Hard Sample Generation and Learning for Cloth-Changing Person Re-ID[C]//Proceedings of the 33rd ACM International Conference on

Multimedia, MM 2025, Dublin, Ireland, October 27-31, 2025. ACM, 2025: 1704-1713. DOI: 10.1145/3746027.3755394.

[135] NGUYEN V D, MANTINI P, SHAH S K. Temporal 3D Shape Modeling for Video-based Cloth-Changing Person Re-Identification[C]//2024 IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW). 2024: 173-182. DOI: 10.1109/WACVW60836.2024.00025.

[136] 庄建军, 王楠. T3FRNet：一种融合三重感知细粒度重构的换衣行人重识别方法[J]. 电子与信息学报, 2026, 48(01): 370-381.

[137] DENG W, ZHENG L, YE Q, et al. Image-image domain adaptation with preserved self-similarity and domain-dissimilarity for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 994-1003.

[138] ZHENG Z, YANG X, YU Z, et al. Joint discriminative and generative learning for person re-identification[C]//proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 2138-2147.

[139] KARRAS T, LAINE S, AITTALA M, et al. Analyzing and Improving the Image Quality of StyleGAN[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020.

[140] XU Y, DENG B, WANG J, et al. High-resolution face swapping via latent semantics disentanglement[C]//proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 7642-7651.

[141] JIA X, ZHONG X, YE M, et al. Complementary data augmentation for cloth-changing person re-identification[J]. IEEE Transactions on Image Processing, 2022, 31: 4227-4239.

[142] HAN K, GONG S, HUANG Y, et al. Clothing-Change Feature Augmentation for Person Re-Identification[C]//proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 22066-22075.

[143] ZHIHUI Z, XINYANG J, FENG Z, et al. Viewpoint-aware loss with angular regularization for person re-identification[C]//In Proceedings of the 33rd AAAI Conference on Artificial Intelligence (AAAI-19). 2019: 1-10.

[144] QIAN X, FU Y, XIANG T, et al. Pose-Normalized Image Generation for Person Re-identification[C]//15th European Conference on Computer Vision. 2018: 661-678.

[145] KALAYEH M M, BASARAN E, GÖKMEN M, et al. Human Semantic Parsing for Person Re-identification[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 1062-1071. DOI: 10.1109/CVPR.2018.00117.

[146] CHU R, SUN Y, LI Y, et al. Vehicle Re-Identification With Viewpoint-Aware Metric Learning[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 8281-8290. DOI: 10.1109/ICCV.2019.00837.

[147] WANG Y W L, Hu X, H L. SD-ReID: view-aware stable diffusion for aerial-ground person re-identification. 2026.

[148] TU H, LIU C, PENG Y, et al. Clothing-change person re-identification based on fusion of

RGB modality and gait features[J]. Signal, Image and Video Processing, 2024, 18: 2367-2376. DOI: 110.1007/s11760-023-02913-4.

[149] 刘超. 基于多分支结构与步态特征的换衣行人重识别研究[D]. 华东交通大学, 2024. DOI: 10.27147/d.cnki.ghdju.2024.000556.

[150] 冯展祥, 赖剑煌, 袁藏, 等. 走向通用行人重识别：预训练大模型技术在行人重识别的应用综述[J]. 中国图象图形学报, 2025, 30(06): 1638-1660.

致谢

行文至此，意味着我漫长的博士求学生涯即将画上一个句号。掩卷沉思，百感交集。这段旅程充满了探索的兴奋、迷茫的困顿与突破的喜悦，而这一切并非我一人之力所能及。在此，我谨以最诚挚的谢意，献给所有曾照亮我学术之路、给予我温暖与力量的师友亲朋。

首先，我最深沉的敬意与感谢献给我的导师李涛教授。承蒙老师不弃，得以列入门墙。写到这里，心里有太多话想说，又怕说得太简单。李老师，真的特别特别感谢您！要不是您把我领进门，一路鞭策我、指引我，我这博士恐怕是读不下来的。除了学术，我更感谢您教我怎么做事、怎么做人。这份师恩，如山之高，似海之深，学生永志不忘。

感谢卢冶老师在我迷茫时鼓励我，使我树立信心。感谢王恺老师对我科研工作的悉心指导。感谢计算机学院的各位老师，在课程学习与学术研讨中给予我的启迪与帮助。感谢评审委员会的各位专家在百忙之中审阅本论文，并提出宝贵意见。

同门之谊，手足之情。感谢实验室的各位同窗：感谢郭松师兄和高颖琪师姐在我初入实验室时对我在技术上的倾囊相授，感谢王智弘师弟与其他同门在数据收集过程中的鼎力相助，感谢与马志同学的每一次激烈讨论与思维碰撞，感谢胡春雨同学和刘新慧师妹，感谢董慧娟、谢坤鹏、赫鑫宇几位同学，在我学习和生活中给予言语和行动的支持，是你们让这段原本可能枯燥的科研生活变得丰富多彩。那些挑灯夜战的日子、那些互相鼓励的时刻，都将成为我记忆中最珍贵的宝藏。

最后，谨以此文感谢我默默奉献的家人。感谢我的父母，二老数十载含辛茹苦，无私支持我的每一个决定，你们永远是我最坚实的后盾和最温暖的港湾。你们的理解、包容与鼓励，是我疲惫时最温柔的慰藉，让我得以心无旁骛地追逐梦想。

寥寥数语，难尽谢忱。所有未能一一提及的关心与帮助，我将铭记于心。学海无涯，博士毕业并非终点，而是一个新的起点。我将承载着所有人的期望与祝福，在未来的道路上继续求索，努力前行。

个人简历、在学期间发表的学术论文与研究成果

个人简历

刘蒙蒙，出生于 1996 年 12 月 10 日。在 2019 年毕业于南开大学物联网工程专业并获得工学学士学位。于 2019 年至今在南开大学就读计算机科学与技术研究生。

研究生期间发表论文:

- 刘蒙蒙, 郭松, 高颖琪, 李涛 *. 可学习的硬性渗出病变点标注方法 [J]. 小型微型计算机系统. Vol.40, 2657-2661, 2019.
- Mengmeng Liu, Zhi Ma, Tao Li, Yanfeng Jiang, Kai Wang*. Long-Term Person Re-identification with Dramatic Appearance Change: Algorithm and Benchmark[C]. ACM International Conference on Multimedia (ACM MM2022). June, 2022.
- Mengmeng Liu, Tao Li, Zhihong Wang, Along He, Tehui Huang and Qiankun Dong*. A Novel Framework for Data Augmentation on Appearance Changes for Long-Term Person Re-identification[C]. IEEE International Conference on JointCloud Computing 2025 (IEEE JCC 2025), June 2025.

研究生期间其它成果:

- 刘蒙蒙，谢学说，李涛. 一种基于生成模型的跨外观行人重识别检测方法. （专利）
- 刘蒙蒙. “昇腾众智开发者”称号。
- 王恺，马志，胡春雨，刘蒙蒙，刘方鑫. 南开大学第一届“科源杯”大赛潜力奖。
- 中国人工智能学会-华为 Mindspore 学术奖励基金项目：深度神经网络量化方法研究
- 国家重点研发计划课题项目：面向深度融合的异质物联网应用服务协同技术